

Inferência Estatística Comparada

AULA 4 - INFERÊNCIA CLÁSSICA

Introdução

● INFERÊNCIA ESTATÍSTICA

- Questões sobre procedimento inferencial (inferência estatística):
- (i) O que é Informação em um processo de inferência estatística e como podemos representá-la?
- (ii) Quais tipos de questões queremos responder com a informação experimental e quais procedimentos devemos/podemos adotar para responder tais questões?
- (iii) Quais critérios devemos estabelecer para avaliar o desempenho de tais procedimentos?

Introdução

- **INFERÊNCIA ESTATÍSTICA**

- Questões sobre procedimento inferencial (inferência estatística):

- (i) O que é Informação em um processo de inferência estatística e como podemos representá-la?
- (ii) Quais tipos de questões queremos responder com a informação experimental e quais procedimentos devemos/podemos adotar para responder tais questões?
- (iii) Quais critérios devemos estabelecer para avaliar o desempenho de tais procedimentos?

Introdução

- **INFERÊNCIA ESTATÍSTICA**

- Questões sobre procedimento inferencial (inferência estatística):
 - (i) O que é Informação em um processo de inferência estatística e como podemos representá-la?
 - (ii) Quais tipos de questões queremos responder com a informação experimental e quais procedimentos devemos/podemos adotar para responder tais questões?
 - (iii) Quais critérios devemos estabelecer para avaliar o desempenho de tais procedimentos?

Introdução

- **INFERÊNCIA ESTATÍSTICA**

- Questões sobre procedimento inferencial (inferência estatística):
 - (i) O que é Informação em um processo de inferência estatística e como podemos representá-la?
 - (ii) Quais tipos de questões queremos responder com a informação experimental e quais procedimentos devemos/podemos adotar para responder tais questões?
 - (iii) Quais critérios devemos estabelecer para avaliar o desempenho de tais procedimentos?

Introdução

- **INFERÊNCIA ESTATÍSTICA**

- Questões sobre procedimento inferencial (inferência estatística):
 - (i) O que é Informação em um processo de inferência estatística e como podemos representá-la?
 - (ii) Quais tipos de questões queremos responder com a informação experimental e quais procedimentos devemos/podemos adotar para responder tais questões?
 - (iii) Quais critérios devemos estabelecer para avaliar o desempenho de tais procedimentos?

Introdução

- **ELEMENTOS BÁSICOS**

- θ : parâmetro
- Θ : Espaço paramétrico
- X : amostra
- \mathcal{X} : Espaço amostral

Introdução

- **ELEMENTOS BÁSICOS**

- θ : parâmetro
- Θ : Espaço paramétrico
- X : amostra
- \mathcal{X} : Espaço amostral

Introdução

- **ELEMENTOS BÁSICOS**

- θ : parâmetro
- Θ : Espaço paramétrico
- X : amostra
- \mathcal{X} : Espaço amostral

Introdução

- **ELEMENTOS BÁSICOS**

- θ : parâmetro
- Θ : Espaço paramétrico
- X : amostra
- \mathcal{X} : Espaço amostral

Introdução

- **ELEMENTOS BÁSICOS**

- θ : parâmetro
- Θ : Espaço paramétrico
- X : amostra
- \mathcal{X} : Espaço amostral

Introdução

- **MODELO ESTATÍSTICO (CLÁSSICO)**

- $(\mathcal{X}, \mathcal{F}, \mathcal{P})$: onde
- \mathcal{X} : Espaço amostral,
- \mathcal{F} é classe de subconjuntos (σ -álgebra) de \mathcal{X} e
- $\mathcal{P} = \{\mathbb{P}(\cdot|\theta) : \theta \in \Theta\}$ é família de distribuições sobre \mathcal{F} indexada em θ (família paramétrica).

Introdução

- **MODELO ESTATÍSTICO (CLÁSSICO)**

- $(\mathcal{X}, \mathcal{F}, \mathcal{P})$: onde

- \mathcal{X} : Espaço amostral,

- \mathcal{F} é classe de subconjuntos (σ -álgebra) de \mathcal{X} e

- $\mathcal{P} = \{\mathbb{P}(\cdot|\theta) : \theta \in \Theta\}$ é família de distribuições sobre \mathcal{F} indexada em θ (família paramétrica).

Introdução

- **MODELO ESTATÍSTICO (CLÁSSICO)**

- $(\mathcal{X}, \mathcal{F}, \mathcal{P})$: onde

- \mathcal{X} : Espaço amostral,

- \mathcal{F} é classe de subconjuntos (σ -álgebra) de \mathcal{X} e

- $\mathcal{P} = \{\mathbb{P}(\cdot|\theta) : \theta \in \Theta\}$ é família de distribuições sobre \mathcal{F} indexada em θ (família paramétrica).

Introdução

- **MODELO ESTATÍSTICO (CLÁSSICO)**

- $(\mathcal{X}, \mathcal{F}, \mathcal{P})$: onde

- \mathcal{X} : Espaço amostral,

- \mathcal{F} é classe de subconjuntos (σ -álgebra) de \mathcal{X} e

- $\mathcal{P} = \{\mathbb{P}(\cdot|\theta) : \theta \in \Theta\}$ é família de distribuições sobre \mathcal{F} indexada em θ (família paramétrica).

Introdução

- **MODELO ESTATÍSTICO (CLÁSSICO)**

- $(\mathcal{X}, \mathcal{F}, \mathcal{P})$: onde
- \mathcal{X} : Espaço amostral,
- \mathcal{F} é classe de subconjuntos (σ -álgebra) de \mathcal{X} e
- $\mathcal{P} = \{\mathbb{P}(\cdot|\theta) : \theta \in \Theta\}$ é família de distribuições sobre \mathcal{F} indexada em θ (família paramétrica).

Introdução

- No exemplo 1 (segunda aula), $\Theta = \{1, 2, 3, \dots\}$ e $X|\theta \sim U(\{1, \dots, \theta\})$.
- No exemplo 2 (segunda aula), $\Theta = [0, 1]$ e $X = (X_1, \dots, X_n)$, dado θ , c.i.i.d. $Ber(\theta)$
- (i) Informação sobre θ contida (revelada) na amostra (observação amostral) $x \in \mathcal{X}$ expressa por

$$\mathbb{P}(X = x|\theta)$$

Introdução

- No exemplo 1 (segunda aula), $\Theta = \{1, 2, 3, \dots\}$ e $X|\theta \sim U(\{1, \dots, \theta\})$.
- No exemplo 2 (segunda aula), $\Theta = [0, 1]$ e $X = (X_1, \dots, X_n)$, dado θ , c.i.i.d. $Ber(\theta)$
- (i) Informação sobre θ contida (revelada) na amostra (observação amostral) $x \in \mathcal{X}$ expressa por

$$\mathbb{P}(X = x|\theta)$$

Introdução

- No exemplo 1 (segunda aula), $\Theta = \{1, 2, 3, \dots\}$ e $X|\theta \sim U(\{1, \dots, \theta\})$.
- No exemplo 2 (segunda aula), $\Theta = [0, 1]$ e $X = (X_1, \dots, X_n)$, dado θ , c.i.i.d. $Ber(\theta)$
- (i) Informação sobre θ contida (revelada) na amostra (observação amostral) $x \in \mathcal{X}$ expressa por

$$\mathbb{P}(X = x|\theta)$$

Introdução

- No exemplo 1 (segunda aula), $\Theta = \{1, 2, 3, \dots\}$ e $X|\theta \sim U(\{1, \dots, \theta\})$.
- No exemplo 2 (segunda aula), $\Theta = [0, 1]$ e $X = (X_1, \dots, X_n)$, dado θ , c.i.i.d. $Ber(\theta)$
- (i) Informação sobre θ contida (revelada) na amostra (observação amostral) $x \in \mathcal{X}$ expressa por

$$\mathbb{P}(X = x|\theta)$$

Introdução

- $\mathbb{P}(X = x|\theta)$
- Fixado $\theta \in \Theta$, $\mathbb{P}(X = \cdot|\theta)$ é distribuição de probabilidade para a amostra;
- Fixado $x \in \mathcal{X}$, $\mathbb{P}(X = x|\cdot)$ é função não-negativa definida em Θ : **função de verossimilhança para θ gerada por $x \in \mathcal{X}$.**

Introdução

- $\mathbb{P}(X = x|\theta)$
- Fixado $\theta \in \Theta$, $\mathbb{P}(X = \cdot|\theta)$ é distribuição de probabilidade para a amostra;
- Fixado $x \in \mathcal{X}$, $\mathbb{P}(X = x|\cdot)$ é função não-negativa definida em Θ : **função de verossimilhança para θ gerada por $x \in \mathcal{X}$.**

Introdução

- $\mathbb{P}(X = x|\theta)$
- Fixado $\theta \in \Theta$, $\mathbb{P}(X = \cdot|\theta)$ é distribuição de probabilidade para a amostra;
- Fixado $x \in \mathcal{X}$, $\mathbb{P}(X = x|\cdot)$ é função não-negativa definida em Θ : **função de verossimilhança para θ gerada por $x \in \mathcal{X}$.**

Introdução

- $\mathbb{P}(X = x|\theta)$
- Fixado $\theta \in \Theta$, $\mathbb{P}(X = \cdot|\theta)$ é distribuição de probabilidade para a amostra;
- Fixado $x \in \mathcal{X}$, $\mathbb{P}(X = x|\cdot)$ é função não-negativa definida em Θ : **função de verossimilhança para θ gerada por $x \in \mathcal{X}$.**

Introdução

- Uma estatística $T : \mathcal{X} \rightarrow \mathcal{T}$ é suficiente para θ se preserva toda informação relevante da amostra sobre θ . Nesse caso, podemos esperar que
- $$\mathbb{P}(X = x|\theta) = u(x).v(T(x), \theta) \quad , \quad \theta \in \Theta, \quad x \in \mathcal{X}$$
- **(Definição Clássica)** Uma estatística $T : \mathcal{X} \rightarrow \mathcal{T}$ é suficiente para θ se para todo valor possível t da estatística T , a distribuição condicional de X dado $T(X) = t$ e θ , não depende de θ .
- Em geral, é (parece ser) desejável que a inferência sobre θ dependa de x através (apenas) de $T(x)$.

Introdução

- Uma estatística $T : \mathcal{X} \rightarrow \mathcal{T}$ é suficiente para θ se preserva toda informação relevante da amostra sobre θ . Nesse caso, podemos esperar que
- $\mathbb{P}(X = x|\theta) = u(x).v(T(x), \theta) \text{ , } \theta \in \Theta, \text{ } x \in \mathcal{X}$
- **(Definição Clássica)** Uma estatística $T : \mathcal{X} \rightarrow \mathcal{T}$ é suficiente para θ se para todo valor possível t da estatística T , a distribuição condicional de X dado $T(X) = t$ e θ , não depende de θ .
- Em geral, é (parece ser) desejável que a inferência sobre θ dependa de x através (apenas) de $T(x)$.

Introdução

- Uma estatística $T : \mathcal{X} \rightarrow \mathcal{T}$ é suficiente para θ se preserva toda informação relevante da amostra sobre θ . Nesse caso, podemos esperar que
- $\mathbb{P}(X = x|\theta) = u(x).v(T(x), \theta) \text{ , } \theta \in \Theta, x \in \mathcal{X}$
- **(Definição Clássica)** Uma estatística $T : \mathcal{X} \rightarrow \mathcal{T}$ é suficiente para θ se para todo valor possível t da estatística T , a distribuição condicional de X dado $T(X) = t$ e θ , não depende de θ .
- Em geral, é (parece ser) desejável que a inferência sobre θ dependa de x através (apenas) de $T(x)$.

Introdução

- Uma estatística $T : \mathcal{X} \rightarrow \mathcal{T}$ é suficiente para θ se preserva toda informação relevante da amostra sobre θ . Nesse caso, podemos esperar que
- $$\mathbb{P}(X = x|\theta) = u(x).v(T(x), \theta) \quad , \quad \theta \in \Theta, \quad x \in \mathcal{X}$$
- **(Definição Clássica)** Uma estatística $T : \mathcal{X} \rightarrow \mathcal{T}$ é suficiente para θ se para todo valor possível t da estatística T , a distribuição condicional de X dado $T(X) = t$ e θ , não depende de θ .
- Em geral, é (parece ser) desejável que a inferência sobre θ dependa de x através (apenas) de $T(x)$.

Introdução

- Uma estatística $T : \mathcal{X} \rightarrow \mathcal{T}$ é suficiente para θ se preserva toda informação relevante da amostra sobre θ . Nesse caso, podemos esperar que
- $$\mathbb{P}(X = x|\theta) = u(x).v(T(x), \theta) \quad , \quad \theta \in \Theta, \quad x \in \mathcal{X}$$
- **(Definição Clássica)** Uma estatística $T : \mathcal{X} \rightarrow \mathcal{T}$ é suficiente para θ se para todo valor possível t da estatística T , a distribuição condicional de X dado $T(X) = t$ e θ , não depende de θ .
- Em geral, é (parece ser) desejável que a inferência sobre θ dependa de x através (apenas) de $T(x)$.

Abordagem Clássica

- (ii) Questões (problemas) comumente abordados sob a perspectiva clássica (frequentista): Estimação (pontual e intervalar) e teste de hipóteses.
- Para o problema de estimação, fazemos uso de estatísticas "particulares": estimadores.
- Estimador: $\delta : \mathcal{X} \rightarrow \Theta$
- Procedimento de estimação baseado em estimadores não-viesados.

Abordagem Clássica

- (ii) Questões (problemas) comumente abordados sob a perspectiva clássica (frequentista): Estimação (pontual e intervalar) e teste de hipóteses.
- Para o problema de estimação, fazemos uso de estatísticas "particulares": estimadores.
- Estimador: $\delta : \mathcal{X} \rightarrow \Theta$
- Procedimento de estimação baseado em estimadores não-viesados.

Abordagem Clássica

- (ii) Questões (problemas) comumente abordados sob a perspectiva clássica (frequentista): Estimação (pontual e intervalar) e teste de hipóteses.
- Para o problema de estimação, fazemos uso de estatísticas "particulares": estimadores.
- Estimador: $\delta : \mathcal{X} \rightarrow \Theta$
- Procedimento de estimação baseado em estimadores não-viesados.

Abordagem Clássica

- (ii) Questões (problemas) comumente abordados sob a perspectiva clássica (frequentista): Estimação (pontual e intervalar) e teste de hipóteses.
- Para o problema de estimação, fazemos uso de estatísticas "particulares": estimadores.
- Estimador: $\delta : \mathcal{X} \rightarrow \Theta$
- Procedimento de estimação baseado em estimadores não-viesados.

Abordagem Clássica

- (ii) Questões (problemas) comumente abordados sob a perspectiva clássica (frequentista): Estimação (pontual e intervalar) e teste de hipóteses.
- Para o problema de estimação, fazemos uso de estatísticas "particulares": estimadores.
- Estimador: $\delta : \mathcal{X} \rightarrow \Theta$
- Procedimento de estimação baseado em estimadores não-viesados.

Estimação

- $\delta : \mathcal{X} \rightarrow \Theta$ é não-viesado para θ ($g(\theta)$) se, $\forall \theta \in \Theta$, $\mathbb{E}(\delta(X)|\theta) = g(\theta)$, isto é,
- $\mathbb{E}(\delta(X)|\theta) = \sum_{x \in \mathcal{X}} \delta(x) \mathbb{P}(X = x|\theta) = g(\theta)$, $\forall \theta \in \Theta$. (caso discreto)
- $\mathbb{E}(\delta(X)|\theta) = \int_{\mathcal{X}} \delta(x) f(x|\theta) d\theta = g(\theta)$, $\forall \theta \in \Theta$. (caso contínuo)
- No exemplo 2, considere, $n > 2$. Para qualquer $i = 1, \dots, n$, $\delta_i(X) = X_i$ é não-viesado para θ , do mesmo modo que $\delta'(X) = \frac{X_1 + X_2}{2}$ e $\delta^* = \frac{X_1 + \dots + X_n}{n} = \bar{X}$. Nesse caso, δ^* é melhor que qualquer outro (não-viesado).

Estimação

- $\delta : \mathcal{X} \rightarrow \Theta$ é não-viesado para θ ($g(\theta)$) se, $\forall \theta \in \Theta$, $\mathbb{E}(\delta(X)|\theta) = g(\theta)$, isto é,
- $\mathbb{E}(\delta(X)|\theta) = \sum_{x \in \mathcal{X}} \delta(x) \mathbb{P}(X = x|\theta) = g(\theta)$, $\forall \theta \in \Theta$. (caso discreto)
- $\mathbb{E}(\delta(X)|\theta) = \int_{\mathcal{X}} \delta(x) f(x|\theta) d\theta = g(\theta)$, $\forall \theta \in \Theta$. (caso contínuo)
- No exemplo 2, considere, $n > 2$. Para qualquer $i = 1, \dots, n$, $\delta_i(X) = X_i$ é não-viesado para θ , do mesmo modo que $\delta'(X) = \frac{X_1 + X_2}{2}$ e $\delta^* = \frac{X_1 + \dots + X_n}{n} = \bar{X}$. Nesse caso, δ^* é melhor que qualquer outro (não-viesado).

Estimação

- $\delta : \mathcal{X} \rightarrow \Theta$ é não-viesado para θ ($g(\theta)$) se, $\forall \theta \in \Theta$, $\mathbb{E}(\delta(X)|\theta) = g(\theta)$, isto é,
- $\mathbb{E}(\delta(X)|\theta) = \sum_{x \in \mathcal{X}} \delta(x) \mathbb{P}(X = x|\theta) = g(\theta)$, $\forall \theta \in \Theta$. (caso discreto)
- $\mathbb{E}(\delta(X)|\theta) = \int_{\mathcal{X}} \delta(x) f(x|\theta) d\theta = g(\theta)$, $\forall \theta \in \Theta$. (caso contínuo)
- No exemplo 2, considere, $n > 2$. Para qualquer $i = 1, \dots, n$, $\delta_i(X) = X_i$ é não-viesado para θ , do mesmo modo que $\delta'(X) = \frac{X_1 + X_2}{2}$ e $\delta^* = \frac{X_1 + \dots + X_n}{n} = \bar{X}$. Nesse caso, δ^* é melhor que qualquer outro (não-viesado).

Estimação

- $\delta : \mathcal{X} \rightarrow \Theta$ é não-viesado para θ ($g(\theta)$) se, $\forall \theta \in \Theta$, $\mathbb{E}(\delta(X)|\theta) = g(\theta)$, isto é,
- $\mathbb{E}(\delta(X)|\theta) = \sum_{x \in \mathcal{X}} \delta(x) \mathbb{P}(X = x|\theta) = g(\theta)$, $\forall \theta \in \Theta$. (caso discreto)
- $\mathbb{E}(\delta(X)|\theta) = \int_{\mathcal{X}} \delta(x) f(x|\theta) d\theta = g(\theta)$, $\forall \theta \in \Theta$. (caso contínuo)
- No exemplo 2, considere, $n > 2$. Para qualquer $i = 1, \dots, n$, $\delta_i(X) = X_i$ é não-viesado para θ , do mesmo modo que $\delta'(X) = \frac{X_1 + X_2}{2}$ e $\delta^* = \frac{X_1 + \dots + X_n}{n} = \bar{X}$. Nesse caso, δ^* é melhor que qualquer outro (não-viesado).

Estimação

- $\delta : \mathcal{X} \rightarrow \Theta$ é não-viesado para θ ($g(\theta)$) se, $\forall \theta \in \Theta$, $\mathbb{E}(\delta(X)|\theta) = g(\theta)$, isto é,
- $\mathbb{E}(\delta(X)|\theta) = \sum_{x \in \mathcal{X}} \delta(x) \mathbb{P}(X = x|\theta) = g(\theta)$, $\forall \theta \in \Theta$. (caso discreto)
- $\mathbb{E}(\delta(X)|\theta) = \int_{\mathcal{X}} \delta(x) f(x|\theta) d\theta = g(\theta)$, $\forall \theta \in \Theta$. (caso contínuo)
- No exemplo 2, considere, $n > 2$. Para qualquer $i = 1, \dots, n$, $\delta_i(X) = X_i$ é não-viesado para θ , do mesmo modo que $\delta'(X) = \frac{X_1 + X_2}{2}$ e $\delta^* = \frac{X_1 + \dots + X_n}{n} = \bar{X}$. Nesse caso, δ^* é melhor que qualquer outro (não-viesado).

Estimação

- Para $g(\theta) = \theta^2$, $\delta^{(1,2)}(X) = X_1 \cdot X_2$ é não-viesado para $g(\theta)$, do mesmo modo que $\delta^{(i,j)}(X) = X_i \cdot X_j$, $i \neq j$. Qual é o melhor nesse caso?
- Pode-se mostrar que $\delta^{**}(X) = \frac{(\sum_{i=1}^n X_i)(\sum_{i=1}^n X_i - 1)}{n(n-1)}$, que é função da estatística suficiente $\sum_{i=1}^n X_i$, é o "melhor" estimador não-viesado para θ^2 .
- Sob certas condições, pode-se obter o melhor estimador não-viesado para $g(\theta)$ tomando-se um estimador não-viesado qualquer para $g(\theta)$ e condicionando tal estimador a um estatística suficiente (e completa) para θ (RAO-BLACKWELLIZAÇÃO).

Estimação

- Para $g(\theta) = \theta^2$, $\delta^{(1,2)}(X) = X_1 \cdot X_2$ é não-viesado para $g(\theta)$, do mesmo modo que $\delta^{(i,j)}(X) = X_i \cdot X_j$, $i \neq j$. Qual é o melhor nesse caso?
- Pode-se mostrar que $\delta^{**}(X) = \frac{(\sum_{i=1}^n X_i)(\sum_{i=1}^n X_i - 1)}{n(n-1)}$, que é função da estatística suficiente $\sum_{i=1}^n X_i$, é o "melhor" estimador não-viesado para θ^2 .
- Sob certas condições, pode-se obter o melhor estimador não-viesado para $g(\theta)$ tomando-se um estimador não-viesado qualquer para $g(\theta)$ e condicionando tal estimador a um estatística suficiente (e completa) para θ (RAO-BLACKWELLIZAÇÃO).

Estimação

- Para $g(\theta) = \theta^2$, $\delta^{(1,2)}(X) = X_1 \cdot X_2$ é não-viesado para $g(\theta)$, do mesmo modo que $\delta^{(i,j)}(X) = X_i \cdot X_j$, $i \neq j$. Qual é o melhor nesse caso?
- Pode-se mostrar que $\delta^{**}(X) = \frac{(\sum_{i=1}^n X_i)(\sum_{i=1}^n X_i - 1)}{n(n-1)}$, que é função da estatística suficiente $\sum_{i=1}^n X_i$, é o "melhor" estimador não-viesado para θ^2 .
- Sob certas condições, pode-se obter o melhor estimador não-viesado para $g(\theta)$ tomando-se um estimador não-viesado qualquer para $g(\theta)$ e condicionando tal estimador a um estatística suficiente (e completa) para θ (RAO-BLACKWELLIZAÇÃO).

Estimação

- Para $g(\theta) = \theta^2$, $\delta^{(1,2)}(X) = X_1 \cdot X_2$ é não-viesado para $g(\theta)$, do mesmo modo que $\delta^{(i,j)}(X) = X_i \cdot X_j$, $i \neq j$. Qual é o melhor nesse caso?
- Pode-se mostrar que $\delta^{**}(X) = \frac{(\sum_{i=1}^n X_i)(\sum_{i=1}^n X_i - 1)}{n(n-1)}$, que é função da estatística suficiente $\sum_{i=1}^n X_i$, é o "melhor" estimador não-viesado para θ^2 .
- Sob certas condições, pode-se obter o melhor estimador não-viesado para $g(\theta)$ tomando-se um estimador não-viesado qualquer para $g(\theta)$ e condicionando tal estimador a um estatística suficiente (e completa) para θ (RAO-BLACKWELLIZAÇÃO).

Estimação

- No exemplo acima, $\delta^{(1,2)}(X) = X_1 \cdot X_2$ é não-viesado para θ^2 . Com efeito,
$$\mathbb{E}(\delta^{(1,2)}(X)|\theta) = \mathbb{E}(X_1 X_2 | \theta) = \mathbb{E}(X_1 | \theta) \mathbb{E}(X_2 | \theta) = \theta^2, \\ \forall \theta \in \Theta.$$
- Além disso, $T(X) = \sum_{i=1}^n X_i$ é suficiente para θ :
$$\mathbb{P}(X_1 = x_1, \dots, X_n = x_n | \theta) = \prod_{i=1}^n \mathbb{P}(X_i = x_i | \theta) = \\ \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i}$$
- Assim, podemos Rao-Blackwellizar $\delta^{(1,2)}$, obtendo
- $\delta^{**}(X) = \mathbb{E}(\delta^{(1,2)} | T(X))$.

Estimação

- No exemplo acima, $\delta^{(1,2)}(X) = X_1 \cdot X_2$ é não-viesado para θ^2 . Com efeito,
$$\mathbb{E}(\delta^{(1,2)}(X)|\theta) = \mathbb{E}(X_1 X_2|\theta) = \mathbb{E}(X_1|\theta)\mathbb{E}(X_2|\theta) = \theta^2, \\ \forall \theta \in \Theta.$$
- Além disso, $T(X) = \sum_{i=1}^n X_i$ é suficiente para θ :
$$\mathbb{P}(X_1 = x_1, \dots, X_n = x_n|\theta) = \prod_{i=1}^n \mathbb{P}(X_i = x_i|\theta) = \\ \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i}$$
- Assim, podemos Rao-Blackwellizar $\delta^{(1,2)}$, obtendo
- $\delta^{**}(X) = \mathbb{E}(\delta^{(1,2)}|T(X))$.

Estimação

- No exemplo acima, $\delta^{(1,2)}(X) = X_1 \cdot X_2$ é não-viesado para θ^2 . Com efeito,

$$\mathbb{E}(\delta^{(1,2)}(X)|\theta) = \mathbb{E}(X_1 X_2|\theta) = \mathbb{E}(X_1|\theta)\mathbb{E}(X_2|\theta) = \theta^2 ,$$

$$\forall \theta \in \Theta.$$

- Além disso, $T(X) = \sum_{i=1}^n X_i$ é suficiente para θ :

$$\begin{aligned} \mathbb{P}(X_1 = x_1, \dots, X_n = x_n|\theta) &= \prod_{i=1}^n \mathbb{P}(X_i = x_i|\theta) = \\ &= \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} \end{aligned}$$

- Assim, podemos Rao-Blackwellizar $\delta^{(1,2)}$, obtendo
- $\delta^{**}(X) = \mathbb{E}(\delta^{(1,2)}|T(X))$.

Estimação

- No exemplo acima, $\delta^{(1,2)}(X) = X_1 \cdot X_2$ é não-viesado para θ^2 . Com efeito,

$$\mathbb{E}(\delta^{(1,2)}(X)|\theta) = \mathbb{E}(X_1 X_2|\theta) = \mathbb{E}(X_1|\theta)\mathbb{E}(X_2|\theta) = \theta^2 ,$$

$$\forall \theta \in \Theta.$$

- Além disso, $T(X) = \sum_{i=1}^n X_i$ é suficiente para θ :

$$\begin{aligned} \mathbb{P}(X_1 = x_1, \dots, X_n = x_n|\theta) &= \prod_{i=1}^n \mathbb{P}(X_i = x_i|\theta) = \\ &= \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} \end{aligned}$$

- Assim, podemos Rao-Blackwellizar $\delta^{(1,2)}$, obtendo
- $\delta^{**}(X) = \mathbb{E}(\delta^{(1,2)}|T(X))$.

Estimação

- No exemplo acima, $\delta^{(1,2)}(X) = X_1 \cdot X_2$ é não-viesado para θ^2 . Com efeito,
$$\mathbb{E}(\delta^{(1,2)}(X)|\theta) = \mathbb{E}(X_1 X_2|\theta) = \mathbb{E}(X_1|\theta)\mathbb{E}(X_2|\theta) = \theta^2, \\ \forall \theta \in \Theta.$$
- Além disso, $T(X) = \sum_{i=1}^n X_i$ é suficiente para θ :
$$\mathbb{P}(X_1 = x_1, \dots, X_n = x_n|\theta) = \prod_{i=1}^n \mathbb{P}(X_i = x_i|\theta) = \\ \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i}$$
- Assim, podemos Rao-Blackwellizar $\delta^{(1,2)}$, obtendo
- $\delta^{**}(X) = \mathbb{E}(\delta^{(1,2)}|T(X))$.

Estimação

- Para $t \in \{0, 1, \dots, n\}$, temos:

- $$\mathbb{E}(\delta^{(1,2)}(X)|T(X)) = t, \theta) = \mathbb{E}(X_1 X_2 | \sum_{i=1}^n X_i = t, \theta) =$$

$$\mathbb{P}(X_1 X_2 = 1 | \sum_{i=1}^n X_i = t, \theta) =$$

$$\mathbb{P}(X_1 = X_2 = 1 | \sum_{i=1}^n X_i = t, \theta) =$$

$$\frac{\mathbb{P}(X_1=X_2=1, \sum_{i=1}^n X_i=t|\theta)}{\mathbb{P}(\sum_{i=1}^n X_i=t|\theta)} = \frac{\mathbb{P}(X_1=X_2=1, \sum_{i=3}^n X_i = t-2|\theta)}{\mathbb{P}(\sum_{i=1}^n X_i = t|\theta)} =$$

$$\frac{\theta \theta C_{t-2}^{n-2} \theta^{t-2} (1-\theta)^{n-t}}{C_t^n \theta^t (1-\theta)^{n-t}} = \frac{t(t-1)}{n(n-1)}. \text{ Assim,}$$

- $$\delta^{**}(X) = \mathbb{E}(\delta^{(1,2)}(X)|T(X)) = \frac{(\sum_{i=1}^n X_i) (\sum_{i=1}^n X_i - 1)}{n(n-1)}$$

Estimação

- Para $t \in \{0, 1, \dots, n\}$, temos:

$$\bullet \mathbb{E}(\delta^{(1,2)})(X)|T(X)) = t, \theta) = \mathbb{E}(X_1 X_2 | \sum_{i=1}^n X_i = t, \theta) = \\ \mathbb{P}(X_1 X_2 = 1 | \sum_{i=1}^n X_i = t, \theta) =$$

$$\mathbb{P}(X_1 = X_2 = 1 | \sum_{i=1}^n X_i = t, \theta) =$$

$$\frac{\mathbb{P}(X_1=X_2=1, \sum_{i=1}^n X_i=t|\theta)}{\mathbb{P}(\sum_{i=1}^n X_i=t|\theta)} = \frac{\mathbb{P}(X_1=X_2=1, \sum_{i=3}^n X_i = t-2|\theta)}{\mathbb{P}(\sum_{i=1}^n X_i = t|\theta)} =$$

$$\frac{\theta \theta C_{t-2}^{n-2} \theta^{t-2} (1-\theta)^{n-t}}{C_t^n \theta^t (1-\theta)^{n-t}} = \frac{t(t-1)}{n(n-1)}. \text{ Assim,}$$

$$\bullet \delta^{**}(X) = \mathbb{E}(\delta^{(1,2)}(X)|T(X)) = \frac{(\sum_{i=1}^n X_i) (\sum_{i=1}^n X_i - 1)}{n(n-1)}$$

Estimação

- Para $t \in \{0, 1, \dots, n\}$, temos:

- $\mathbb{E}(\delta^{(1,2)}(X)|T(X)) = t, \theta) = \mathbb{E}(X_1 X_2 | \sum_{i=1}^n X_i = t, \theta) =$
 $\mathbb{P}(X_1 X_2 = 1 | \sum_{i=1}^n X_i = t, \theta) =$

$$\mathbb{P}(X_1 = X_2 = 1 | \sum_{i=1}^n X_i = t, \theta) =$$

$$\frac{\mathbb{P}(X_1=X_2=1, \sum_{i=1}^n X_i=t|\theta)}{\mathbb{P}(\sum_{i=1}^n X_i=t|\theta)} = \frac{\mathbb{P}(X_1=X_2=1, \sum_{i=3}^n X_i = t-2|\theta)}{\mathbb{P}(\sum_{i=1}^n X_i = t|\theta)} =$$

$$\frac{\theta \theta C_{t-2}^{n-2} \theta^{t-2} (1-\theta)^{n-t}}{C_t^n \theta^t (1-\theta)^{n-t}} = \frac{t(t-1)}{n(n-1)}. \text{ Assim,}$$

- $\delta^{**}(X) = \mathbb{E}(\delta^{(1,2)}(X)|T(X)) = \frac{(\sum_{i=1}^n X_i)(\sum_{i=1}^n X_i - 1)}{n(n-1)}$

Estimação

- Para $t \in \{0, 1, \dots, n\}$, temos:

- $\mathbb{E}(\delta^{(1,2)})(X)|T(X)) = t, \theta) = \mathbb{E}(X_1 X_2 | \sum_{i=1}^n X_i = t, \theta) =$
 $\mathbb{P}(X_1 X_2 = 1 | \sum_{i=1}^n X_i = t, \theta) =$

$$\mathbb{P}(X_1 = X_2 = 1 | \sum_{i=1}^n X_i = t, \theta) =$$

$$\frac{\mathbb{P}(X_1=X_2=1, \sum_{i=1}^n X_i=t|\theta)}{\mathbb{P}(\sum_{i=1}^n X_i=t|\theta)} = \frac{\mathbb{P}(X_1=X_2=1, \sum_{i=3}^n X_i = t-2|\theta)}{\mathbb{P}(\sum_{i=1}^n X_i = t|\theta)} =$$

$$\frac{\theta \theta C_{t-2}^{n-2} \theta^{t-2} (1-\theta)^{n-t}}{C_t^n \theta^t (1-\theta)^{n-t}} = \frac{t(t-1)}{n(n-1)}. \text{ Assim,}$$

- $\delta^{**}(X) = \mathbb{E}(\delta^{(1,2)}(X)|T(X)) = \frac{(\sum_{i=1}^n X_i) (\sum_{i=1}^n X_i - 1)}{n(n-1)}$

Estimação

- $\delta^{**}(X)$ satisfaz: (Teorema de Rao-Blackwell)
- $\mathbb{E}(\delta^{**}(X)|\theta) = \theta$, $\forall \theta \in \Theta$ e
- $Var(\delta^{**}(X)|\theta) \leq Var(\delta^{(1,2)}(X)|\theta)$, $\forall \theta \in \Theta$.
- Esse procedimento (Rao-Blackwellização) pode ser adotado para um estimadores não-viesados sob condições relativamente gerais.
- Há outras alternativas de estimadores para θ ($g(\theta)$): por exemplo, estimador de máxima verossimilhança.

Estimação

- $\delta^{**}(X)$ satisfaz: (Teorema de Rao-Blackwell)
- $\mathbb{E}(\delta^{**}(X)|\theta) = \theta$, $\forall \theta \in \Theta$ e
- $Var(\delta^{**}(X)|\theta) \leq Var(\delta^{(1,2)}(X)|\theta)$, $\forall \theta \in \Theta$.
- Esse procedimento (Rao-Blackwellização) pode ser adotado para um estimadores não-viesados sob condições relativamente gerais.
- Há outras alternativas de estimadores para θ ($g(\theta)$): por exemplo, estimador de máxima verossimilhança.

Estimação

- $\delta^{**}(X)$ satisfaz: (Teorema de Rao-Blackwell)
- $\mathbb{E}(\delta^{**}(X)|\theta) = \theta$, $\forall \theta \in \Theta$ e
- $Var(\delta^{**}(X)|\theta) \leq Var(\delta^{(1,2)}(X)|\theta)$, $\forall \theta \in \Theta$.
- Esse procedimento (Rao-Blackwellização) pode ser adotado para um estimadores não-viesados sob condições relativamente gerais.
- Há outras alternativas de estimadores para θ ($g(\theta)$): por exemplo, estimador de máxima verossimilhança.

Estimação

- $\delta^{**}(X)$ satisfaz: (Teorema de Rao-Blackwell)
- $\mathbb{E}(\delta^{**}(X)|\theta) = \theta$, $\forall \theta \in \Theta$ e
- $Var(\delta^{**}(X)|\theta) \leq Var(\delta^{(1,2)}(X)|\theta)$, $\forall \theta \in \Theta$.
- Esse procedimento (Rao-Blackwellização) pode ser adotado para um estimadores não-viesados sob condições relativamente gerais.
- Há outras alternativas de estimadores para θ ($g(\theta)$): por exemplo, estimador de máxima verossimilhança.

Estimação

- $\delta^{**}(X)$ satisfaz: (Teorema de Rao-Blackwell)
- $\mathbb{E}(\delta^{**}(X)|\theta) = \theta$, $\forall \theta \in \Theta$ e
- $Var(\delta^{**}(X)|\theta) \leq Var(\delta^{(1,2)}(X)|\theta)$, $\forall \theta \in \Theta$.
- Esse procedimento (Rao-Blackwellização) pode ser adotado para um estimadores não-viesados sob condições relativamente gerais.
- Há outras alternativas de estimadores para θ ($g(\theta)$): por exemplo, estimador de máxima verossimilhança.

Estimação

- $\delta^{**}(X)$ satisfaz: (Teorema de Rao-Blackwell)
- $\mathbb{E}(\delta^{**}(X)|\theta) = \theta$, $\forall \theta \in \Theta$ e
- $Var(\delta^{**}(X)|\theta) \leq Var(\delta^{(1,2)}(X)|\theta)$, $\forall \theta \in \Theta$.
- Esse procedimento (Rao-Blackwellização) pode ser adotado para um estimadores não-viesados sob condições relativamente gerais.
- Há outras alternativas de estimadores para θ ($g(\theta)$): por exemplo, estimador de máxima verossimilhança.