

Inferência Estatística Comparada

AULA 8 - INFERÊNCIA BAYESIANA

Introdução

- Abordagem à Inferência Estatística baseada na interpretação subjetiva de probabilidade.

- Ideia fundamental:

PROBABILIDADE como medida, representação numérica de **INCERTEZA**.

- Sob essa ideia, uma (medida de) probabilidade é **a** representação de incerteza de **um indivíduo** ("Your probabilities"); é a representação numérica que decorre, sob certas condições, da avaliação do indivíduo sobre eventos desconhecidos.
- Construção de probabilidade subjetiva: impõe que para quantidades/eventos desconhecidos (onde há incerteza), devemos fazer uso de probabilidades para quantificar, representar incerteza.

Introdução

- Abordagem à Inferência Estatística baseada na interpretação subjetiva de probabilidade.

- Ideia fundamental:

PROBABILIDADE como medida, representação numérica de **INCERTEZA**.

- Sob essa ideia, uma (medida de) probabilidade é a representação de incerteza de **um indivíduo** ("Your probabilities"); é a representação numérica que decorre, sob certas condições, da avaliação do indivíduo sobre eventos desconhecidos.
- Construção de probabilidade subjetiva: impõe que para quantidades/eventos desconhecidos (onde há incerteza), devemos fazer uso de probabilidades para quantificar, representar incerteza.

Introdução

- Abordagem à Inferência Estatística baseada na interpretação subjetiva de probabilidade.
- Ideia fundamental:

PROBABILIDADE como medida, representação numérica de **INCERTEZA**.

- Sob essa ideia, uma (medida de) probabilidade é a representação de incerteza de **um indivíduo** ("Your probabilities"); é a representação numérica que decorre, sob certas condições, da avaliação do indivíduo sobre eventos desconhecidos.
- Construção de probabilidade subjetiva: impõe que para quantidades/eventos desconhecidos (onde há incerteza), devemos fazer uso de probabilidades para quantificar, representar incerteza.

Introdução

- Abordagem à Inferência Estatística baseada na interpretação subjetiva de probabilidade.
- Ideia fundamental:

PROBABILIDADE como medida, representação numérica de **INCERTEZA**.

- Sob essa ideia, uma (medida de) probabilidade é **a** representação de incerteza de **um indivíduo** ("Your probabilities"); é a representação numérica que decorre, sob certas condições, da avaliação do indivíduo sobre eventos desconhecidos.
- Construção de probabilidade subjetiva: impõe que para quantidades/eventos desconhecidos (onde há incerteza), devemos fazer uso de probabilidades para quantificar, representar incerteza.

Introdução

- Abordagem à Inferência Estatística baseada na interpretação subjetiva de probabilidade.
- Ideia fundamental:

PROBABILIDADE como medida, representação numérica de **INCERTEZA**.

- Sob essa ideia, uma (medida de) probabilidade é **a** representação de incerteza de **um indivíduo** ("Your probabilities"); é a representação numérica que decorre, sob certas condições, da avaliação do indivíduo sobre eventos desconhecidos.
- Construção de probabilidade subjetiva: impõe que para quantidades/eventos desconhecidos (onde há incerteza), devemos fazer uso de probabilidades para quantificar, representar incerteza.

Construção de probabilidade subjetiva

- Breve resumo:

A partir da especificação de uma relação de "crença" entre "eventos", \preceq , que atenda certos requisitos, assegura-se a existência de uma (única) medida de probabilidade que "representa", "coincide" com a relação de crença \preceq .

- Suposições: (M. H. DeGroot (1970))

- (Ω, \mathcal{F}) , onde $\Omega \neq \emptyset$ e \mathcal{F} é sigma-álgebra de subconjuntos de Ω .

- Supõe-se que um indivíduo especifica $\preceq \subset \mathcal{F}^2$ com a seguinte interpretação:

$(A, B) \in \preceq$ (ou $A \preceq B$) se "ele não acredita mais em A do que em B " ("acredita em B ao menos como acredita em A ").

Construção de probabilidade subjetiva

- Breve resumo:

A partir da especificação de uma relação de "crença" entre "eventos", \preceq , que atenda certos requisitos, assegura-se a existência de uma (única) medida de probabilidade que "representa", "coincide" com a relação de crença \preceq .

- Suposições: (M. H. DeGroot (1970))

- (Ω, \mathcal{F}) , onde $\Omega \neq \emptyset$ e \mathcal{F} é sigma-álgebra de subconjuntos de Ω .

- Supõe-se que um indivíduo especifica $\preceq \subset \mathcal{F}^2$ com a seguinte interpretação:

$(A, B) \in \preceq$ (ou $A \preceq B$) se "ele não acredita mais em A do que em B " ("acredita em B ao menos como acredita em A ").

Construção de probabilidade subjetiva

- Breve resumo:

A partir da especificação de uma relação de "crença" entre "eventos", \preceq , que atenda certos requisitos, assegura-se a existência de uma (única) medida de probabilidade que "representa", "coincide" com a relação de crença \preceq .

- Suposições: (M. H. DeGroot (1970))

- (Ω, \mathcal{F}) , onde $\Omega \neq \emptyset$ e \mathcal{F} é sigma-álgebra de subconjuntos de Ω .
- Supõe-se que um indivíduo especifica $\preceq \subset \mathcal{F}^2$ com a seguinte interpretação:

$(A, B) \in \preceq$ (ou $A \preceq B$) se "ele não acredita mais em A do que em B " ("acredita em B ao menos como acredita em A ").

Construção de probabilidade subjetiva

- Breve resumo:

A partir da especificação de uma relação de "crença" entre "eventos", \preceq , que atenda certos requisitos, assegura-se a existência de uma (única) medida de probabilidade que "representa", "coincide" com a relação de crença \preceq .

- Suposições: (M. H. DeGroot (1970))

- (Ω, \mathcal{F}) , onde $\Omega \neq \emptyset$ e \mathcal{F} é sigma-álgebra de subconjuntos de Ω .

- Supõe-se que um indivíduo especifica $\preceq \subset \mathcal{F}^2$ com a seguinte interpretação:

$(A, B) \in \preceq$ (ou $A \preceq B$) se "ele não acredita mais em A do que em B " ("acredita em B ao menos como acredita em A ").

Construção de probabilidade subjetiva

- Breve resumo:

A partir da especificação de uma relação de "crença" entre "eventos", \preceq , que atenda certos requisitos, assegura-se a existência de uma (única) medida de probabilidade que "representa", "coincide" com a relação de crença \preceq .

- Suposições: (M. H. DeGroot (1970))
- (Ω, \mathcal{F}) , onde $\Omega \neq \emptyset$ e \mathcal{F} é sigma-álgebra de subconjuntos de Ω .
- Supõe-se que um indivíduo especifica $\preceq \subset \mathcal{F}^2$ com a seguinte interpretação:

$(A, B) \in \preceq$ (ou $A \preceq B$) se "ele não acredita mais em A do que em B " ("acredita em B ao menos como acredita em A ").

Construção de probabilidade subjetiva

- Exemplo (próxima partida entre as equipes X e Y):
 $\Omega = \mathbb{N}^2$ e $\mathcal{F}(\Omega)$. Ω representa o conjunto de possíveis placares do jogo.
- Alguns elementos de \preceq , segundo o indivíduo que contempla o placar do jogo em questão:
- $\{(7, 1)\} \preceq \{(1, 0)\}$
 $\{(0, i)\} \preceq \{(i, 0)\}$, para todo $i \in \mathbb{N}$
 $\{(i, j)\} \preceq \{(j, i)\}$, para $j > i$
 $\{(j + 1, i)\} \preceq \{(j, i)\}$ para $j > i$
 $\{(i, 0) : i \in \mathbb{N}\} \preceq \{(0, i) : i \in \mathbb{N}\}$
 etc..

Construção de probabilidade subjetiva

- Exemplo (próxima partida entre as equipes X e Y):
 $\Omega = \mathbb{N}^2$ e $\mathcal{F}(\Omega)$. Ω representa o conjunto de possíveis placares do jogo.
- Alguns elementos de \preceq , segundo o indivíduo que contempla o placar do jogo em questão:
- $\{(7, 1)\} \preceq \{(1, 0)\}$
 $\{(0, i)\} \preceq \{(i, 0)\}$, para todo $i \in \mathbb{N}$
 $\{(i, j)\} \preceq \{(j, i)\}$, para $j > i$
 $\{(j + 1, i)\} \preceq \{(j, i)\}$ para $j > i$
 $\{(i, 0) : i \in \mathbb{N}\} \preceq \{(0, i) : i \in \mathbb{N}\}$
 etc..

Construção de probabilidade subjetiva

- Exemplo (próxima partida entre as equipes X e Y):
 $\Omega = \mathbb{N}^2$ e $\mathcal{F}(\Omega)$. Ω representa o conjunto de possíveis placares do jogo.
- Alguns elementos de \preceq , segundo o indivíduo que contempla o placar do jogo em questão:
- $\{(7, 1)\} \preceq \{(1, 0)\}$
 $\{(0, i)\} \preceq \{(i, 0)\}$, para todo $i \in \mathbb{N}$
 $\{(i, j)\} \preceq \{(j, i)\}$, para $j > i$
 $\{(j + 1, i)\} \preceq \{(j, i)\}$ para $j > i$
 $\{(i, 0) : i \in \mathbb{N}\} \preceq \{(0, i) : i \in \mathbb{N}\}$
 etc..

Construção de probabilidade subjetiva

- Exemplo (próxima partida entre as equipes X e Y):
 $\Omega = \mathbb{N}^2$ e $\mathcal{F}(\Omega)$. Ω representa o conjunto de possíveis placares do jogo.
- Alguns elementos de \preceq , segundo o indivíduo que contempla o placar do jogo em questão:
- $\{(7, 1)\} \preceq \{(1, 0)\}$
 $\{(0, i)\} \preceq \{(i, 0)\}$, para todo $i \in \mathbb{N}$
 $\{(i, j)\} \preceq \{(j, i)\}$, para $j > i$
 $\{(j + 1, i)\} \preceq \{(j, i)\}$ para $j > i$
 $\{(i, 0) : i \in \mathbb{N}\} \preceq \{(0, i) : i \in \mathbb{N}\}$
 etc..

Construção de probabilidade subjetiva

- Condições sobre \preceq :

C1) Para todo $A, B \in \mathcal{F}$, $A \preceq B$ ou $B \preceq A$

C2) Para $A, B, C \in \mathcal{F}$, $A \preceq B$ e $B \preceq C \Rightarrow A \preceq C$

C3) $\emptyset \preceq A$, $\forall A \in \mathcal{F}$

+ condições adicionais.

- TEOREMA** Considere $\preceq \subset \mathcal{F}^2$. Se \preceq satisfaz as condições de C1 a C3, então

$\exists! \mathbb{P} : \mathcal{F} \rightarrow [0, 1]$ medida de probabilidade tal que para quaisquer $A, B \in \mathcal{F}$,

$$A \preceq B \Leftrightarrow \mathbb{P}(A) \leq \mathbb{P}(B) \quad \mathbb{P} \text{ representa } \preceq$$

Construção de probabilidade subjetiva

- Condições sobre \preceq :

C1) Para todo $A, B \in \mathcal{F}$, $A \preceq B$ ou $B \preceq A$

C2) Para $A, B, C \in \mathcal{F}$, $A \preceq B$ e $B \preceq C \Rightarrow A \preceq C$

C3) $\emptyset \preceq A$, $\forall A \in \mathcal{F}$

+ condições adicionais.

- TEOREMA** Considere $\preceq \subset \mathcal{F}^2$. Se \preceq satisfaz as condições de C1 a C?, então

$\exists! \mathbb{P} : \mathcal{F} \rightarrow [0, 1]$ medida de probabilidade tal que para quaisquer $A, B \in \mathcal{F}$,

$$A \preceq B \Leftrightarrow \mathbb{P}(A) \leq \mathbb{P}(B) \quad \mathbb{P} \text{ representa } \preceq$$

Construção de probabilidade subjetiva

- Condições sobre \preceq :

C1) Para todo $A, B \in \mathcal{F}$, $A \preceq B$ ou $B \preceq A$

C2) Para $A, B, C \in \mathcal{F}$, $A \preceq B$ e $B \preceq C \Rightarrow A \preceq C$

C3) $\emptyset \preceq A$, $\forall A \in \mathcal{F}$

+ condições adicionais.

- TEOREMA** Considere $\preceq \subset \mathcal{F}^2$. Se \preceq satisfaz as condições de C1 a C3, então

$\exists! \mathbb{P} : \mathcal{F} \rightarrow [0, 1]$ medida de probabilidade tal que para quaisquer $A, B \in \mathcal{F}$,

$$A \preceq B \Leftrightarrow \mathbb{P}(A) \leq \mathbb{P}(B) \quad \mathbb{P} \text{ representa } \preceq$$

Construção de probabilidade subjetiva

- Observações:
- A partir do Teorema, o indivíduo "pode" ("deve") fazer uso das regras do cálculo de probabilidades usuais para lidar com SUA incerteza.
- Outras construções de probabilidade subjetiva: DeFinetti, Savage, French, Kadane,...
- Unicidade da representação (unicidade de \mathbb{P})
- Outras representações de incerteza: lógica (conjuntos) "fuzzy" , probabilidades imprecisas, medidas possibilistas, etc..

Construção de probabilidade subjetiva

- Observações:
- A partir do Teorema, o indivíduo "pode" ("deve") fazer uso das regras do cálculo de probabilidades usuais para lidar com SUA incerteza.
- Outras construções de probabilidade subjetiva: DeFinetti, Savage, French, Kadane,...
- Unicidade da representação (unicidade de \mathbb{P})
- Outras representações de incerteza: lógica (conjuntos) "fuzzy" , probabilidades imprecisas, medidas possibilistas, etc..

Construção de probabilidade subjetiva

- Observações:
- A partir do Teorema, o indivíduo "pode" ("deve") fazer uso das regras do cálculo de probabilidades usuais para lidar com SUA incerteza.
- Outras construções de probabilidade subjetiva: DeFinetti, Savage, French, Kadane,...
- Unicidade da representação (unicidade de \mathbb{P})
- Outras representações de incerteza: lógica (conjuntos) "fuzzy" , probabilidades imprecisas, medidas possibilistas, etc..

Construção de probabilidade subjetiva

- Observações:
- A partir do Teorema, o indivíduo "pode" ("deve") fazer uso das regras do cálculo de probabilidades usuais para lidar com SUA incerteza.
- Outras construções de probabilidade subjetiva: DeFinetti, Savage, French, Kadane,...
- Unicidade da representação (unicidade de \mathbb{P})
- Outras representações de incerteza: lógica (conjuntos) "fuzzy" , probabilidades imprecisas, medidas possibilistas, etc..

Construção de probabilidade subjetiva

- Observações:
- A partir do Teorema, o indivíduo "pode" ("deve") fazer uso das regras do cálculo de probabilidades usuais para lidar com SUA incerteza.
- Outras construções de probabilidade subjetiva: DeFinetti, Savage, French, Kadane,...
- Unicidade da representação (unicidade de \mathbb{P})
- Outras representações de incerteza: lógica (conjuntos) "fuzzy" , probabilidades imprecisas, medidas possibilistas, etc..

Modelo Bayesiano

- Usualmente, num problema de inferência estatística, são desconhecidos, pré-experimentação, θ , o parâmetro de interesse, e X , a amostra, o resultado do experimento.
- Assim, sob certas condições, devemos atribuir probabilidades para o par (θ, X) . Mais precisamente, devemos especificar (no caso Θ e \mathcal{X} finitos)
- $\mathbb{P}(\theta = i, X = x)$ para cada par $(i, x) \in \Theta \times \mathcal{X}$
- Comumente, reescrevemos a distribuição conjunta acima por
- $\mathbb{P}(\theta = i, X = x) = \mathbb{P}(\theta = i) \mathbb{P}(X = x | \theta = i)$

Modelo Bayesiano

- Usualmente, num problema de inferência estatística, são desconhecidos, pré-experimentação, θ , o parâmetro de interesse, e X , a amostra, o resultado do experimento.
- Assim, sob certas condições, devemos atribuir probabilidades para o par (θ, X) . Mais precisamente, devemos especificar (no caso Θ e \mathcal{X} finitos)
- $\mathbb{P}(\theta = i, X = x)$ para cada par $(i, x) \in \Theta \times \mathcal{X}$
- Comumente, reescrevemos a distribuição conjunta acima por
- $\mathbb{P}(\theta = i, X = x) = \mathbb{P}(\theta = i) \mathbb{P}(X = x | \theta = i)$

Modelo Bayesiano

- Usualmente, num problema de inferência estatística, são desconhecidos, pré-experimentação, θ , o parâmetro de interesse, e X , a amostra, o resultado do experimento.
- Assim, sob certas condições, devemos atribuir probabilidades para o par (θ, X) . Mais precisamente, devemos especificar (no caso Θ e \mathcal{X} finitos)
- $\mathbb{P}(\theta = i, X = x)$ para cada par $(i, x) \in \Theta \times \mathcal{X}$
- Comumente, reescrevemos a distribuição conjunta acima por
- $\mathbb{P}(\theta = i, X = x) = \mathbb{P}(\theta = i) \mathbb{P}(X = x | \theta = i)$

Modelo Bayesiano

- Usualmente, num problema de inferência estatística, são desconhecidos, pré-experimentação, θ , o parâmetro de interesse, e X , a amostra, o resultado do experimento.
- Assim, sob certas condições, devemos atribuir probabilidades para o par (θ, X) . Mais precisamente, devemos especificar (no caso Θ e \mathcal{X} finitos)
- $\mathbb{P}(\theta = i, X = x)$ para cada par $(i, x) \in \Theta \times \mathcal{X}$
- Comumente, reescrevemos a distribuição conjunta acima por
- $\mathbb{P}(\theta = i, X = x) = \mathbb{P}(\theta = i) \mathbb{P}(X = x | \theta = i)$

Modelo Bayesiano

- Usualmente, num problema de inferência estatística, são desconhecidos, pré-experimentação, θ , o parâmetro de interesse, e X , a amostra, o resultado do experimento.
- Assim, sob certas condições, devemos atribuir probabilidades para o par (θ, X) . Mais precisamente, devemos especificar (no caso Θ e \mathcal{X} finitos)
- $\mathbb{P}(\theta = i, X = x)$ para cada par $(i, x) \in \Theta \times \mathcal{X}$
- Comumente, reescrevemos a distribuição conjunta acima por
- $\mathbb{P}(\theta = i, X = x) = \mathbb{P}(\theta = i) \mathbb{P}(X = x | \theta = i)$

Modelo Bayesiano

- $\mathbb{P}(\theta = i, X = x) = \mathbb{P}(\theta = i) \mathbb{P}(X = x | \theta = i)$, onde
- $((i, \mathbb{P}(\theta = i)))_{i \in \Theta}$ é a distribuição a **A PRIORI** (pré-amostragem) para θ (distribuição marginal de θ) e
- $((x, \mathbb{P}(X = x | \theta = i)))_{x \in \mathcal{X}}$ é a distribuição para a **AMOSTRA** X dado $\theta = i$.
- Assim, comumente, o modelo estatístico bayesiano é dado por:
- $(\Theta \times \mathcal{X}, \mathcal{F}, \mathbb{P})$, onde \mathcal{F} é sigma-álgebra de subconjuntos de $\Theta \times \mathcal{X}$ e \mathbb{P} é a (única) probabilidade que representa incerteza sobre (θ, X) pré-experimentação.
- $(\Theta \times \mathcal{X}, \mathcal{F}, \mathbb{P})$ é um espaço de probabilidade.

Modelo Bayesiano

- $\mathbb{P}(\theta = i, X = x) = \mathbb{P}(\theta = i) \mathbb{P}(X = x | \theta = i)$, onde
- $((i, \mathbb{P}(\theta = i)))_{i \in \Theta}$ é a distribuição a **A PRIORI** (pré-amostragem) para θ (distribuição marginal de θ) e
- $((x, \mathbb{P}(X = x | \theta = i)))_{x \in \mathcal{X}}$ é a distribuição para a **AMOSTRA** X dado $\theta = i$.
- Assim, comumente, o modelo estatístico bayesiano é dado por:
- $(\Theta \times \mathcal{X}, \mathcal{F}, \mathbb{P})$, onde \mathcal{F} é sigma-álgebra de subconjuntos de $\Theta \times \mathcal{X}$ e \mathbb{P} é a (única) probabilidade que representa incerteza sobre (θ, X) pré-experimentação.
- $(\Theta \times \mathcal{X}, \mathcal{F}, \mathbb{P})$ é um espaço de probabilidade.

Modelo Bayesiano

- $\mathbb{P}(\theta = i, X = x) = \mathbb{P}(\theta = i) \mathbb{P}(X = x | \theta = i)$, onde
- $((i, \mathbb{P}(\theta = i)))_{i \in \Theta}$ é a distribuição a **A PRIORI** (pré-amostragem) para θ (distribuição marginal de θ) e
- $((x, \mathbb{P}(X = x | \theta = i)))_{x \in \mathcal{X}}$ é a distribuição para a **AMOSTRA** X dado $\theta = i$.
- Assim, comumente, o modelo estatístico bayesiano é dado por:
- $(\Theta \times \mathcal{X}, \mathcal{F}, \mathbb{P})$, onde \mathcal{F} é sigma-álgebra de subconjuntos de $\Theta \times \mathcal{X}$ e \mathbb{P} é a (única) probabilidade que representa incerteza sobre (θ, X) pré-experimentação.
- $(\Theta \times \mathcal{X}, \mathcal{F}, \mathbb{P})$ é um espaço de probabilidade.

Modelo Bayesiano

- $\mathbb{P}(\theta = i, X = x) = \mathbb{P}(\theta = i) \mathbb{P}(X = x | \theta = i)$, onde
- $((i, \mathbb{P}(\theta = i)))_{i \in \Theta}$ é a distribuição a **A PRIORI** (pré-amostragem) para θ (distribuição marginal de θ) e
- $((x, \mathbb{P}(X = x | \theta = i)))_{x \in \mathcal{X}}$ é a distribuição para a **AMOSTRA** X dado $\theta = i$.
- Assim, comumente, o modelo estatístico bayesiano é dado por:
- $(\Theta \times \mathcal{X}, \mathcal{F}, \mathbb{P})$, onde \mathcal{F} é sigma-álgebra de subconjuntos de $\Theta \times \mathcal{X}$ e \mathbb{P} é a (única) probabilidade que representa incerteza sobre (θ, X) pré-experimentação.
- $(\Theta \times \mathcal{X}, \mathcal{F}, \mathbb{P})$ é um espaço de probabilidade.

Modelo Bayesiano

- $\mathbb{P}(\theta = i, X = x) = \mathbb{P}(\theta = i) \mathbb{P}(X = x | \theta = i)$, onde
- $((i, \mathbb{P}(\theta = i)))_{i \in \Theta}$ é a distribuição a **A PRIORI** (pré-amostragem) para θ (distribuição marginal de θ) e
- $((x, \mathbb{P}(X = x | \theta = i)))_{x \in \mathcal{X}}$ é a distribuição para a **AMOSTRA** X dado $\theta = i$.
- Assim, comumente, o modelo estatístico bayesiano é dado por:
- $(\Theta \times \mathcal{X}, \mathcal{F}, \mathbb{P})$, onde \mathcal{F} é sigma-álgebra de subconjuntos de $\Theta \times \mathcal{X}$ e \mathbb{P} é a (única) probabilidade que representa incerteza sobre (θ, X) pré-experimentação.
- $(\Theta \times \mathcal{X}, \mathcal{F}, \mathbb{P})$ é um espaço de probabilidade.

Modelo Bayesiano

- $\mathbb{P}(\theta = i, X = x) = \mathbb{P}(\theta = i) \mathbb{P}(X = x | \theta = i)$, onde
- $((i, \mathbb{P}(\theta = i)))_{i \in \Theta}$ é a distribuição a **A PRIORI** (pré-amostragem) para θ (distribuição marginal de θ) e
- $((x, \mathbb{P}(X = x | \theta = i)))_{x \in \mathcal{X}}$ é a distribuição para a **AMOSTRA** X dado $\theta = i$.
- Assim, comumente, o modelo estatístico bayesiano é dado por:
- $(\Theta \times \mathcal{X}, \mathcal{F}, \mathbb{P})$, onde \mathcal{F} é sigma-álgebra de subconjuntos de $\Theta \times \mathcal{X}$ e \mathbb{P} é a (única) probabilidade que representa incerteza sobre (θ, X) pré-experimentação.
- $(\Theta \times \mathcal{X}, \mathcal{F}, \mathbb{P})$ é um espaço de probabilidade.

Operação Bayesiana

- Operação Bayesiana: combina a incerteza inicial sobre θ , representada pela distribuição a priori, com a informação revelada sobre o parâmetro pelos dados, $x \in \mathcal{X}$, expressa por $V_x(\cdot)$.

TEOREMA DE BAYES

$(\Omega, \mathbb{F}, \mathbb{P})$. Seja (A_1, \dots, A_k) partição de Ω e $D \in \mathcal{F}$ com $\mathbb{P}(D) > 0$. Então, para $i = 1, \dots, k$,

$$\mathbb{P}(A_i|D) = \frac{\mathbb{P}(D|A_i) \mathbb{P}(A_i)}{\sum_{j=1}^k \mathbb{P}(D|A_j) \mathbb{P}(A_j)}$$

- No modelo bayesiano, se $\Theta = \{\theta_1, \dots, \theta_k\}$, definindo $A_i = \{\theta = i\}$, $i = 1, \dots, k$, e $D = \{X = x\}$, obtemos, pelo Teorema de Bayes, que

Operação Bayesiana

- Operação Bayesiana: combina a incerteza inicial sobre θ , representada pela distribuição a priori, com a informação revelada sobre o parâmetro pelos dados, $x \in \mathcal{X}$, expressa por $V_x(\cdot)$.

TEOREMA DE BAYES

$(\Omega, \mathbb{F}, \mathbb{P})$. Seja (A_1, \dots, A_k) partição de Ω e $D \in \mathcal{F}$ com $\mathbb{P}(D) > 0$. Então, para $i = 1, \dots, k$,

$$\mathbb{P}(A_i|D) = \frac{\mathbb{P}(D|A_i) \mathbb{P}(A_i)}{\sum_{j=1}^k \mathbb{P}(D|A_j) \mathbb{P}(A_j)}$$

- No modelo bayesiano, se $\Theta = \{\theta_1, \dots, \theta_k\}$, definindo $A_i = \{\theta = i\}$, $i = 1, \dots, k$, e $D = \{X = x\}$, obtemos, pelo Teorema de Bayes, que

Operação Bayesiana

- Operação Bayesiana: combina a incerteza inicial sobre θ , representada pela distribuição a priori, com a informação revelada sobre o parâmetro pelos dados, $x \in \mathcal{X}$, expressa por $V_x(\cdot)$.

TEOREMA DE BAYES

$(\Omega, \mathbb{F}, \mathbb{P})$. Seja (A_1, \dots, A_k) partição de Ω e $D \in \mathcal{F}$ com $\mathbb{P}(D) > 0$. Então, para $i = 1, \dots, k$,

$$\mathbb{P}(A_i|D) = \frac{\mathbb{P}(D|A_i) \mathbb{P}(A_i)}{\sum_{j=1}^k \mathbb{P}(D|A_j) \mathbb{P}(A_j)}$$

- No modelo bayesiano, se $\Theta = \{\theta_1, \dots, \theta_k\}$, definindo $A_i = \{\theta = i\}$, $i = 1, \dots, k$, e $D = \{X = x\}$, obtemos, pelo Teorema de Bayes, que

Operação Bayesiana

- $\mathbb{P}(\theta = i | X = x) = \frac{\mathbb{P}(X=x|\theta=i) \mathbb{P}(\theta=i)}{\sum_{j=1}^k \mathbb{P}(X=x|\theta=j) \mathbb{P}(\theta=j)}$
- $((i, \mathbb{P}(\theta = i | X = x)))_{i \in \Theta}$: distribuição a posteriori para θ dada a informação revelada pela observação $X = x$.
- Extensões comuns (além do caso discreto):
- 1) X discreto e θ contínuo:

$$f(\theta | X = x) = \frac{\mathbb{P}(X=x|\theta) f(\theta)}{\int_{\Theta} \mathbb{P}(X=x|\theta') f(\theta') d\theta'} \propto \mathbb{P}(X = x|\theta) f(\theta)$$

- 2) (θ, X) contínuo:

$$f(\theta | x) = \frac{f(x|\theta) f(\theta)}{\int_{\Theta} f(x|\theta') f(\theta') d\theta'} \propto f(x|\theta) f(\theta)$$

Operação Bayesiana

- $\mathbb{P}(\theta = i | X = x) = \frac{\mathbb{P}(X=x|\theta=i) \mathbb{P}(\theta=i)}{\sum_{j=1}^k \mathbb{P}(X=x|\theta=j) \mathbb{P}(\theta=j)}$
- $((i, \mathbb{P}(\theta = i | X = x)))_{i \in \Theta}$: distribuição a posteriori para θ dada a informação revelada pela observação $X = x$.
- Extensões comuns (além do caso discreto):

- 1) X discreto e θ contínuo:

$$f(\theta | X = x) = \frac{\mathbb{P}(X=x|\theta) f(\theta)}{\int_{\Theta} \mathbb{P}(X=x|\theta') f(\theta') d\theta'} \propto \mathbb{P}(X = x|\theta) f(\theta)$$

- 2) (θ, X) contínuo:

$$f(\theta | x) = \frac{f(x|\theta) f(\theta)}{\int_{\Theta} f(x|\theta') f(\theta') d\theta'} \propto f(x|\theta) f(\theta)$$

Operação Bayesiana

- $\mathbb{P}(\theta = i | X = x) = \frac{\mathbb{P}(X=x|\theta=i) \mathbb{P}(\theta=i)}{\sum_{j=1}^k \mathbb{P}(X=x|\theta=j) \mathbb{P}(\theta=j)}$
- $((i, \mathbb{P}(\theta = i | X = x)))_{i \in \Theta}$: distribuição a posteriori para θ dada a informação revelada pela observação $X = x$.

● Extensões comuns (além do caso discreto):

● 1) X discreto e θ contínuo:

$$f(\theta | X = x) = \frac{\mathbb{P}(X=x|\theta) f(\theta)}{\int_{\Theta} \mathbb{P}(X=x|\theta') f(\theta') d\theta'} \propto \mathbb{P}(X = x|\theta) f(\theta)$$

● 2) (θ, X) contínuo:

$$f(\theta | x) = \frac{f(x|\theta) f(\theta)}{\int_{\Theta} f(x|\theta') f(\theta') d\theta'} \propto f(x|\theta) f(\theta)$$

Operação Bayesiana

- $\mathbb{P}(\theta = i | X = x) = \frac{\mathbb{P}(X=x|\theta=i) \mathbb{P}(\theta=i)}{\sum_{j=1}^k \mathbb{P}(X=x|\theta=j) \mathbb{P}(\theta=j)}$
- $((i, \mathbb{P}(\theta = i | X = x)))_{i \in \Theta}$: distribuição a posteriori para θ dada a informação revelada pela observação $X = x$.
- Extensões comuns (além do caso discreto):

- 1) X discreto e θ contínuo:

$$f(\theta | X = x) = \frac{\mathbb{P}(X=x|\theta) f(\theta)}{\int_{\Theta} \mathbb{P}(X=x|\theta') f(\theta') d\theta'} \propto \mathbb{P}(X = x|\theta) f(\theta)$$

- 2) (θ, X) contínuo:

$$f(\theta | x) = \frac{f(x|\theta) f(\theta)}{\int_{\Theta} f(x|\theta') f(\theta') d\theta'} \propto f(x|\theta) f(\theta)$$

Operação Bayesiana

- $\mathbb{P}(\theta = i | X = x) = \frac{\mathbb{P}(X=x|\theta=i) \mathbb{P}(\theta=i)}{\sum_{j=1}^k \mathbb{P}(X=x|\theta=j) \mathbb{P}(\theta=j)}$
- $((i, \mathbb{P}(\theta = i | X = x)))_{i \in \Theta}$: distribuição a posteriori para θ dada a informação revelada pela observação $X = x$.
- Extensões comuns (além do caso discreto):
- 1) X discreto e θ contínuo:

$$f(\theta | X = x) = \frac{\mathbb{P}(X=x|\theta) f(\theta)}{\int_{\Theta} \mathbb{P}(X=x|\theta') f(\theta') d\theta'} \propto \mathbb{P}(X = x|\theta) f(\theta)$$

- 2) (θ, X) contínuo:

$$f(\theta | x) = \frac{f(x|\theta) f(\theta)}{\int_{\Theta} f(x|\theta') f(\theta') d\theta'} \propto f(x|\theta) f(\theta)$$

Operação Bayesiana

- $\mathbb{P}(\theta = i | X = x) = \frac{\mathbb{P}(X=x|\theta=i) \mathbb{P}(\theta=i)}{\sum_{j=1}^k \mathbb{P}(X=x|\theta=j) \mathbb{P}(\theta=j)}$
- $((i, \mathbb{P}(\theta = i | X = x)))_{i \in \Theta}$: distribuição a posteriori para θ dada a informação revelada pela observação $X = x$.
- Extensões comuns (além do caso discreto):

- 1) X discreto e θ contínuo:

$$f(\theta | X = x) = \frac{\mathbb{P}(X=x|\theta) f(\theta)}{\int_{\Theta} \mathbb{P}(X=x|\theta') f(\theta') d\theta'} \propto \mathbb{P}(X = x|\theta) f(\theta)$$

- 2) (θ, X) contínuo:

$$f(\theta | x) = \frac{f(x|\theta) f(\theta)}{\int_{\Theta} f(x|\theta') f(\theta') d\theta'} \propto f(x|\theta) f(\theta)$$

Operação Bayesiana

- Exemplo 1: Uma urna contém θ bolas brancas e $5 - \theta$ bolas verdes, $\theta \in \Theta = \{0, 1, 2, 3, 4, 5\}$. Duas bolas são extraídas uma a uma, sem reposição, da urna. Seja $X_i = 1$, se a i -ésima bola retirada é branca e $X_i = 0$, caso contrário. Seja $X = (X_1, X_2)$. Suponha $\theta \sim \text{Uniforme}(\Theta)$.

- Se são observadas, em sequência, uma bola verde e uma bola branca, temos, a posteriori, para $i = 0, 1, 2, 3, 4, 5$, que

$$\bullet \mathbb{P}(\theta = i | X = (0, 1)) = \frac{\mathbb{P}(X=(0,1)|\theta=i) \mathbb{P}(\theta=i)}{\sum_{j=0}^5 \mathbb{P}(X=(0,1)|\theta=j) \mathbb{P}(\theta=j)} =$$

$$\bullet = \frac{\frac{(5-i)}{5} \frac{i}{4} \frac{1}{6}}{\sum_{j=0}^5 \frac{(5-j)}{5} \frac{j}{4} \frac{1}{6}} \Rightarrow \mathbb{P}(\theta = i | X = (0, 1)) = \frac{i(5-i)}{20}$$

Operação Bayesiana

- Exemplo 1: Uma urna contém θ bolas brancas e $5 - \theta$ bolas verdes, $\theta \in \Theta = \{0, 1, 2, 3, 4, 5\}$. Duas bolas são extraídas uma a uma, sem reposição, da urna. Seja $X_i = 1$, se a i -ésima bola retirada é branca e $X_i = 0$, caso contrário. Seja $X = (X_1, X_2)$. Suponha $\theta \sim \text{Uniforme}(\Theta)$.

- Se são observadas, em sequência, uma bola verde e uma bola branca, temos, a posteriori, para $i = 0, 1, 2, 3, 4, 5$, que

$$\mathbb{P}(\theta = i | X = (0, 1)) = \frac{\mathbb{P}(X=(0,1)|\theta=i) \mathbb{P}(\theta=i)}{\sum_{j=0}^5 \mathbb{P}(X=(0,1)|\theta=j) \mathbb{P}(\theta=j)} =$$

$$= \frac{\frac{(5-i)}{5} \frac{i}{4} \frac{1}{6}}{\sum_{j=0}^5 \frac{(5-j)}{5} \frac{j}{4} \frac{1}{6}} \Rightarrow \mathbb{P}(\theta = i | X = (0, 1)) = \frac{i(5-i)}{20}$$

Operação Bayesiana

- Exemplo 1: Uma urna contém θ bolas brancas e $5 - \theta$ bolas verdes, $\theta \in \Theta = \{0, 1, 2, 3, 4, 5\}$. Duas bolas são extraídas uma a uma, sem reposição, da urna. Seja $X_i = 1$, se a i -ésima bola retirada é branca e $X_i = 0$, caso contrário. Seja $X = (X_1, X_2)$. Suponha $\theta \sim \text{Uniforme}(\Theta)$.
- Se são observadas, em sequência, uma bola verde e uma bola branca, temos, a posteriori, para $i = 0, 1, 2, 3, 4, 5$, que

$$\mathbb{P}(\theta = i | X = (0, 1)) = \frac{\mathbb{P}(X=(0,1)|\theta=i) \mathbb{P}(\theta=i)}{\sum_{j=0}^5 \mathbb{P}(X=(0,1)|\theta=j) \mathbb{P}(\theta=j)} =$$

$$= \frac{\frac{(5-i)}{5} \frac{i}{4} \frac{1}{6}}{\sum_{j=0}^5 \frac{(5-j)}{5} \frac{j}{4} \frac{1}{6}} \Rightarrow \mathbb{P}(\theta = i | X = (0, 1)) = \frac{i(5-i)}{20}$$

Operação Bayesiana

- Exemplo 1: Uma urna contém θ bolas brancas e $5 - \theta$ bolas verdes, $\theta \in \Theta = \{0, 1, 2, 3, 4, 5\}$. Duas bolas são extraídas uma a uma, sem reposição, da urna. Seja $X_i = 1$, se a i -ésima bola retirada é branca e $X_i = 0$, caso contrário. Seja $X = (X_1, X_2)$. Suponha $\theta \sim \text{Uniforme}(\Theta)$.

- Se são observadas, em sequência, uma bola verde e uma bola branca, temos, a posteriori, para $i = 0, 1, 2, 3, 4, 5$, que

$$\bullet \mathbb{P}(\theta = i | X = (0, 1)) = \frac{\mathbb{P}(X=(0,1)|\theta=i) \mathbb{P}(\theta=i)}{\sum_{j=0}^5 \mathbb{P}(X=(0,1)|\theta=j) \mathbb{P}(\theta=j)} =$$

$$\bullet = \frac{\frac{(5-i)}{5} \frac{i}{4} \frac{1}{6}}{\sum_{j=0}^5 \frac{(5-j)}{5} \frac{j}{4} \frac{1}{6}} \Rightarrow \mathbb{P}(\theta = i | X = (0, 1)) = \frac{i(5-i)}{20}$$

Operação Bayesiana

- Exemplo 1: Uma urna contém θ bolas brancas e $5 - \theta$ bolas verdes, $\theta \in \Theta = \{0, 1, 2, 3, 4, 5\}$. Duas bolas são extraídas uma a uma, sem reposição, da urna. Seja $X_i = 1$, se a i -ésima bola retirada é branca e $X_i = 0$, caso contrário. Seja $X = (X_1, X_2)$. Suponha $\theta \sim \text{Uniforme}(\Theta)$.

- Se são observadas, em sequência, uma bola verde e uma bola branca, temos, a posteriori, para $i = 0, 1, 2, 3, 4, 5$, que

$$\bullet \mathbb{P}(\theta = i | X = (0, 1)) = \frac{\mathbb{P}(X=(0,1)|\theta=i) \mathbb{P}(\theta=i)}{\sum_{j=0}^5 \mathbb{P}(X=(0,1)|\theta=j) \mathbb{P}(\theta=j)} =$$

$$\bullet = \frac{\frac{(5-i)}{5} \frac{i}{4} \frac{1}{6}}{\sum_{j=0}^5 \frac{(5-j)}{5} \frac{j}{4} \frac{1}{6}} \Rightarrow \mathbb{P}(\theta = i | X = (0, 1)) = \frac{i(5-i)}{20}$$

Operação Bayesiana

- Se são observadas duas bolas brancas, temos, a posteriori, para $i = 0, 1, 2, 3, 4, 5$, que

- $$\mathbb{P}(\theta = i | X = (1, 1)) = \frac{\mathbb{P}(X=(1,1)|\theta=i) \mathbb{P}(\theta=i)}{\sum_{j=0}^5 \mathbb{P}(X=(1,1)|\theta=j) \mathbb{P}(\theta=j)} =$$

- $$= \frac{\frac{i}{5} \frac{(i-1)}{4} \frac{1}{6}}{\sum_{j=0}^5 \frac{j}{5} \frac{(j-1)}{4} \frac{1}{6}} \Rightarrow \mathbb{P}(\theta = i | X = (1, 1)) = \frac{i(i-1)}{40}$$

Operação Bayesiana

- Se são observadas duas bolas brancas, temos, a posteriori, para $i = 0, 1, 2, 3, 4, 5$, que

$$\bullet \mathbb{P}(\theta = i | X = (1, 1)) = \frac{\mathbb{P}(X=(1,1)|\theta=i) \mathbb{P}(\theta=i)}{\sum_{j=0}^5 \mathbb{P}(X=(1,1)|\theta=j) \mathbb{P}(\theta=j)} =$$

$$\bullet = \frac{\frac{i}{5} \frac{(i-1)}{4} \frac{1}{6}}{\sum_{j=0}^5 \frac{j}{5} \frac{(j-1)}{4} \frac{1}{6}} \Rightarrow \mathbb{P}(\theta = i | X = (1, 1)) = \frac{i(i-1)}{40}$$

Operação Bayesiana

- Se são observadas duas bolas brancas, temos, a posteriori, para $i = 0, 1, 2, 3, 4, 5$, que

$$\bullet \mathbb{P}(\theta = i | X = (1, 1)) = \frac{\mathbb{P}(X=(1,1)|\theta=i) \mathbb{P}(\theta=i)}{\sum_{j=0}^5 \mathbb{P}(X=(1,1)|\theta=j) \mathbb{P}(\theta=j)} =$$

$$\bullet = \frac{\frac{i}{5} \frac{(i-1)}{4} \frac{1}{6}}{\sum_{j=0}^5 \frac{j}{5} \frac{(j-1)}{4} \frac{1}{6}} \Rightarrow \mathbb{P}(\theta = i | X = (1, 1)) = \frac{i(i-1)}{40}$$

Operação Bayesiana

- Se são observadas duas bolas brancas, temos, a posteriori, para $i = 0, 1, 2, 3, 4, 5$, que

- $$\mathbb{P}(\theta = i | X = (1, 1)) = \frac{\mathbb{P}(X=(1,1)|\theta=i) \mathbb{P}(\theta=i)}{\sum_{j=0}^5 \mathbb{P}(X=(1,1)|\theta=j) \mathbb{P}(\theta=j)} =$$

- $$= \frac{\frac{i}{5} \frac{(i-1)}{4} \frac{1}{6}}{\sum_{j=0}^5 \frac{j}{5} \frac{(j-1)}{4} \frac{1}{6}} \Rightarrow \mathbb{P}(\theta = i | X = (1, 1)) = \frac{i(i-1)}{40}$$

Operação Bayesiana

- Exemplo 2: Considere um processo de produção no qual os itens produzidos são classificados como não defeituosos ou defeituosos. Para avaliar a fração não conforme do processo, θ , uma amostra de $n = 10$ itens é selecionada da produção e cada unidade amostrada é classificada como defeituosa ou não defeituosa. Para $i = 1, \dots, n$, seja $X_i = 1$ se o i -ésimo item observado é classificado como não conforme e $X_i = 0$, caso contrário. Seja $X = (X_1, \dots, X_{10})$. Suponhamos, a priori, $\theta \sim \text{Beta}(1, 19)$.
- Se você é informado que $X = x = (0, 0, 0, 0, 0, 0, 0, 0, 0, 0)$, temos, admitindo que X é AAS do modelo Bernoulli (θ), que

Operação Bayesiana

- Exemplo 2: Considere um processo de produção no qual os itens produzidos são classificados como não defeituosos ou defeituosos. Para avaliar a fração não conforme do processo, θ , uma amostra de $n = 10$ itens é selecionada da produção e cada unidade amostrada é classificada como defeituosa ou não defeituosa. Para $i = 1, \dots, n$, seja $X_i = 1$ se o i -ésimo item observado é classificado como não conforme e $X_i = 0$, caso contrário. Seja $X = (X_1, \dots, X_{10})$. Suponhamos, a priori, $\theta \sim \text{Beta}(1, 19)$.
- Se você é informado que $X = x = (0, 0, 0, 0, 0, 0, 0, 0, 0, 0)$, temos, admitindo que X é AAS do modelo Bernoulli (θ), que

Operação Bayesiana

- Exemplo 2: Considere um processo de produção no qual os itens produzidos são classificados como não defeituosos ou defeituosos. Para avaliar a fração não conforme do processo, θ , uma amostra de $n = 10$ itens é selecionada da produção e cada unidade amostrada é classificada como defeituosa ou não defeituosa. Para $i = 1, \dots, n$, seja $X_i = 1$ se o i -ésimo item observado é classificado como não conforme e $X_i = 0$, caso contrário. Seja $X = (X_1, \dots, X_{10})$. Suponhamos, a priori, $\theta \sim \text{Beta}(1, 19)$.
- Se você é informado que $X = x = (0, 0, 0, 0, 0, 0, 0, 0, 0, 0)$, temos, admitindo que X é AAS do modelo Bernoulli (θ), que

Operação Bayesiana

- $\theta \sim \text{Beta}(1 + 0, 19 + 10 - 0) \sim \text{Beta}(1, 29)$
- Lembrete: Se $\theta \sim \text{Beta}(a, b)$, $a, b > 0$, e (X_1, \dots, X_n) é AAS do modelo Bernoulli (θ) , então

$$\theta | X_1 = x_1, \dots, X_n = x_n \sim \text{Beta}(a + \sum_{i=1}^n x_i, b + n - \sum_{i=1}^n x_i)$$

- Por outro lado, se o resultado do experimento é $X = (0, 0, 0, 0, 0, 0, 0, 1, 0, 0)$, temos, admitindo que X é AAS do modelo Bernoulli (θ) , que
- $\theta \sim \text{Beta}(1 + 1, 19 + 10 - 1) \sim \text{Beta}(2, 28)$

Operação Bayesiana

- $\theta \sim \text{Beta}(1 + 0, 19 + 10 - 0) \sim \text{Beta}(1, 29)$
- Lembrete: Se $\theta \sim \text{Beta}(a, b)$, $a, b > 0$, e (X_1, \dots, X_n) é AAS do modelo Bernoulli (θ) , então

$$\theta | X_1 = x_1, \dots, X_n = x_n \sim \text{Beta}(a + \sum_{i=1}^n x_i, b + n - \sum_{i=1}^n x_i)$$

- Por outro lado, se o resultado do experimento é $X = (0, 0, 0, 0, 0, 0, 0, 1, 0, 0)$, temos, admitindo que X é AAS do modelo Bernoulli (θ) , que
- $\theta \sim \text{Beta}(1 + 1, 19 + 10 - 1) \sim \text{Beta}(2, 28)$

Operação Bayesiana

- $\theta \sim \text{Beta}(1 + 0, 19 + 10 - 0) \sim \text{Beta}(1, 29)$
- Lembrete: Se $\theta \sim \text{Beta}(a, b)$, $a, b > 0$, e (X_1, \dots, X_n) é AAS do modelo Bernoulli (θ), então

$$\theta | X_1 = x_1, \dots, X_n = x_n \sim \text{Beta}(a + \sum_{i=1}^n x_i, b + n - \sum_{i=1}^n x_i)$$

- Por outro lado, se o resultado do experimento é $X = (0, 0, 0, 0, 0, 0, 0, 1, 0, 0)$, temos, admitindo que X é AAS do modelo Bernoulli (θ), que
- $\theta \sim \text{Beta}(1 + 1, 19 + 10 - 1) \sim \text{Beta}(2, 28)$

Operação Bayesiana

- $\theta \sim \text{Beta}(1 + 0, 19 + 10 - 0) \sim \text{Beta}(1, 29)$
- Lembrete: Se $\theta \sim \text{Beta}(a, b)$, $a, b > 0$, e (X_1, \dots, X_n) é AAS do modelo Bernoulli (θ), então

$$\theta | X_1 = x_1, \dots, X_n = x_n \sim \text{Beta}(a + \sum_{i=1}^n x_i, b + n - \sum_{i=1}^n x_i)$$

- Por outro lado, se o resultado do experimento é $X = (0, 0, 0, 0, 0, 0, 0, 1, 0, 0)$, temos, admitindo que X é AAS do modelo Bernoulli (θ), que

$$\theta \sim \text{Beta}(1 + 1, 19 + 10 - 1) \sim \text{Beta}(2, 28)$$

Operação Bayesiana

- $\theta \sim \text{Beta}(1 + 0, 19 + 10 - 0) \sim \text{Beta}(1, 29)$
- Lembrete: Se $\theta \sim \text{Beta}(a, b)$, $a, b > 0$, e (X_1, \dots, X_n) é AAS do modelo Bernoulli (θ), então

$$\theta | X_1 = x_1, \dots, X_n = x_n \sim \text{Beta}(a + \sum_{i=1}^n x_i, b + n - \sum_{i=1}^n x_i)$$

- Por outro lado, se o resultado do experimento é $X = (0, 0, 0, 0, 0, 0, 0, 1, 0, 0)$, temos, admitindo que X é AAS do modelo Bernoulli (θ), que
- $\theta \sim \text{Beta}(1 + 1, 19 + 10 - 1) \sim \text{Beta}(2, 28)$

Operação Bayesiana

- Comentários:
- 1) Distribuição a posteriori: inferência plena (mais completa) sob a perspectiva bayesiana.
- 2) Sequencialidade da operação bayesiana
- Exemplo 1: Inicialmente, observação "apenas" de $X_1 = 0$:

$$\begin{aligned}\mathbb{P}(\theta = i | X_1 = 0) &= \frac{\mathbb{P}(X_1=0|\theta=i) \mathbb{P}(\theta=i)}{\sum_{j=0}^5 \mathbb{P}(X_1=0|\theta=j) \mathbb{P}(\theta=j)} = \\ &= \frac{\frac{(5-i)}{5} \frac{1}{6}}{\sum_{j=0}^5 \frac{(5-j)}{5} \frac{1}{6}} \Rightarrow \mathbb{P}(\theta = i | X_1 = 0) = \frac{(5-i)}{15}\end{aligned}$$

Operação Bayesiana

- Comentários:
- 1) Distribuição a posteriori: inferência plena (mais completa) sob a perspectiva bayesiana.
- 2) Sequencialidade da operação bayesiana
- Exemplo 1: Inicialmente, observação "apenas" de $X_1 = 0$:

$$\begin{aligned}\mathbb{P}(\theta = i | X_1 = 0) &= \frac{\mathbb{P}(X_1=0|\theta=i) \mathbb{P}(\theta=i)}{\sum_{j=0}^5 \mathbb{P}(X_1=0|\theta=j) \mathbb{P}(\theta=j)} = \\ &= \frac{\frac{(5-i)}{5} \frac{1}{6}}{\sum_{j=0}^5 \frac{(5-j)}{5} \frac{1}{6}} \Rightarrow \mathbb{P}(\theta = i | X_1 = 0) = \frac{(5-i)}{15}\end{aligned}$$

Operação Bayesiana

- Comentários:
- 1) Distribuição a posteriori: inferência plena (mais completa) sob a perspectiva bayesiana.
- 2) Sequencialidade da operação bayesiana
- Exemplo 1: Inicialmente, observação "apenas" de $X_1 = 0$:

$$\begin{aligned}\mathbb{P}(\theta = i | X_1 = 0) &= \frac{\mathbb{P}(X_1=0|\theta=i) \mathbb{P}(\theta=i)}{\sum_{j=0}^5 \mathbb{P}(X_1=0|\theta=j) \mathbb{P}(\theta=j)} = \\ &= \frac{\frac{(5-i)}{5} \frac{1}{6}}{\sum_{j=0}^5 \frac{(5-j)}{5} \frac{1}{6}} \Rightarrow \mathbb{P}(\theta = i | X_1 = 0) = \frac{(5-i)}{15}\end{aligned}$$

Operação Bayesiana

- Comentários:
- 1) Distribuição a posteriori: inferência plena (mais completa) sob a perspectiva bayesiana.
- 2) Sequencialidade da operação bayesiana
- Exemplo 1: Inicialmente, observação "apenas" de $X_1 = 0$:

$$\begin{aligned}\mathbb{P}(\theta = i | X_1 = 0) &= \frac{\mathbb{P}(X_1=0|\theta=i) \mathbb{P}(\theta=i)}{\sum_{j=0}^5 \mathbb{P}(X_1=0|\theta=j) \mathbb{P}(\theta=j)} = \\ &= \frac{\frac{(5-i)}{5} \frac{1}{6}}{\sum_{j=0}^5 \frac{(5-j)}{5} \frac{1}{6}} \Rightarrow \mathbb{P}(\theta = i | X_1 = 0) = \frac{(5-i)}{15}\end{aligned}$$

Operação Bayesiana

- Comentários:
- 1) Distribuição a posteriori: inferência plena (mais completa) sob a perspectiva bayesiana.
- 2) Sequencialidade da operação bayesiana
- Exemplo 1: Inicialmente, observação "apenas" de $X_1 = 0$:

$$\begin{aligned}\mathbb{P}(\theta = i | X_1 = 0) &= \frac{\mathbb{P}(X_1=0|\theta=i) \mathbb{P}(\theta=i)}{\sum_{j=0}^5 \mathbb{P}(X_1=0|\theta=j) \mathbb{P}(\theta=j)} = \\ &= \frac{\frac{(5-i)}{5} \frac{1}{6}}{\sum_{j=0}^5 \frac{(5-j)}{5} \frac{1}{6}} \Rightarrow \mathbb{P}(\theta = i | X_1 = 0) = \frac{(5-i)}{15}\end{aligned}$$

Operação Bayesiana

- Em seguida, após a observação de $X_2 = 1$:

- $\mathbb{P}(\theta = i | X_2 = 1, X_1 = 0) =$

$$= \frac{\mathbb{P}(X_2=1|\theta=i, X_1=0) \mathbb{P}(\theta=i|X_1=0)}{\sum_{j=0}^5 \mathbb{P}(X_2=1|\theta=j, X_1=0) \mathbb{P}(\theta=j|X_1=0)} =$$

$$= \frac{\frac{i}{4} \frac{(5-i)}{15}}{\sum_{j=0}^5 \frac{j}{4} \frac{(5-j)}{15}} \Rightarrow$$

$$\Rightarrow \mathbb{P}(\theta = i | X_2 = 1, X_1 = 0) = \frac{i(5-i)}{20}$$

Operação Bayesiana

- Em seguida, após a observação de $X_2 = 1$:

- $\mathbb{P}(\theta = i | X_2 = 1, X_1 = 0) =$

$$= \frac{\mathbb{P}(X_2=1|\theta=i, X_1=0) \mathbb{P}(\theta=i|X_1=0)}{\sum_{j=0}^5 \mathbb{P}(X_2=1|\theta=j, X_1=0) \mathbb{P}(\theta=j|X_1=0)} =$$

$$= \frac{\frac{i}{4} \frac{(5-i)}{15}}{\sum_{j=0}^5 \frac{j}{4} \frac{(5-j)}{15}} \Rightarrow$$

$$\Rightarrow \mathbb{P}(\theta = i | X_2 = 1, X_1 = 0) = \frac{i(5-i)}{20}$$

Operação Bayesiana

- Em seguida, após a observação de $X_2 = 1$:

- $\mathbb{P}(\theta = i | X_2 = 1, X_1 = 0) =$

$$= \frac{\mathbb{P}(X_2=1|\theta=i, X_1=0) \mathbb{P}(\theta=i|X_1=0)}{\sum_{j=0}^5 \mathbb{P}(X_2=1|\theta=j, X_1=0) \mathbb{P}(\theta=j|X_1=0)} =$$

$$= \frac{\frac{i}{4} \frac{(5-i)}{15}}{\sum_{j=0}^5 \frac{j}{4} \frac{(5-j)}{15}} \Rightarrow$$

$$\Rightarrow \mathbb{P}(\theta = i | X_2 = 1, X_1 = 0) = \frac{i(5-i)}{20}$$

Operação Bayesiana

- No Exemplo 2, suponhamos a observação, primeiramente, de $X_1 = \dots = X_5 = 0$. Então,

$$\theta | X_1 = \dots = X_5 = 0 \sim \text{Beta}(1 + 0; 19 + 5 - 0) \sim \text{Beta}(1, 24)$$

Em seguida, observadas $X_6 = \dots = X_{10} = 0$, temos

$$\begin{aligned} \theta | X_6 = \dots = X_{10} = 0, X_1 = \dots = X_5 = 0 &\sim \\ &\sim \text{Beta}(1 + 0, 24 + 5 - 0) \sim \text{Beta}(1, 29) \end{aligned}$$

Analogamente, se $X_6 = X_7 = X_8 = 0, X_9 = 1, X_{10} = 0$, temos

$$\begin{aligned} \theta | X_6 = X_7 = X_8 = 0, X_9 = 1, X_{10} = 0, X_1 = \dots = X_5 = 0 &\sim \\ &\sim \text{Beta}(1 + 1, 24 + 5 - 1) \sim \text{Beta}(2, 28). \end{aligned}$$

Operação Bayesiana

- No Exemplo 2, suponhamos a observação, primeiramente, de $X_1 = \dots = X_5 = 0$. Então,

$$\theta | X_1 = \dots = X_5 = 0 \sim \text{Beta}(1 + 0; 19 + 5 - 0) \sim \text{Beta}(1, 24)$$

Em seguida, observadas $X_6 = \dots = X_{10} = 0$, temos

$$\begin{aligned} \theta | X_6 = \dots = X_{10} = 0, X_1 = \dots = X_5 = 0 &\sim \\ &\sim \text{Beta}(1 + 0, 24 + 5 - 0) \sim \text{Beta}(1, 29) \end{aligned}$$

Analogamente, se $X_6 = X_7 = X_8 = 0, X_9 = 1, X_{10} = 0$, temos

$$\begin{aligned} \theta | X_6 = X_7 = X_8 = 0, X_9 = 1, X_{10} = 0, X_1 = \dots = X_5 = 0 &\sim \\ &\sim \text{Beta}(1 + 1, 24 + 5 - 1) \sim \text{Beta}(2, 28). \end{aligned}$$

Suficiência

● 3) Suficiência

● No exemplo 1, note que (exercício !!!),

● $\theta|X_1 = 0, X_2 = 1 \sim \theta|X_1 + X_2 = 1$

● Na verdade, (exercício!!!) para todo $(x_1, x_2) \in \mathcal{X}$,

● $\theta|X_1 = x_1, X_2 = x_2 \sim \theta|X_1 + X_2 = x_1 + x_2$

● No exemplo 2, de modo similar,

● $\theta|X_1 = \dots = X_8 = X_{10} = 0, X_9 = 1 \sim \theta|\sum_{i=1}^{10} X_i = 1$

Suficiência

● 3) Suficiência

- No exemplo 1, note que (exercício !!!),
- $\theta|X_1 = 0, X_2 = 1 \sim \theta|X_1 + X_2 = 1$
- Na verdade, (exercício!!!) para todo $(x_1, x_2) \in \mathcal{X}$,
- $\theta|X_1 = x_1, X_2 = x_2 \sim \theta|X_1 + X_2 = x_1 + x_2$
- No exemplo 2, de modo similar,
- $\theta|X_1 = \dots = X_8 = X_{10} = 0, X_9 = 1 \sim \theta|\sum_{i=1}^{10} X_i = 1$

Suficiência

- **3) Suficiência**

- No exemplo 1, note que (exercício !!!),

- $\theta|X_1 = 0, X_2 = 1 \sim \theta|X_1 + X_2 = 1$

- Na verdade, (exercício!!!) para todo $(x_1, x_2) \in \mathcal{X}$,

- $\theta|X_1 = x_1, X_2 = x_2 \sim \theta|X_1 + X_2 = x_1 + x_2$

- No exemplo 2, de modo similar,

- $\theta|X_1 = \dots = X_8 = X_{10} = 0, X_9 = 1 \sim \theta|\sum_{i=1}^{10} X_i = 1$

Suficiência

- **3) Suficiência**

- No exemplo 1, note que (exercício !!!),

- $\theta|X_1 = 0, X_2 = 1 \sim \theta|X_1 + X_2 = 1$

- Na verdade, (exercício!!!) para todo $(x_1, x_2) \in \mathcal{X}$,

- $\theta|X_1 = x_1, X_2 = x_2 \sim \theta|X_1 + X_2 = x_1 + x_2$

- No exemplo 2, de modo similar,

- $\theta|X_1 = \dots = X_8 = X_{10} = 0, X_9 = 1 \sim \theta|\sum_{i=1}^{10} X_i = 1$

Suficiência

- **3) Suficiência**

- No exemplo 1, note que (exercício !!!),

- $\theta|X_1 = 0, X_2 = 1 \sim \theta|X_1 + X_2 = 1$

- Na verdade, (exercício!!!) para todo $(x_1, x_2) \in \mathcal{X}$,

- $\theta|X_1 = x_1, X_2 = x_2 \sim \theta|X_1 + X_2 = x_1 + x_2$

- No exemplo 2, de modo similar,

- $\theta|X_1 = \dots = X_8 = X_{10} = 0, X_9 = 1 \sim \theta|\sum_{i=1}^{10} X_i = 1$

Suficiência

- 3) **Suficiência**

- No exemplo 1, note que (exercício !!!),

- $\theta|X_1 = 0, X_2 = 1 \sim \theta|X_1 + X_2 = 1$

- Na verdade, (exercício!!!) para todo $(x_1, x_2) \in \mathcal{X}$,

- $\theta|X_1 = x_1, X_2 = x_2 \sim \theta|X_1 + X_2 = x_1 + x_2$

- No exemplo 2, de modo similar,

- $\theta|X_1 = \dots = X_8 = X_{10} = 0, X_9 = 1 \sim \theta|\sum_{i=1}^{10} X_i = 1$

Suficiência

- 3) **Suficiência**

- No exemplo 1, note que (exercício !!!),

- $\theta|X_1 = 0, X_2 = 1 \sim \theta|X_1 + X_2 = 1$

- Na verdade, (exercício!!!) para todo $(x_1, x_2) \in \mathcal{X}$,

- $\theta|X_1 = x_1, X_2 = x_2 \sim \theta|X_1 + X_2 = x_1 + x_2$

- No exemplo 2, de modo similar,

- $\theta|X_1 = \dots = X_8 = X_{10} = 0, X_9 = 1 \sim \theta|\sum_{i=1}^{10} X_i = 1$

Suficiência

- 3) **Suficiência**
- No exemplo 1, note que (exercício !!!),
- $\theta|X_1 = 0, X_2 = 1 \sim \theta|X_1 + X_2 = 1$
- Na verdade, (exercício!!!) para todo $(x_1, x_2) \in \mathcal{X}$,
- $\theta|X_1 = x_1, X_2 = x_2 \sim \theta|X_1 + X_2 = x_1 + x_2$
- No exemplo 2, de modo similar,
- $\theta|X_1 = \dots = X_8 = X_{10} = 0, X_9 = 1 \sim \theta|\sum_{i=1}^{10} X_i = 1$

Suficiência

- **Suficiência:** Estatística Suficiente preserva toda a informação relevante da amostra sobre θ . É razoável imaginar que a inferência baseada na informação da amostra X coincida com a inferência baseada na informação ("parcial") do valor da estatística suficiente $T(X)$.
- Como a inferência é A distribuição a posteriori para θ , parece razoável a seguinte definição de suficiência:
- **(Suficiência Bayesiana)** Uma estatística T é suficiente para θ se, para toda priori para θ e para todo $x \in \mathcal{X}$,

$$\theta \mid T(X) = T(x) \sim \theta \mid X = x$$

Suficiência

- **Suficiência:** Estatística Suficiente preserva toda a informação relevante da amostra sobre θ . É razoável imaginar que a inferência baseada na informação da amostra X coincida com a inferência baseada na informação ("parcial") do valor da estatística suficiente $T(X)$.
- Como a inferência é A distribuição a posteriori para θ , parece razoável a seguinte definição de suficiência:
- **(Suficiência Bayesiana)** Uma estatística T é suficiente para θ se, para toda priori para θ e para todo $x \in \mathcal{X}$,

$$\theta \mid T(X) = T(x) \sim \theta \mid X = x$$

Suficiência

- **Suficiência:** Estatística Suficiente preserva toda a informação relevante da amostra sobre θ . É razoável imaginar que a inferência baseada na informação da amostra X coincida com a inferência baseada na informação ("parcial") do valor da estatística suficiente $T(X)$.
- Como a inferência é A distribuição a posteriori para θ , parece razoável a seguinte definição de suficiência:
- (Suficiência Bayesiana) Uma estatística T é suficiente para θ se, para toda priori para θ e para todo $x \in \mathcal{X}$,

$$\theta \mid T(X) = T(x) \sim \theta \mid X = x$$

Suficiência

- **Suficiência:** Estatística Suficiente preserva toda a informação relevante da amostra sobre θ . É razoável imaginar que a inferência baseada na informação da amostra X coincida com a inferência baseada na informação ("parcial") do valor da estatística suficiente $T(X)$.
- Como a inferência é A distribuição a posteriori para θ , parece razoável a seguinte definição de suficiência:
- **(Suficiência Bayesiana)** Uma estatística T é suficiente para θ se, para toda priori para θ e para todo $x \in \mathcal{X}$,

$$\theta \mid T(X) = T(x) \sim \theta \mid X = x$$

Suficiência

- **Suficiência:** Estatística Suficiente preserva toda a informação relevante da amostra sobre θ . É razoável imaginar que a inferência baseada na informação da amostra X coincida com a inferência baseada na informação ("parcial") do valor da estatística suficiente $T(X)$.
- Como a inferência é A distribuição a posteriori para θ , parece razoável a seguinte definição de suficiência:
- **(Suficiência Bayesiana)** Uma estatística T é suficiente para θ se, para toda priori para θ e para todo $x \in \mathcal{X}$,

$$\theta \mid T(X) = T(x) \sim \theta \mid X = x$$

Suficiência

- Exemplo 1: $X = (X_1, \dots, X_n)$ AAS do modelo Bernoulli (θ).
Seja $T(X) = \sum_{i=1}^n X_i$. Para $x = (x_1, \dots, x_n) \in \{0, 1\}^n$,
- $f(\theta|x) \propto \mathbb{P}(X = x|\theta) f(\theta) = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} f(\theta)$
- Além disso, temos que
- $f(\theta | \sum_{i=1}^n X_i = \sum_{i=1}^n x_i) \propto \mathbb{P}(\sum_{i=1}^n X_i = \sum_{i=1}^n x_i | \theta) f(\theta) \propto$
- $\propto \binom{n}{\sum_{i=1}^n x_i} \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} f(\theta) \Rightarrow$
- $\Rightarrow f(\theta | (T(X) = T(x))) \propto \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} f(\theta)$
- Como para todo x , $\theta | T(X) = T(x) \sim \theta | X = x$, resulta que $T(X) = \sum_{i=1}^n X_i$ é suficiente para θ .

Suficiência

- Exemplo 1: $X = (X_1, \dots, X_n)$ AAS do modelo Bernoulli (θ).
Seja $T(X) = \sum_{i=1}^n X_i$. Para $x = (x_1, \dots, x_n) \in \{0, 1\}^n$,
- $f(\theta|x) \propto \mathbb{P}(X = x|\theta) f(\theta) = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} f(\theta)$
- Além disso, temos que
- $f(\theta | \sum_{i=1}^n X_i = \sum_{i=1}^n x_i) \propto \mathbb{P}(\sum_{i=1}^n X_i = \sum_{i=1}^n x_i | \theta) f(\theta) \propto$
- $\propto \binom{n}{\sum_{i=1}^n x_i} \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} f(\theta) \Rightarrow$
- $\Rightarrow f(\theta | (T(X) = T(x))) \propto \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} f(\theta)$
- Como para todo x , $\theta | T(X) = T(x) \sim \theta | X = x$, resulta que $T(X) = \sum_{i=1}^n X_i$ é suficiente para θ .

Suficiência

- Exemplo 1: $X = (X_1, \dots, X_n)$ AAS do modelo Bernoulli (θ).
Seja $T(X) = \sum_{i=1}^n X_i$. Para $x = (x_1, \dots, x_n) \in \{0, 1\}^n$,
- $f(\theta|x) \propto \mathbb{P}(X = x|\theta) f(\theta) = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} f(\theta)$
- Além disso, temos que
- $f(\theta|\sum_{i=1}^n X_i = \sum_{i=1}^n x_i) \propto \mathbb{P}(\sum_{i=1}^n X_i = \sum_{i=1}^n x_i|\theta) f(\theta) \propto$
- $\propto \binom{n}{\sum_{i=1}^n x_i} \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} f(\theta) \Rightarrow$
- $\Rightarrow f(\theta|(T(X) = T(x))) \propto \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} f(\theta)$
- Como para todo x , $\theta|T(X) = T(x) \sim \theta|X = x$, resulta que $T(X) = \sum_{i=1}^n X_i$ é suficiente para θ .

Suficiência

- Exemplo 1: $X = (X_1, \dots, X_n)$ AAS do modelo Bernoulli (θ).
Seja $T(X) = \sum_{i=1}^n X_i$. Para $x = (x_1, \dots, x_n) \in \{0, 1\}^n$,
- $f(\theta|x) \propto \mathbb{P}(X = x|\theta) f(\theta) = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} f(\theta)$
- Além disso, temos que
- $f(\theta|\sum_{i=1}^n X_i = \sum_{i=1}^n x_i) \propto \mathbb{P}(\sum_{i=1}^n X_i = \sum_{i=1}^n x_i|\theta) f(\theta) \propto$
- $\propto \binom{n}{\sum_{i=1}^n x_i} \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} f(\theta) \Rightarrow$
- $\Rightarrow f(\theta|(T(X) = T(x))) \propto \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} f(\theta)$
- Como para todo x , $\theta|T(X) = T(x) \sim \theta|X = x$, resulta que $T(X) = \sum_{i=1}^n X_i$ é suficiente para θ .

Suficiência

- Exemplo 1: $X = (X_1, \dots, X_n)$ AAS do modelo Bernoulli (θ).
Seja $T(X) = \sum_{i=1}^n X_i$. Para $x = (x_1, \dots, x_n) \in \{0, 1\}^n$,
- $f(\theta|x) \propto \mathbb{P}(X = x|\theta) f(\theta) = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} f(\theta)$
- Além disso, temos que
- $f(\theta | \sum_{i=1}^n X_i = \sum_{i=1}^n x_i) \propto \mathbb{P}(\sum_{i=1}^n X_i = \sum_{i=1}^n x_i | \theta) f(\theta) \propto$
- $\propto \binom{n}{\sum_{i=1}^n x_i} \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} f(\theta) \Rightarrow$
- $\Rightarrow f(\theta | (T(X) = T(x))) \propto \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} f(\theta)$
- Como para todo x , $\theta | T(X) = T(x) \sim \theta | X = x$, resulta que $T(X) = \sum_{i=1}^n X_i$ é suficiente para θ .

Suficiência

- Exemplo 1: $X = (X_1, \dots, X_n)$ AAS do modelo Bernoulli (θ).
Seja $T(X) = \sum_{i=1}^n X_i$. Para $x = (x_1, \dots, x_n) \in \{0, 1\}^n$,
- $f(\theta|x) \propto \mathbb{P}(X = x|\theta) f(\theta) = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} f(\theta)$
- Além disso, temos que
- $f(\theta | \sum_{i=1}^n X_i = \sum_{i=1}^n x_i) \propto \mathbb{P}(\sum_{i=1}^n X_i = \sum_{i=1}^n x_i | \theta) f(\theta) \propto$
- $\propto \binom{n}{\sum_{i=1}^n x_i} \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} f(\theta) \Rightarrow$
- $\Rightarrow f(\theta | (T(X) = T(x))) \propto \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} f(\theta)$
- Como para todo x , $\theta | T(X) = T(x) \sim \theta | X = x$, resulta que $T(X) = \sum_{i=1}^n X_i$ é suficiente para θ .

Suficiência

- Exemplo 1: $X = (X_1, \dots, X_n)$ AAS do modelo Bernoulli (θ).
Seja $T(X) = \sum_{i=1}^n X_i$. Para $x = (x_1, \dots, x_n) \in \{0, 1\}^n$,
- $f(\theta|x) \propto \mathbb{P}(X = x|\theta) f(\theta) = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} f(\theta)$
- Além disso, temos que
- $f(\theta | \sum_{i=1}^n X_i = \sum_{i=1}^n x_i) \propto \mathbb{P}(\sum_{i=1}^n X_i = \sum_{i=1}^n x_i | \theta) f(\theta) \propto$
- $\propto \binom{n}{\sum_{i=1}^n x_i} \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} f(\theta) \Rightarrow$
- $\Rightarrow f(\theta | (T(X) = T(x))) \propto \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} f(\theta)$
- Como para todo x , $\theta | T(X) = T(x) \sim \theta | X = x$, resulta que $T(X) = \sum_{i=1}^n X_i$ é suficiente para θ .

Suficiência

- Exemplo 1: $X = (X_1, \dots, X_n)$ AAS do modelo Bernoulli (θ).
Seja $T(X) = \sum_{i=1}^n X_i$. Para $x = (x_1, \dots, x_n) \in \{0, 1\}^n$,
- $f(\theta|x) \propto \mathbb{P}(X = x|\theta) f(\theta) = \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} f(\theta)$
- Além disso, temos que
- $f(\theta | \sum_{i=1}^n X_i = \sum_{i=1}^n x_i) \propto \mathbb{P}(\sum_{i=1}^n X_i = \sum_{i=1}^n x_i | \theta) f(\theta) \propto$
- $\propto \binom{n}{\sum_{i=1}^n x_i} \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} f(\theta) \Rightarrow$
- $\Rightarrow f(\theta | (T(X) = T(x))) \propto \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} f(\theta)$
- Como para todo x , $\theta | T(X) = T(x) \sim \theta | X = x$, resulta que $T(X) = \sum_{i=1}^n X_i$ é suficiente para θ .

Suficiência

- Exemplo 2: Seja $X = (X_1, \dots, X_n)$ AAS do modelo $\text{Exp}(\theta)$.
Seja $T(X) = \sum_{i=1}^n X_i$. Para $x = (x_1, \dots, x_n) \in \mathbb{R}_+^n$,
- $f(\theta|x) \propto f(x|\theta) f(\theta) = \theta^n e^{-\theta \sum_{i=1}^n x_i} f(\theta)$
- Além disso, temos que
- $f(\theta | \sum_{i=1}^n X_i = \sum_{i=1}^n x_i) \propto f(\sum_{i=1}^n x_i | \theta) f(\theta) \propto$
- $\propto \frac{\theta^n}{\Gamma(n)} (\sum_{i=1}^n x_i)^{n-1} e^{-\theta \sum_{i=1}^n x_i} f(\theta) \Rightarrow$
- $\Rightarrow f(\theta | (T(X) = T(x))) \propto \theta^n e^{-\theta \sum_{i=1}^n x_i} f(\theta)$
- Como para todo x , $\theta | T(X) = T(x) \sim \theta | X = x$, resulta que $T(X) = \sum_{i=1}^n X_i$ é suficiente para θ .

Suficiência

- Exemplo 2: Seja $X = (X_1, \dots, X_n)$ AAS do modelo $\text{Exp}(\theta)$.
Seja $T(X) = \sum_{i=1}^n X_i$. Para $x = (x_1, \dots, x_n) \in \mathbb{R}_+^n$,

- $f(\theta|x) \propto f(x|\theta) f(\theta) = \theta^n e^{-\theta \sum_{i=1}^n x_i} f(\theta)$

- Além disso, temos que

- $f(\theta | \sum_{i=1}^n X_i = \sum_{i=1}^n x_i) \propto f(\sum_{i=1}^n x_i | \theta) f(\theta) \propto$

- $\propto \frac{\theta^n}{\Gamma(n)} (\sum_{i=1}^n x_i)^{n-1} e^{-\theta \sum_{i=1}^n x_i} f(\theta) \Rightarrow$

- $\Rightarrow f(\theta | (T(X) = T(x))) \propto \theta^n e^{-\theta \sum_{i=1}^n x_i} f(\theta)$

- Como para todo x , $\theta | T(X) = T(x) \sim \theta | X = x$, resulta que $T(X) = \sum_{i=1}^n X_i$ é suficiente para θ .

Suficiência

- Exemplo 2: Seja $X = (X_1, \dots, X_n)$ AAS do modelo $\text{Exp}(\theta)$.
Seja $T(X) = \sum_{i=1}^n X_i$. Para $x = (x_1, \dots, x_n) \in \mathbb{R}_+^n$,

- $f(\theta|x) \propto f(x|\theta) f(\theta) = \theta^n e^{-\theta \sum_{i=1}^n x_i} f(\theta)$

- Além disso, temos que

- $f(\theta | \sum_{i=1}^n X_i = \sum_{i=1}^n x_i) \propto f(\sum_{i=1}^n x_i | \theta) f(\theta) \propto$

- $\propto \frac{\theta^n}{\Gamma(n)} (\sum_{i=1}^n x_i)^{n-1} e^{-\theta \sum_{i=1}^n x_i} f(\theta) \Rightarrow$

- $\Rightarrow f(\theta | (T(X) = T(x))) \propto \theta^n e^{-\theta \sum_{i=1}^n x_i} f(\theta)$

- Como para todo x , $\theta | T(X) = T(x) \sim \theta | X = x$, resulta que $T(X) = \sum_{i=1}^n X_i$ é suficiente para θ .

Suficiência

- Exemplo 2: Seja $X = (X_1, \dots, X_n)$ AAS do modelo $\text{Exp}(\theta)$.
Seja $T(X) = \sum_{i=1}^n X_i$. Para $x = (x_1, \dots, x_n) \in \mathbb{R}_+^n$,

- $f(\theta|x) \propto f(x|\theta) f(\theta) = \theta^n e^{-\theta \sum_{i=1}^n x_i} f(\theta)$

- Além disso, temos que

- $f(\theta | \sum_{i=1}^n X_i = \sum_{i=1}^n x_i) \propto f(\sum_{i=1}^n x_i | \theta) f(\theta) \propto$

- $\propto \frac{\theta^n}{\Gamma(n)} (\sum_{i=1}^n x_i)^{n-1} e^{-\theta \sum_{i=1}^n x_i} f(\theta) \Rightarrow$

- $\Rightarrow f(\theta | (T(X) = T(x))) \propto \theta^n e^{-\theta \sum_{i=1}^n x_i} f(\theta)$

- Como para todo x , $\theta | T(X) = T(x) \sim \theta | X = x$, resulta que $T(X) = \sum_{i=1}^n X_i$ é suficiente para θ .

Suficiência

- Exemplo 2: Seja $X = (X_1, \dots, X_n)$ AAS do modelo $\text{Exp}(\theta)$.
Seja $T(X) = \sum_{i=1}^n X_i$. Para $x = (x_1, \dots, x_n) \in \mathbb{R}_+^n$,

- $f(\theta|x) \propto f(x|\theta) f(\theta) = \theta^n e^{-\theta \sum_{i=1}^n x_i} f(\theta)$

- Além disso, temos que

- $f(\theta | \sum_{i=1}^n X_i = \sum_{i=1}^n x_i) \propto f(\sum_{i=1}^n x_i | \theta) f(\theta) \propto$

- $\propto \frac{\theta^n}{\Gamma(n)} (\sum_{i=1}^n x_i)^{n-1} e^{-\theta \sum_{i=1}^n x_i} f(\theta) \Rightarrow$

- $\Rightarrow f(\theta | (T(X) = T(x))) \propto \theta^n e^{-\theta \sum_{i=1}^n x_i} f(\theta)$

- Como para todo x , $\theta | T(X) = T(x) \sim \theta | X = x$, resulta que $T(X) = \sum_{i=1}^n X_i$ é suficiente para θ .

Suficiência

- Exemplo 2: Seja $X = (X_1, \dots, X_n)$ AAS do modelo $\text{Exp}(\theta)$.
Seja $T(X) = \sum_{i=1}^n X_i$. Para $x = (x_1, \dots, x_n) \in \mathbb{R}_+^n$,

- $f(\theta|x) \propto f(x|\theta) f(\theta) = \theta^n e^{-\theta \sum_{i=1}^n x_i} f(\theta)$

- Além disso, temos que

- $f(\theta | \sum_{i=1}^n X_i = \sum_{i=1}^n x_i) \propto f(\sum_{i=1}^n x_i | \theta) f(\theta) \propto$

- $\propto \frac{\theta^n}{\Gamma(n)} \left(\sum_{i=1}^n x_i \right)^{n-1} e^{-\theta \sum_{i=1}^n x_i} f(\theta) \Rightarrow$

- $\Rightarrow f(\theta | (T(X) = T(x))) \propto \theta^n e^{-\theta \sum_{i=1}^n x_i} f(\theta)$

- Como para todo x , $\theta | T(X) = T(x) \sim \theta | X = x$, resulta que $T(X) = \sum_{i=1}^n X_i$ é suficiente para θ .

Suficiência

- Exemplo 2: Seja $X = (X_1, \dots, X_n)$ AAS do modelo $\text{Exp}(\theta)$.
Seja $T(X) = \sum_{i=1}^n X_i$. Para $x = (x_1, \dots, x_n) \in \mathbb{R}_+^n$,

- $f(\theta|x) \propto f(x|\theta) f(\theta) = \theta^n e^{-\theta \sum_{i=1}^n x_i} f(\theta)$

- Além disso, temos que

- $f(\theta | \sum_{i=1}^n X_i = \sum_{i=1}^n x_i) \propto f(\sum_{i=1}^n x_i | \theta) f(\theta) \propto$

- $\propto \frac{\theta^n}{\Gamma(n)} \left(\sum_{i=1}^n x_i \right)^{n-1} e^{-\theta \sum_{i=1}^n x_i} f(\theta) \Rightarrow$

- $\Rightarrow f(\theta | (T(X) = T(x))) \propto \theta^n e^{-\theta \sum_{i=1}^n x_i} f(\theta)$

- Como para todo x , $\theta | T(X) = T(x) \sim \theta | X = x$, resulta que $T(X) = \sum_{i=1}^n X_i$ é suficiente para θ .

Suficiência

- Exemplo 2: Seja $X = (X_1, \dots, X_n)$ AAS do modelo $\text{Exp}(\theta)$.
Seja $T(X) = \sum_{i=1}^n X_i$. Para $x = (x_1, \dots, x_n) \in \mathbb{R}_+^n$,
- $f(\theta|x) \propto f(x|\theta) f(\theta) = \theta^n e^{-\theta \sum_{i=1}^n x_i} f(\theta)$
- Além disso, temos que
- $f(\theta | \sum_{i=1}^n X_i = \sum_{i=1}^n x_i) \propto f(\sum_{i=1}^n x_i | \theta) f(\theta) \propto$
- $\propto \frac{\theta^n}{\Gamma(n)} \left(\sum_{i=1}^n x_i \right)^{n-1} e^{-\theta \sum_{i=1}^n x_i} f(\theta) \Rightarrow$
- $\Rightarrow f(\theta | (T(X) = T(x))) \propto \theta^n e^{-\theta \sum_{i=1}^n x_i} f(\theta)$
- Como para todo x , $\theta | T(X) = T(x) \sim \theta | X = x$, resulta que $T(X) = \sum_{i=1}^n X_i$ é suficiente para θ .

Suficiência

- Comentários:
- Suficiência Clássica \Rightarrow Suficiência Bayesiana
- Há equivalência entre Suficiência Clássica e Suficiência Bayesiana nos casos dominados (para toda \mathbb{P}_θ com mesma medida σ -finita dominante).
- 4) Justificativa para adoção de modelos paramétricos:
o que é (significa) θ ? Por que AAS ?
Justificativa: **Permutabilidade** + **Condições adicionais**

Suficiência

- Comentários:
- Suficiência Clássica \Rightarrow Suficiência Bayesiana
- Há equivalência entre Suficiência Clássica e Suficiência Bayesiana nos casos dominados (para toda \mathbb{P}_θ com mesma medida σ -finita dominante).
- 4) Justificativa para adoção de modelos paramétricos:
o que é (significa) θ ? Por que AAS ?
Justificativa: Permutabilidade + Condições adicionais

Suficiência

- Comentários:
- Suficiência Clássica \Rightarrow Suficiência Bayesiana
- Há equivalência entre Suficiência Clássica e Suficiência Bayesiana nos casos dominados (para toda \mathbb{P}_θ com mesma medida σ -finita dominante).
- 4) Justificativa para adoção de modelos paramétricos:
o que é (significa) θ ? Por que AAS ?
Justificativa: Permutabilidade + Condições adicionais

Suficiência

- Comentários:
- Suficiência Clássica \Rightarrow Suficiência Bayesiana
- Há equivalência entre Suficiência Clássica e Suficiência Bayesiana nos casos dominados (para toda \mathbb{P}_θ com mesma medida σ -finita dominante).
- 4) Justificativa para adoção de modelos paramétricos:
o que é (significa) θ ? Por que AAS ?
Justificativa: Permutabilidade + Condições adicionais

Suficiência

- Comentários:
- Suficiência Clássica \Rightarrow Suficiência Bayesiana
- Há equivalência entre Suficiência Clássica e Suficiência Bayesiana nos casos dominados (para toda \mathbb{P}_θ com mesma medida σ -finita dominante).
- 4) Justificativa para adoção de modelos paramétricos:
o que é (significa) θ ? Por que AAS ?
Justificativa: **Permutabilidade** + **Condições adicionais**

Permutabilidade

- Permutabilidade: julgamento/opinião fundamental (sob a perspectiva bayesiana) acerca de quantidades observáveis (potenciais observações amostrais).
- Revela a "indistinguibilidade" entre as unidades amostrais quanto a uma variável/característica (resposta) desconhecida (sob apreciação por um indivíduo).
"Simetria" entre as variáveis/características associadas às unidades amostrais.
- Noção menos restritiva sobre quantidades observáveis que a noção de "variáveis IID".
- Por outro lado, traz/permite, sob certas condições, uma interpretação para o (a existência do) parâmetro θ bem como para a suposição de "variáveis IID".

Permutabilidade

- Permutabilidade: julgamento/opinião fundamental (sob a perspectiva bayesiana) acerca de quantidades observáveis (potenciais observações amostrais).
- Revela a "indistinguibilidade" entre as unidades amostrais quanto a uma variável/característica (resposta) desconhecida (sob apreciação por um indivíduo).
"Simetria" entre as variáveis/características associadas às unidades amostrais.
- Noção menos restritiva sobre quantidades observáveis que a noção de "variáveis IID".
- Por outro lado, traz/permite, sob certas condições, uma interpretação para o (a existência do) parâmetro θ bem como para a suposição de "variáveis IID".

Permutabilidade

- Permutabilidade: julgamento/opinião fundamental (sob a perspectiva bayesiana) acerca de quantidades observáveis (potenciais observações amostrais).
- Revela a "indistinguibilidade" entre as unidades amostrais quanto a uma variável/característica (resposta) desconhecida (sob apreciação por um indivíduo).
"Simetria" entre as variáveis/características associadas às unidades amostrais.
- Noção menos restritiva sobre quantidades observáveis que a noção de "variáveis IID".
- Por outro lado, traz/permite, sob certas condições, uma interpretação para o (a existência do) parâmetro θ bem como para a suposição de "variáveis IID".

Permutabilidade

- Permutabilidade: julgamento/opinião fundamental (sob a perspectiva bayesiana) acerca de quantidades observáveis (potenciais observações amostrais).
- Revela a "indistinguibilidade" entre as unidades amostrais quanto a uma variável/característica (resposta) desconhecida (sob apreciação por um indivíduo).
"Simetria" entre as variáveis/características associadas às unidades amostrais.
- Noção menos restritiva sobre quantidades observáveis que a noção de "variáveis IID".
- Por outro lado, traz/permite, sob certas condições, uma interpretação para o (a existência do) parâmetro θ bem como para a suposição de "variáveis IID".

Permutabilidade

- Permutabilidade: julgamento/opinião fundamental (sob a perspectiva bayesiana) acerca de quantidades observáveis (potenciais observações amostrais).
- Revela a "indistinguibilidade" entre as unidades amostrais quanto a uma variável/característica (resposta) desconhecida (sob apreciação por um indivíduo).
"Simetria" entre as variáveis/características associadas às unidades amostrais.
- Noção menos restritiva sobre quantidades observáveis que a noção de "variáveis IID".
- Por outro lado, traz/permite, sob certas condições, uma interpretação para o (a existência do) parâmetro θ bem como para a suposição de "variáveis IID".

Permutabilidade

- **DEFINIÇÃO :** Seja $X = (X_1, \dots, X_n)$ um vetor aleatório discreto. Dizemos que X_1, \dots, X_n são permutáveis (X é permutável ou \mathbb{P} é permutável) se para toda permutação dos índices $1, \dots, n$ (isto é, para toda $\pi : \{1, \dots, n\} \rightarrow \{1, \dots, n\}$ injetora) e para todo valor x_i , $i = 1, \dots, n$,
- $\mathbb{P}(X_{\pi(1)} = x_1, \dots, X_{\pi(n)} = x_n) = \mathbb{P}(X_1 = x_1, \dots, X_n = x_n)$
- Extensões "naturais" para o caso geral em termos de função de distribuição ou função densidade do vetor aleatório X .

Permutabilidade

- **DEFINIÇÃO :** Seja $X = (X_1, \dots, X_n)$ um vetor aleatório discreto. Dizemos que X_1, \dots, X_n são permutáveis (X é permutável ou \mathbb{P} é permutável) se para toda permutação dos índices $1, \dots, n$ (isto é, para toda $\pi : \{1, \dots, n\} \rightarrow \{1, \dots, n\}$ injetora) e para todo valor x_i , $i = 1, \dots, n$,
- $\mathbb{P}(X_{\pi(1)} = x_1, \dots, X_{\pi(n)} = x_n) = \mathbb{P}(X_1 = x_1, \dots, X_n = x_n)$
- Extensões "naturais" para o caso geral em termos de função de distribuição ou função densidade do vetor aleatório X .

Permutabilidade

- **DEFINIÇÃO :** Seja $X = (X_1, \dots, X_n)$ um vetor aleatório discreto. Dizemos que X_1, \dots, X_n são permutáveis (X é permutável ou \mathbb{P} é permutável) se para toda permutação dos índices $1, \dots, n$ (isto é, para toda $\pi : \{1, \dots, n\} \rightarrow \{1, \dots, n\}$ injetora) e para todo valor x_i , $i = 1, \dots, n$,
- $\mathbb{P}(X_{\pi(1)} = x_1, \dots, X_{\pi(n)} = x_n) = \mathbb{P}(X_1 = x_1, \dots, X_n = x_n)$
- Extensões "naturais" para o caso geral em termos de função de distribuição ou função densidade do vetor aleatório X .

Permutabilidade

- **DEFINIÇÃO :** Seja $X = (X_1, \dots, X_n)$ um vetor aleatório discreto. Dizemos que X_1, \dots, X_n são permutáveis (X é permutável ou \mathbb{P} é permutável) se para toda permutação dos índices $1, \dots, n$ (isto é, para toda $\pi : \{1, \dots, n\} \rightarrow \{1, \dots, n\}$ injetora) e para todo valor x_i , $i = 1, \dots, n$,
- $\mathbb{P}(X_{\pi(1)} = x_1, \dots, X_{\pi(n)} = x_n) = \mathbb{P}(X_1 = x_1, \dots, X_n = x_n)$
- Extensões "naturais" para o caso geral em termos de função de distribuição ou função densidade do vetor aleatório X .

Permutabilidade

- Exemplo 1: $X = (X_1, \dots, X_n)$ v. a. independentes e identicamente distribuídas Bernoulli (θ_0) , $\theta_0 \in (0, 1)$. Para $x_i = 0, 1$, $i = 1, \dots, n$, temos

$$\begin{aligned}\mathbb{P}(X_{\pi(1)} = x_1, \dots, X_{\pi(n)} = x_n) &= \prod_{i=1}^n \mathbb{P}(X_{\pi(i)} = x_i) = \\ &= \prod_{i=1}^n \mathbb{P}(X_i = x_i) = \theta_0^{\sum_{i=1}^n x_i} (1 - \theta_0)^{n - \sum_{i=1}^n x_i}\end{aligned}$$

- Exemplo 2: $X = (X_1, X_2)$ v. a. de Bernoulli com distribuição dada por: para $x_i = 0, 1$, $i = 1, 2$,

$$\mathbb{P}(X_1 = x_1, X_2 = x_2) = \frac{1}{3 \binom{2}{x_1+x_2}}. \text{ Permutando } X,$$

$$\mathbb{P}(X_2 = x_1, X_1 = x_2) = \frac{1}{3 \binom{2}{x_2+x_1}} =$$

$$= \frac{1}{3 \binom{2}{x_1+x_2}} = \mathbb{P}(X_1 = x_1, X_2 = x_2)$$

Permutabilidade

- Exemplo 1: $X = (X_1, \dots, X_n)$ v. a. independentes e identicamente distribuídas Bernoulli (θ_0) , $\theta_0 \in (0, 1)$. Para $x_i = 0, 1$, $i = 1, \dots, n$, temos

$$\begin{aligned}\mathbb{P}(X_{\pi(1)} = x_1, \dots, X_{\pi(n)} = x_n) &= \prod_{i=1}^n \mathbb{P}(X_{\pi(i)} = x_i) = \\ &= \prod_{i=1}^n \mathbb{P}(X_i = x_i) = \theta_0^{\sum_{i=1}^n x_i} (1 - \theta_0)^{n - \sum_{i=1}^n x_i}\end{aligned}$$

- Exemplo 2: $X = (X_1, X_2)$ v. a. de Bernoulli com distribuição dada por: para $x_i = 0, 1$, $i = 1, 2$,

$$\mathbb{P}(X_1 = x_1, X_2 = x_2) = \frac{1}{3 \binom{2}{x_1+x_2}}. \text{ Permutando } X,$$

$$\mathbb{P}(X_2 = x_1, X_1 = x_2) = \frac{1}{3 \binom{2}{x_2+x_1}} =$$

$$= \frac{1}{3 \binom{2}{x_1+x_2}} = \mathbb{P}(X_1 = x_1, X_2 = x_2)$$

Permutabilidade

- Exemplo 1: $X = (X_1, \dots, X_n)$ v. a. independentes e identicamente distribuídas Bernoulli (θ_0) , $\theta_0 \in (0, 1)$. Para $x_i = 0, 1$, $i = 1, \dots, n$, temos

$$\begin{aligned}\mathbb{P}(X_{\pi(1)} = x_1, \dots, X_{\pi(n)} = x_n) &= \prod_{i=1}^n \mathbb{P}(X_{\pi(i)} = x_i) = \\ &= \prod_{i=1}^n \mathbb{P}(X_i = x_i) = \theta_0^{\sum_{i=1}^n x_i} (1 - \theta_0)^{n - \sum_{i=1}^n x_i}\end{aligned}$$

- Exemplo 2: $X = (X_1, X_2)$ v. a. de Bernoulli com distribuição dada por: para $x_i = 0, 1$, $i = 1, 2$,

$$\mathbb{P}(X_1 = x_1, X_2 = x_2) = \frac{1}{3 \binom{2}{x_1+x_2}}. \text{ Permutando } X,$$

$$\mathbb{P}(X_2 = x_1, X_1 = x_2) = \frac{1}{3 \binom{2}{x_2+x_1}} =$$

$$= \frac{1}{3 \binom{2}{x_1+x_2}} = \mathbb{P}(X_1 = x_1, X_2 = x_2)$$

Permutabilidade

- Logo, X_1 e X_2 são permutáveis.
- Note que, no exemplo 2, $X_1 \sim X_2 \sim \text{Bernoulli}(\frac{1}{2})$. No entanto, X_1 e X_2 NÃO são independentes!!
- Alguns resultados:
- **Resultado 1:** Sejam X_1, \dots, X_n variáveis aleatórias IID. Então, X_1, \dots, X_n são permutáveis.
- Assim, todo vetor de variáveis IID é de variáveis permutáveis. Por outro lado, há vetores permutáveis cujas componentes não são independentes (ver Exemplo 2).

Permutabilidade

- Logo, X_1 e X_2 são permutáveis.
- Note que, no exemplo 2, $X_1 \sim X_2 \sim \text{Bernoulli}(\frac{1}{2})$. No entanto, X_1 e X_2 NÃO são independentes!!
- Alguns resultados:
- **Resultado 1:** Sejam X_1, \dots, X_n variáveis aleatórias IID. Então, X_1, \dots, X_n são permutáveis.
- Assim, todo vetor de variáveis IID é de variáveis permutáveis. Por outro lado, há vetores permutáveis cujas componentes não são independentes (ver Exemplo 2).

Permutabilidade

- Logo, X_1 e X_2 são permutáveis.
- Note que, no exemplo 2, $X_1 \sim X_2 \sim \text{Bernoulli}(\frac{1}{2})$. No entanto, X_1 e X_2 NÃO são independentes!!
- Alguns resultados:
- **Resultado 1:** Sejam X_1, \dots, X_n variáveis aleatórias IID. Então, X_1, \dots, X_n são permutáveis.
- Assim, todo vetor de variáveis IID é de variáveis permutáveis. Por outro lado, há vetores permutáveis cujas componentes não são independentes (ver Exemplo 2).

Permutabilidade

- Logo, X_1 e X_2 são permutáveis.
- Note que, no exemplo 2, $X_1 \sim X_2 \sim \text{Bernoulli}(\frac{1}{2})$. No entanto, X_1 e X_2 NÃO são independentes!!
- Alguns resultados:
- **Resultado 1:** Sejam X_1, \dots, X_n variáveis aleatórias IID. Então, X_1, \dots, X_n são permutáveis.
- Assim, todo vetor de variáveis IID é de variáveis permutáveis. Por outro lado, há vetores permutáveis cujas componentes não são independentes (ver Exemplo 2).

Permutabilidade

- Logo, X_1 e X_2 são permutáveis.
- Note que, no exemplo 2, $X_1 \sim X_2 \sim \text{Bernoulli}(\frac{1}{2})$. No entanto, X_1 e X_2 NÃO são independentes!!
- Alguns resultados:
- **Resultado 1:** Sejam X_1, \dots, X_n variáveis aleatórias IID. Então, X_1, \dots, X_n são permutáveis.
- Assim, todo vetor de variáveis IID é de variáveis permutáveis. Por outro lado, há vetores permutáveis cujas componentes não são independentes (ver Exemplo 2).

Permutabilidade

- Logo, X_1 e X_2 são permutáveis.
- Note que, no exemplo 2, $X_1 \sim X_2 \sim \text{Bernoulli}(\frac{1}{2})$. No entanto, X_1 e X_2 NÃO são independentes!!
- Alguns resultados:
- **Resultado 1:** Sejam X_1, \dots, X_n variáveis aleatórias IID. Então, X_1, \dots, X_n são permutáveis.
- Assim, todo vetor de variáveis IID é de variáveis permutáveis. Por outro lado, há vetores permutáveis cujas componentes não são independentes (ver Exemplo 2).

Permutabilidade

- **Resultado 2:** Sejam X_1, \dots, X_n variáveis aleatórias permutáveis. Então, X_1, \dots, X_n são identicamente distribuídas.
- Assim, todo vetor de variáveis permutáveis é de variáveis identicamente distribuídas (ID). Por outro lado, há vetores de variáveis ID que não são permutáveis.
- Exemplo: Seja (X_1, X_2) um vetor aleatório com distribuição de probabilidade dada por

$$\begin{aligned}\mathbb{P}(X_1 = -1, X_2 = 0) &= \mathbb{P}(X_1 = 0, X_2 = 1) = \\ &= \mathbb{P}(X_1 = 1, X_2 = -1) = \frac{1}{3}\end{aligned}$$

Note que $X_1 \sim X_2 \sim U\{-1, 0, 1\}$. No entanto,

$$\mathbb{P}(X_1 = -1, X_2 = 0) \neq \mathbb{P}(X_1 = 0, X_2 = -1)$$

Permutabilidade

- **Resultado 2:** Sejam X_1, \dots, X_n variáveis aleatórias permutáveis. Então, X_1, \dots, X_n são identicamente distribuídas.
- Assim, todo vetor de variáveis permutáveis é de variáveis identicamente distribuídas (ID). Por outro lado, há vetores de variáveis ID que não são permutáveis.
- Exemplo: Seja (X_1, X_2) um vetor aleatório com distribuição de probabilidade dada por

$$\begin{aligned}\mathbb{P}(X_1 = -1, X_2 = 0) &= \mathbb{P}(X_1 = 0, X_2 = 1) = \\ &= \mathbb{P}(X_1 = 1, X_2 = -1) = \frac{1}{3}\end{aligned}$$

Note que $X_1 \sim X_2 \sim U\{-1, 0, 1\}$. No entanto,

$$\mathbb{P}(X_1 = -1, X_2 = 0) \neq \mathbb{P}(X_1 = 0, X_2 = -1)$$

Permutabilidade

- **Resultado 2:** Sejam X_1, \dots, X_n variáveis aleatórias permutáveis. Então, X_1, \dots, X_n são identicamente distribuídas.
- Assim, todo vetor de variáveis permutáveis é de variáveis identicamente distribuídas (ID). Por outro lado, há vetores de variáveis ID que não são permutáveis.
- Exemplo: Seja (X_1, X_2) um vetor aleatório com distribuição de probabilidade dada por

$$\begin{aligned}\mathbb{P}(X_1 = -1, X_2 = 0) &= \mathbb{P}(X_1 = 0, X_2 = 1) = \\ &= \mathbb{P}(X_1 = 1, X_2 = -1) = \frac{1}{3}\end{aligned}$$

Note que $X_1 \sim X_2 \sim U\{-1, 0, 1\}$. No entanto,

$$\mathbb{P}(X_1 = -1, X_2 = 0) \neq \mathbb{P}(X_1 = 0, X_2 = -1)$$

Permutabilidade

- **Resultado 2:** Sejam X_1, \dots, X_n variáveis aleatórias permutáveis. Então, X_1, \dots, X_n são identicamente distribuídas.
- Assim, todo vetor de variáveis permutáveis é de variáveis identicamente distribuídas (ID). Por outro lado, há vetores de variáveis ID que não são permutáveis.
- Exemplo: Seja (X_1, X_2) um vetor aleatório com distribuição de probabilidade dada por

$$\begin{aligned}\mathbb{P}(X_1 = -1, X_2 = 0) &= \mathbb{P}(X_1 = 0, X_2 = 1) = \\ &= \mathbb{P}(X_1 = 1, X_2 = -1) = \frac{1}{3}\end{aligned}$$

Note que $X_1 \sim X_2 \sim U\{-1, 0, 1\}$. No entanto,

$$\mathbb{P}(X_1 = -1, X_2 = 0) \neq \mathbb{P}(X_1 = 0, X_2 = -1)$$

Permutabilidade

- Resumidamente:
- IID \Rightarrow Permutabilidade \Rightarrow ID
- **Resultado 3:** Seja $X = (X_1, \dots, X_n)$ vetor aleatório de variáveis aleatórias permutáveis. Então, qualquer marginal k -dimensional, $k < n$, de X é também permutável.
- No que segue, estendemos a definição de vetor permutável para sequências de variáveis aleatórias.

Permutabilidade

- Resumidamente:
- IID \Rightarrow Permutabilidade \Rightarrow ID
- **Resultado 3:** Seja $X = (X_1, \dots, X_n)$ vetor aleatório de variáveis aleatórias permutáveis. Então, qualquer marginal k -dimensional, $k < n$, de X é também permutável.
- No que segue, estendemos a definição de vetor permutável para sequências de variáveis aleatórias.

Permutabilidade

- Resumidamente:
- **IID \Rightarrow Permutabilidade \Rightarrow ID**
- **Resultado 3:** Seja $X = (X_1, \dots, X_n)$ vetor aleatório de variáveis aleatórias permutáveis. Então, qualquer marginal k -dimensional, $k < n$, de X é também permutável.
- No que segue, estendemos a definição de vetor permutável para sequências de variáveis aleatórias.

Permutabilidade

- Resumidamente:
- IID \Rightarrow **Permutabilidade** \Rightarrow ID
- **Resultado 3:** Seja $X = (X_1, \dots, X_n)$ vetor aleatório de variáveis aleatórias permutáveis. Então, qualquer marginal k -dimensional, $k < n$, de X é também permutável.
- No que segue, estendemos a definição de vetor permutável para sequências de variáveis aleatórias.

Permutabilidade

- Resumidamente:
- IID \Rightarrow **Permutabilidade** \Rightarrow ID
- **Resultado 3:** Seja $X = (X_1, \dots, X_n)$ vetor aleatório de variáveis aleatórias permutáveis. Então, qualquer marginal k -dimensional, $k < n$, de X é também permutável.
- No que segue, estendemos a definição de vetor permutável para sequências de variáveis aleatórias.

Permutabilidade

- **DEFINIÇÃO:** Uma sequência de variáveis aleatórias $(X_n)_{n \geq 1}$ é de variáveis permutáveis (ou o processo estocástico $(X_n)_{n \geq 1}$ é permutável) se, para todo $n \in \mathbb{N}^*$, X_1, \dots, X_n são permutáveis.
- Exemplo 1: $(X_n)_{n \geq 1}$ sequência de variáveis IID Bernoulli (θ) . É fácil ver que $(X_n)_{n \geq 1}$ é permutável.
- Exemplo 2: $(X_n)_{n \geq 1}$ sequência de variáveis de Bernoulli cuja distribuição marginal de X_1, \dots, X_n , para cada $n \geq 1$, é dada por: para $x_i = 0, 1, i = 1, \dots, n$,

$$\mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = \frac{1}{(n+1) \binom{n}{\sum_{i=1}^n x_i}}$$

$(X_n)_{n \geq 1}$ é permutável. Note que as variáveis X_1, X_2, \dots NÃO são independentes.

Permutabilidade

- **DEFINIÇÃO:** Uma sequência de variáveis aleatórias $(X_n)_{n \geq 1}$ é de variáveis permutáveis (ou o processo estocástico $(X_n)_{n \geq 1}$ é permutável) se, para todo $n \in \mathbb{N}^*$, X_1, \dots, X_n são permutáveis.
- Exemplo 1: $(X_n)_{n \geq 1}$ sequência de variáveis IID Bernoulli (θ). É fácil ver que $(X_n)_{n \geq 1}$ é permutável.
- Exemplo 2: $(X_n)_{n \geq 1}$ sequência de variáveis de Bernoulli cuja distribuição marginal de X_1, \dots, X_n , para cada $n \geq 1$, é dada por: para $x_i = 0, 1, i = 1, \dots, n$,

$$\mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = \frac{1}{(n+1) \binom{n}{\sum_{i=1}^n x_i}}$$

$(X_n)_{n \geq 1}$ é permutável. Note que as variáveis X_1, X_2, \dots NÃO são independentes.

Permutabilidade

- **DEFINIÇÃO:** Uma sequência de variáveis aleatórias $(X_n)_{n \geq 1}$ é de variáveis permutáveis (ou o processo estocástico $(X_n)_{n \geq 1}$ é permutável) se, para todo $n \in \mathbb{N}^*$, X_1, \dots, X_n são permutáveis.
- Exemplo 1: $(X_n)_{n \geq 1}$ sequência de variáveis IID Bernoulli (θ) . É fácil ver que $(X_n)_{n \geq 1}$ é permutável.
- Exemplo 2: $(X_n)_{n \geq 1}$ sequência de variáveis de Bernoulli cuja distribuição marginal de X_1, \dots, X_n , para cada $n \geq 1$, é dada por: para $x_i = 0, 1, i = 1, \dots, n$,

$$\mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = \frac{1}{(n+1) \binom{n}{\sum_{i=1}^n x_i}}$$

$(X_n)_{n \geq 1}$ é permutável. Note que as variáveis X_1, X_2, \dots NÃO são independentes.

Permutabilidade

- **DEFINIÇÃO:** Uma sequência de variáveis aleatórias $(X_n)_{n \geq 1}$ é de variáveis permutáveis (ou o processo estocástico $(X_n)_{n \geq 1}$ é permutável) se, para todo $n \in \mathbb{N}^*$, X_1, \dots, X_n são permutáveis.
- Exemplo 1: $(X_n)_{n \geq 1}$ sequência de variáveis IID Bernoulli (θ) . É fácil ver que $(X_n)_{n \geq 1}$ é permutável.
- Exemplo 2: $(X_n)_{n \geq 1}$ sequência de variáveis de Bernoulli cuja distribuição marginal de X_1, \dots, X_n , para cada $n \geq 1$, é dada por: para $x_i = 0, 1, i = 1, \dots, n$,

$$\mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = \frac{1}{(n+1) \binom{n}{\sum_{i=1}^n x_i}}$$

$(X_n)_{n \geq 1}$ é permutável. Note que as variáveis X_1, X_2, \dots NÃO são independentes.

Permutabilidade

● Teorema da Representação de De Finetti (variáveis 0-1)

Seja $(X_n)_{n \geq 1}$ uma sequência de variáveis **permutáveis de Bernoulli**. Então, existe uma (única) medida de probabilidade μ tal que $\mu([0, 1]) = 1$ e tal que, para todo $n \in \mathbb{N}^*$, a marginal de X_1, \dots, X_n é dada por: para $x_i = 0, 1$, $i = 1, \dots, n$,

$$\mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = \int_{[0,1]} \theta^{\sum_{i=1}^n x_i} (1-\theta)^{n-\sum_{i=1}^n x_i} d\mu(\theta)$$

Além disso,

$$\bar{X}_n = \frac{\sum_{i=1}^n X_i}{n} \xrightarrow{q.c.} \theta, \text{ onde } \theta \text{ é distribuído segundo } \mu.$$

Permutabilidade

● Teorema da Representação de De Finetti (variáveis 0-1)

Seja $(X_n)_{n \geq 1}$ uma sequência de variáveis **permutáveis de Bernoulli**. Então, existe uma (única) medida de probabilidade μ tal que $\mu([0, 1]) = 1$ e tal que, para todo $n \in \mathbb{N}^*$, a marginal de X_1, \dots, X_n é dada por: para $x_i = 0, 1$, $i = 1, \dots, n$,

$$\mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = \int_{[0,1]} \theta^{\sum_{i=1}^n x_i} (1-\theta)^{n-\sum_{i=1}^n x_i} d\mu(\theta)$$

Além disso,

$$\bar{X}_n = \frac{\sum_{i=1}^n X_i}{n} \xrightarrow{q.c.} \theta, \text{ onde } \theta \text{ é distribuído segundo } \mu.$$

Permutabilidade

- No exemplo 1, $(X_n)_{n \geq 1}$ é uma sequência de variáveis IID Bernoulli (θ_0) . Para cada $n \geq 1$, e $x_i = 0, 1$, $i = 1, \dots, n$, temos que

$$\begin{aligned} \mathbb{P}(X_1 = x_1, \dots, X_n = x_n) &= \theta_0^{\sum_{i=1}^n x_i} (1 - \theta_0)^{n - \sum_{i=1}^n x_i} = \\ &= \int_{[0,1]} \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} d\mu_0(\theta) , \end{aligned}$$

onde μ_0 é a medida de probabilidade concentrada (degenerada) em $\{\theta_0\}$ ($\mathbb{P}(\theta = \theta_0) = 1$).

Permutabilidade

- No exemplo 1, $(X_n)_{n \geq 1}$ é uma sequência de variáveis IID Bernoulli (θ_0) . Para cada $n \geq 1$, e $x_i = 0, 1, i = 1, \dots, n$, temos que

$$\begin{aligned} \mathbb{P}(X_1 = x_1, \dots, X_n = x_n) &= \theta_0^{\sum_{i=1}^n x_i} (1 - \theta_0)^{n - \sum_{i=1}^n x_i} = \\ &= \int_{[0,1]} \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} d\mu_0(\theta) , \end{aligned}$$

onde μ_0 é a medida de probabilidade concentrada (degenerada) em $\{\theta_0\}$ ($\mathbb{P}(\theta = \theta_0) = 1$).

Permutabilidade

- Voltando ao exemplo 2, onde $(X_n)_{n \geq 1}$ é uma sequência de variáveis de Bernoulli cuja distribuição marginal de X_1, \dots, X_n , para cada $n \geq 1$, é dada por: para $x_i = 0, 1$, $i = 1, \dots, n$,

$$\mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = \frac{1}{(n+1) \binom{n}{\sum_{i=1}^n x_i}}$$

Note que, para cada $n \geq 1$, e $x_i = 0, 1$, $i = 1, \dots, n$,

$$\int_0^1 \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} d\theta = \frac{1}{(n+1) \binom{n}{\sum_{i=1}^n x_i}}.$$

Assim, μ corresponde à distribuição uniforme sobre $[0, 1]$. Isto é, $\theta \sim U(0, 1)$.

Permutabilidade

- Voltando ao exemplo 2, onde $(X_n)_{n \geq 1}$ é uma sequência de variáveis de Bernoulli cuja distribuição marginal de X_1, \dots, X_n , para cada $n \geq 1$, é dada por: para $x_i = 0, 1$, $i = 1, \dots, n$,

$$\mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = \frac{1}{(n+1) \binom{n}{\sum_{i=1}^n x_i}}$$

Note que, para cada $n \geq 1$, e $x_i = 0, 1$, $i = 1, \dots, n$,

$$\int_0^1 \theta^{\sum_{i=1}^n x_i} (1 - \theta)^{n - \sum_{i=1}^n x_i} d\theta = \frac{1}{(n+1) \binom{n}{\sum_{i=1}^n x_i}}.$$

Assim, μ corresponde à distribuição uniforme sobre $[0, 1]$. Isto é, $\theta \sim U(0, 1)$.

Permutabilidade

- Comentários:
- A medida μ que aparece no Teorema da Representação é denominada medida de De Finetti.
- Do Teorema da Representação, θ é o **limite** da sequência de frequências relativas $(\bar{X}_n)_{n \geq 1}$. Num certo sentido, θ é não-observável.
- Inferência sobre θ

X

Inferência para coleções finitas de variáveis de $(X_n)_{n \geq 1}$ (inferência preditiva). Voltaremos a esse ponto mais adiante.

Permutabilidade

- Comentários:

- A medida μ que aparece no Teorema da Representação é denominada medida de De Finetti.
- Do Teorema da Representação, θ é o **limite** da sequência de frequências relativas $(\bar{X}_n)_{n \geq 1}$. Num certo sentido, θ é não-observável.
- Inferência sobre θ

X

Inferência para coleções finitas de variáveis de $(X_n)_{n \geq 1}$ (inferência preditiva). Voltaremos a esse ponto mais adiante.

Permutabilidade

- Comentários:
- A medida μ que aparece no Teorema da Representação é denominada medida de De Finetti.
- Do Teorema da Representação, θ é o **limite** da sequência de frequências relativas $(\bar{X}_n)_{n \geq 1}$. Num certo sentido, θ é não-observável.
- Inferência sobre θ

X

Inferência para coleções finitas de variáveis de $(X_n)_{n \geq 1}$ (inferência preditiva). Voltaremos a esse ponto mais adiante.

Permutabilidade

- Comentários:
- A medida μ que aparece no Teorema da Representação é denominada medida de De Finetti.
- Do Teorema da Representação, θ é o **limite** da sequência de frequências relativas $(\bar{X}_n)_{n \geq 1}$. Num certo sentido, θ é não-observável.

- Inferência sobre θ

X

Inferência para coleções finitas de variáveis de $(X_n)_{n \geq 1}$ (inferência preditiva). Voltaremos a esse ponto mais adiante.

Permutabilidade

- Comentários:
- A medida μ que aparece no Teorema da Representação é denominada medida de De Finetti.
- Do Teorema da Representação, θ é o **limite** da sequência de frequências relativas $(\bar{X}_n)_{n \geq 1}$. Num certo sentido, θ é não-observável.
- Inferência sobre θ

X

Inferência para coleções finitas de variáveis de $(X_n)_{n \geq 1}$ (inferência preditiva). Voltaremos a esse ponto mais adiante.

Permutabilidade

- O Teorema da Representação **não** se aplica a vetores permutáveis **finito-dimensionais**. Por exemplo, seja $X = (X_1, X_2)$ vetor aleatório com distribuição uniforme em $\{(1, 1), (1, 0), (0, 1)\}$. Para que a distribuição de X admita a representação integral do Teorema, deveríamos ter:

$$\mathbb{P}(X_1 = 0, X_2 = 0) = \int_{[0,1]} (1 - \theta)^2 d\mu(\theta) = \mathbb{E}[(1 - \theta)^2] = 0,$$

donde $\mathbb{P}(\theta = 1) = 1$ e, conseqüentemente,

$$\mathbb{P}(X_1 = 1, X_2 = 1) = 1 \text{ !!!!!!!!!!! (absurdo!!)}$$

- Teorema da Representação fornece condições para a consideração de AAS do modelo Bernoulli (θ).
- Extensões, fortalecimentos para outros modelos paramétricos (**teoremas tipo de De Finetti**). Exemplos:

Permutabilidade

- O Teorema da Representação **não** se aplica a vetores permutáveis **finito-dimensionais**. Por exemplo, seja $X = (X_1, X_2)$ vetor aleatório com distribuição uniforme em $\{(1, 1), (1, 0), (0, 1)\}$. Para que a distribuição de X admita a representação integral do Teorema, deveríamos ter:

$$\mathbb{P}(X_1 = 0, X_2 = 0) = \int_{[0,1]} (1 - \theta)^2 d\mu(\theta) = \mathbb{E}[(1 - \theta)^2] = 0,$$

donde $\mathbb{P}(\theta = 1) = 1$ e, conseqüentemente,

$$\mathbb{P}(X_1 = 1, X_2 = 1) = 1 \text{ !!!!!!!!!!! (absurdo!!)}$$

- Teorema da Representação fornece condições para a consideração de AAS do modelo Bernoulli (θ).
- Extensões, fortalecimentos para outros modelos paramétricos (**teoremas tipo de De Finetti**). Exemplos:

Permutabilidade

- O Teorema da Representação **não** se aplica a vetores permutáveis **finito-dimensionais**. Por exemplo, seja $X = (X_1, X_2)$ vetor aleatório com distribuição uniforme em $\{(1, 1), (1, 0), (0, 1)\}$. Para que a distribuição de X admita a representação integral do Teorema, deveríamos ter:

$$\mathbb{P}(X_1 = 0, X_2 = 0) = \int_{[0,1]} (1 - \theta)^2 d\mu(\theta) = \mathbb{E}[(1 - \theta)^2] = 0,$$

donde $\mathbb{P}(\theta = 1) = 1$ e, conseqüentemente,

$$\mathbb{P}(X_1 = 1, X_2 = 1) = 1 \text{ !!!!!!!!!!! (absurdo!!)}$$

- Teorema da Representação fornece condições para a consideração de AAS do modelo Bernoulli (θ).
- Extensões, fortalecimentos para outros modelos paramétricos (**teoremas tipo de De Finetti**). Exemplos:

Permutabilidade

- O Teorema da Representação **não** se aplica a vetores permutáveis **finito-dimensionais**. Por exemplo, seja $X = (X_1, X_2)$ vetor aleatório com distribuição uniforme em $\{(1, 1), (1, 0), (0, 1)\}$. Para que a distribuição de X admita a representação integral do Teorema, deveríamos ter:

$$\mathbb{P}(X_1 = 0, X_2 = 0) = \int_{[0,1]} (1 - \theta)^2 d\mu(\theta) = \mathbb{E}[(1 - \theta)^2] = 0,$$

donde $\mathbb{P}(\theta = 1) = 1$ e, conseqüentemente,

$$\mathbb{P}(X_1 = 1, X_2 = 1) = 1 \text{ !!!!!!!!!!! (absurdo!!)}$$

- Teorema da Representação fornece condições para a consideração de AAS do modelo Bernoulli (θ).
- Extensões, fortalecimentos para outros modelos paramétricos (**teoremas tipo de De Finetti**). Exemplos:

Permutabilidade

- Teorema:** Seja $(X_n)_{n \geq 1}$ uma sequência de variáveis **permutáveis** a valores em \mathbb{N} tal que, para todo $n \in \mathbb{N}^*$, $X_1, \dots, X_n | \sum_{i=1}^n X_i = t \sim \text{Multinomial}(t; (1/n, \dots, 1/n))$, isto é,

$$\mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = \frac{t!}{\prod_{i=1}^n x_i!} \left(\frac{1}{n}\right)^t \prod_{i=1}^n \mathbb{I}_{\mathbb{N}}(x_i) \mathbb{I}_{\{t\}}\left(\sum_{i=1}^n x_i\right)$$

Então, existe uma (única) medida de probabilidade μ tal que $\mu(\mathbb{R}_+) = 1$ e tal que, para todo $n \in \mathbb{N}^*$, a marginal de X_1, \dots, X_n é dada por: para $x_i = 0, 1, 2, \dots, i = 1, \dots, n$,

$$\mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = \int_{\mathbb{R}_+} \frac{e^{-n\theta} \theta^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n x_i!} d\mu(\theta)$$

Além disso, $\bar{X}_n = \frac{\sum_{i=1}^n X_i}{n} \xrightarrow{q.c.} \theta$, onde θ é distribuído segundo μ .

Permutabilidade

- Teorema:** Seja $(X_n)_{n \geq 1}$ uma sequência de variáveis **permutáveis** a valores em \mathbb{N} tal que, para todo $n \in \mathbb{N}^*$, $X_1, \dots, X_n | \sum_{i=1}^n X_i = t \sim \text{Multinomial}(t; (1/n, \dots, 1/n))$, isto é,

$$\mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = \frac{t!}{\prod_{i=1}^n x_i!} \left(\frac{1}{n}\right)^t \prod_{i=1}^n \mathbb{I}_{\mathbb{N}}(x_i) \mathbb{I}_{\{t\}}\left(\sum_{i=1}^n x_i\right)$$

Então, existe uma (única) medida de probabilidade μ tal que $\mu(\mathbb{R}_+) = 1$ e tal que, para todo $n \in \mathbb{N}^*$, a marginal de X_1, \dots, X_n é dada por: para $x_i = 0, 1, 2, \dots, i = 1, \dots, n$,

$$\mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = \int_{\mathbb{R}_+} \frac{e^{-n\theta} \theta^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n x_i!} d\mu(\theta)$$

Além disso, $\bar{X}_n = \frac{\sum_{i=1}^n X_i}{n} \xrightarrow{q.c.} \theta$, onde θ é distribuído segundo μ .

Permutabilidade

- **Teorema:** Seja $(X_n)_{n \geq 1}$ uma sequência de variáveis **permutáveis** tal que, **para todo** $n \in \mathbb{N}^*$,

$$X_1, \dots, X_n | \sum_{i=1}^n X_i^2 = t \sim \text{Uniforme}(S_t^{(n)}) ,$$

onde $S_t^{(n)} = \{(u_1, \dots, u_n) \in \mathbb{R}^n : \sum_{i=1}^n u_i^2 = t\}, t > 0$.

Então, existe uma (única) medida de probabilidade μ tal que $\mu(\mathbb{R}_+) = 1$ e tal que, para todo $n \in \mathbb{N}^*$, a marginal de X_1, \dots, X_n é dada por: para $x_i \in \mathbb{R}, i = 1, \dots, n$,

$$\mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n) = \int_{\mathbb{R}_+} \prod_{i=1}^n \Phi\left(\frac{x_i}{\sqrt{\theta}}\right) d\mu(\theta)$$

Além disso, $\frac{\sum_{i=1}^n X_i^2}{n} \xrightarrow{q.c.} \theta$, onde θ é distribuído segundo a medida μ .

Permutabilidade

- **Teorema:** Seja $(X_n)_{n \geq 1}$ uma sequência de variáveis **permutáveis** tal que, **para todo** $n \in \mathbb{N}^*$,

$$X_1, \dots, X_n | \sum_{i=1}^n X_i^2 = t \sim \text{Uniforme}(S_t^{(n)}) ,$$

onde $S_t^{(n)} = \{(u_1, \dots, u_n) \in \mathbb{R}^n : \sum_{i=1}^n u_i^2 = t\}, t > 0$.

Então, existe uma (única) medida de probabilidade μ tal que $\mu(\mathbb{R}_+) = 1$ e tal que, para todo $n \in \mathbb{N}^*$, a marginal de X_1, \dots, X_n é dada por: para $x_i \in \mathbb{R}, i = 1, \dots, n$,

$$\mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n) = \int_{\mathbb{R}_+} \prod_{i=1}^n \Phi\left(\frac{x_i}{\sqrt{\theta}}\right) d\mu(\theta)$$

Além disso, $\frac{\sum_{i=1}^n X_i^2}{n} \xrightarrow{q.c.} \theta$, onde θ é distribuído segundo a medida μ .

Permutabilidade

- Observação:
- Há versões finitas de teoremas tipo de De Finetti: são avaliadas as distâncias entre marginais de um vetor permutável com certas características e misturas de variáveis IID (de modelos paramétricos). Usualmente, são estabelecidos majorantes para tais distâncias.

Permutabilidade

- Observação:
- Há versões finitas de teoremas tipo de De Finetti: são avaliadas as distâncias entre marginais de um vetor permutável com certas características e misturas de variáveis IID (de modelos paramétricos). Usualmente, são estabelecidos majorantes para tais distâncias.

Permutabilidade

- Observação:
- Há versões finitas de teoremas tipo de De Finetti: são avaliadas as distâncias entre marginais de um vetor permutável com certas características e misturas de variáveis IID (de modelos paramétricos). Usualmente, são estabelecidos majorantes para tais distâncias.

Permutabilidade

- **Inferencia Preditiva:** Inferência para "observações futuras" (em oposição à inferência para limites de médias ou frequências relativas - " θ ").
- Distribuição preditiva (a posteriori) para observações futuras:
- 1) Suponhamos $(X_n)_{n \geq 1}$, dado θ , condicionalmente independentes (θ contínuo)

$$\begin{aligned}
 \bullet \mathbb{P}(X_{n+1} = x_{n+1}, \dots, X_{n+k} = x_{n+k} | X_1 = x_1, \dots, X_n = x_n) &= \\
 \int_{\Theta} \mathbb{P}(X_{n+1} = x_{n+1}, \dots, X_{n+k} = x_{n+k} | \theta, x_1, \dots, x_n) f(\theta | x_1, \dots, x_n) d\theta \\
 &= \int_{\Theta} \mathbb{P}(X_{n+1} = x_{n+1}, \dots, X_{n+k} = x_{n+k} | \theta) f(\theta | x_1, \dots, x_n) d\theta
 \end{aligned}$$

Permutabilidade

- **Inferencia Preditiva:** Inferência para "observações futuras" (em oposição à inferência para limites de médias ou frequências relativas - " θ ").

- Distribuição preditiva (a posteriori) para observações futuras:

- 1) Suponhamos $(X_n)_{n \geq 1}$, dado θ , condicionalmente independentes (θ contínuo)

$$\begin{aligned} \bullet \mathbb{P}(X_{n+1} = x_{n+1}, \dots, X_{n+k} = x_{n+k} | X_1 = x_1, \dots, X_n = x_n) &= \\ \int_{\Theta} \mathbb{P}(X_{n+1} = x_{n+1}, \dots, X_{n+k} = x_{n+k} | \theta, x_1, \dots, x_n) f(\theta | x_1, \dots, x_n) d\theta &= \\ = \int_{\Theta} \mathbb{P}(X_{n+1} = x_{n+1}, \dots, X_{n+k} = x_{n+k} | \theta) f(\theta | x_1, \dots, x_n) d\theta \end{aligned}$$

Permutabilidade

- **Inferencia Preditiva:** Inferência para "observações futuras" (em oposição à inferência para limites de médias ou frequências relativas - " θ ").

- Distribuição preditiva (a posteriori) para observações futuras:

- 1) Suponhamos $(X_n)_{n \geq 1}$, dado θ , condicionalmente independentes (θ contínuo)

$$\begin{aligned} \bullet \mathbb{P}(X_{n+1} = x_{n+1}, \dots, X_{n+k} = x_{n+k} | X_1 = x_1, \dots, X_n = x_n) &= \\ \int_{\Theta} \mathbb{P}(X_{n+1} = x_{n+1}, \dots, X_{n+k} = x_{n+k} | \theta, x_1, \dots, x_n) f(\theta | x_1, \dots, x_n) d\theta &= \\ = \int_{\Theta} \mathbb{P}(X_{n+1} = x_{n+1}, \dots, X_{n+k} = x_{n+k} | \theta) f(\theta | x_1, \dots, x_n) d\theta \end{aligned}$$

Permutabilidade

- **Inferencia Preditiva:** Inferência para "observações futuras" (em oposição à inferência para limites de médias ou frequências relativas - " θ ").
- Distribuição preditiva (a posteriori) para observações futuras:
- 1) Suponhamos $(X_n)_{n \geq 1}$, dado θ , condicionalmente independentes (θ contínuo)

$$\begin{aligned}
 \bullet \quad \mathbb{P}(X_{n+1} = x_{n+1}, \dots, X_{n+k} = x_{n+k} | X_1 = x_1, \dots, X_n = x_n) &= \\
 \int_{\Theta} \mathbb{P}(X_{n+1} = x_{n+1}, \dots, X_{n+k} = x_{n+k} | \theta, x_1, \dots, x_n) f(\theta | x_1, \dots, x_n) d\theta & \\
 = \int_{\Theta} \mathbb{P}(X_{n+1} = x_{n+1}, \dots, X_{n+k} = x_{n+k} | \theta) f(\theta | x_1, \dots, x_n) d\theta &
 \end{aligned}$$

Permutabilidade

- **Inferencia Preditiva:** Inferência para "observações futuras" (em oposição à inferência para limites de médias ou frequências relativas - " θ ").
- Distribuição preditiva (a posteriori) para observações futuras:
- 1) Suponhamos $(X_n)_{n \geq 1}$, dado θ , condicionalmente independentes (θ contínuo)

$$\begin{aligned}
 \bullet \mathbb{P}(X_{n+1} = x_{n+1}, \dots, X_{n+k} = x_{n+k} | X_1 = x_1, \dots, X_n = x_n) &= \\
 \int_{\Theta} \mathbb{P}(X_{n+1} = x_{n+1}, \dots, X_{n+k} = x_{n+k} | \theta, x_1, \dots, x_n) f(\theta | x_1, \dots, x_n) d\theta & \\
 = \int_{\Theta} \mathbb{P}(X_{n+1} = x_{n+1}, \dots, X_{n+k} = x_{n+k} | \theta) f(\theta | x_1, \dots, x_n) d\theta &
 \end{aligned}$$

Permutabilidade

- Assim,
- $$\mathbb{P}(X_{n+1} = x_{n+1}, \dots, X_{n+k} = x_{n+k} | X_1 = x_1, \dots, X_n = x_n) =$$

$$= \int_{\Theta} \prod_{i=1}^k \mathbb{P}(X_{n+i} = x_{n+i} | \theta) f(\theta | x_1, \dots, x_n) d\theta$$
- Exemplo: $(X_n)_{n \geq 1}$ sequência de variáveis de Bernoulli permutáveis. Então, para $k = 1$, temos

$$\begin{aligned} \mathbb{P}(X_{n+1} = 1 | X_1 = x_1, \dots, X_n = x_n) &= \\ &= \int_{[0,1]} \mathbb{P}(X_{n+1} = 1 | \theta) f(\theta | x_1, \dots, x_n) d\theta = \\ &= \int_{[0,1]} \theta f(\theta | x_1, \dots, x_n) d\theta = \mathbb{E}(\theta | x_1, \dots, x_n) \end{aligned}$$

Permutabilidade

- Assim,

- $$\mathbb{P}(X_{n+1} = x_{n+1}, \dots, X_{n+k} = x_{n+k} | X_1 = x_1, \dots, X_n = x_n) =$$

$$= \int_{\Theta} \prod_{i=1}^k \mathbb{P}(X_{n+i} = x_{n+i} | \theta) f(\theta | x_1, \dots, x_n) d\theta$$

- Exemplo: $(X_n)_{n \geq 1}$ sequência de variáveis de Bernoulli permutáveis. Então, para $k = 1$, temos

$$\mathbb{P}(X_{n+1} = 1 | X_1 = x_1, \dots, X_n = x_n) =$$

$$= \int_{[0,1]} \mathbb{P}(X_{n+1} = 1 | \theta) f(\theta | x_1, \dots, x_n) d\theta =$$

$$= \int_{[0,1]} \theta f(\theta | x_1, \dots, x_n) d\theta = \mathbb{E}(\theta | x_1, \dots, x_n)$$

Permutabilidade

- Assim,

$$\begin{aligned} \bullet \quad \mathbb{P}(X_{n+1} = x_{n+1}, \dots, X_{n+k} = x_{n+k} | X_1 = x_1, \dots, X_n = x_n) &= \\ &= \int_{\Theta} \prod_{i=1}^k \mathbb{P}(X_{n+i} = x_{n+i} | \theta) f(\theta | x_1, \dots, x_n) d\theta \end{aligned}$$

- Exemplo: $(X_n)_{n \geq 1}$ sequência de variáveis de Bernoulli permutáveis. Então, para $k = 1$, temos

$$\begin{aligned} \mathbb{P}(X_{n+1} = 1 | X_1 = x_1, \dots, X_n = x_n) &= \\ &= \int_{[0,1]} \mathbb{P}(X_{n+1} = 1 | \theta) f(\theta | x_1, \dots, x_n) d\theta = \\ &= \int_{[0,1]} \theta f(\theta | x_1, \dots, x_n) d\theta = \mathbb{E}(\theta | x_1, \dots, x_n) \end{aligned}$$

Permutabilidade

- Assim,
- $$\mathbb{P}(X_{n+1} = x_{n+1}, \dots, X_{n+k} = x_{n+k} | X_1 = x_1, \dots, X_n = x_n) =$$

$$= \int_{\Theta} \prod_{i=1}^k \mathbb{P}(X_{n+i} = x_{n+i} | \theta) f(\theta | x_1, \dots, x_n) d\theta$$
- Exemplo: $(X_n)_{n \geq 1}$ sequência de variáveis de Bernoulli permutáveis. Então, para $k = 1$, temos

$$\begin{aligned} \mathbb{P}(X_{n+1} = 1 | X_1 = x_1, \dots, X_n = x_n) &= \\ &= \int_{[0,1]} \mathbb{P}(X_{n+1} = 1 | \theta) f(\theta | x_1, \dots, x_n) d\theta = \\ &= \int_{[0,1]} \theta f(\theta | x_1, \dots, x_n) d\theta = \mathbb{E}(\theta | x_1, \dots, x_n) \end{aligned}$$

Permutabilidade

$$\begin{aligned}
 & \bullet \mathbb{P}(\sum_{i=1}^k X_{n+i} = t | X_1 = x_1, \dots, X_n = x_n) = \\
 &= \sum_{A_t} \mathbb{P}(X_{n+1} = u_1, \dots, X_{n+k} = u_k \mid x_1, \dots, x_n) = \\
 &= \sum_{A_t} \int_{\Theta} \prod_{i=1}^k \mathbb{P}(X_{n+i} = u_i | \theta) f(\theta | x_1, \dots, x_n) d\theta = \\
 &= \sum_{A_t} \int_{\Theta} \theta^{\sum_{i=1}^k u_i} (1 - \theta)^{k - \sum_{i=1}^k u_i} f(\theta | x_1, \dots, x_n) d\theta = \\
 &= \int_{\Theta} \sum_{A_t} \theta^t (1 - \theta)^{k-t} f(\theta | x_1, \dots, x_n) d\theta = \\
 &= \int_{\Theta} \binom{k}{t} \theta^t (1 - \theta)^{k-t} f(\theta | x_1, \dots, x_n) d\theta = \\
 &= \binom{k}{t} \mathbb{E}[\theta^t (1 - \theta)^{k-t} \mid x_1, \dots, x_n] ,
 \end{aligned}$$

onde $A_t = \{(u_1, \dots, u_k) \in \{0, 1\}^k : \sum_{i=1}^k u_i = t\}$, $0 \leq t \leq k$.

Permutabilidade

$$\begin{aligned}
 & \bullet \mathbb{P}(\sum_{i=1}^k X_{n+i} = t | X_1 = x_1, \dots, X_n = x_n) = \\
 &= \sum_{A_t} \mathbb{P}(X_{n+1} = u_1, \dots, X_{n+k} = u_k \mid x_1, \dots, x_n) = \\
 &= \sum_{A_t} \int_{\Theta} \prod_{i=1}^k \mathbb{P}(X_{n+i} = u_i | \theta) f(\theta | x_1, \dots, x_n) d\theta = \\
 &= \sum_{A_t} \int_{\Theta} \theta^{\sum_{i=1}^k u_i} (1 - \theta)^{k - \sum_{i=1}^k u_i} f(\theta | x_1, \dots, x_n) d\theta = \\
 &= \int_{\Theta} \sum_{A_t} \theta^t (1 - \theta)^{k-t} f(\theta | x_1, \dots, x_n) d\theta = \\
 &= \int_{\Theta} \binom{k}{t} \theta^t (1 - \theta)^{k-t} f(\theta | x_1, \dots, x_n) d\theta = \\
 &= \binom{k}{t} \mathbb{E}[\theta^t (1 - \theta)^{k-t} \mid x_1, \dots, x_n] ,
 \end{aligned}$$

onde $A_t = \{(u_1, \dots, u_k) \in \{0, 1\}^k : \sum_{i=1}^k u_i = t\}$, $0 \leq t \leq k$.