

Inferência Estatística Comparada

AULA 9 - INFERÊNCIA BAYESIANA

Introdução

- A inferência mais completa sobre θ , sob a abordagem bayesiana, é a distribuição a posteriori para esse parâmetro.
- No entanto, a partir da posteriori, podemos extrair estimativas pontuais, intervalares (por região), testar hipóteses, etc.. Do mesmo modo, pré-experimentação, podemos construir estimadores, funções de testes, etc..
- Tais procedimentos são comumente derivados a partir da Teoria da Decisão.
- Relembremos, em linha gerais, o procedimento de obtenção de decisões (regra de decisões) ótimas sob a Teoria da Decisão.

Introdução

- A inferência mais completa sobre θ , sob a abordagem bayesiana, é a distribuição a posteriori para esse parâmetro.
- No entanto, a partir da posteriori, podemos extrair estimativas pontuais, intervalares (por região), testar hipóteses, etc.. Do mesmo modo, pré-experimentação, podemos construir estimadores, funções de testes, etc..
- Tais procedimentos são comumente derivados a partir da Teoria da Decisão.
- Relembremos, em linha gerais, o procedimento de obtenção de decisões (regra de decisões) ótimas sob a Teoria da Decisão.

Introdução

- A inferência mais completa sobre θ , sob a abordagem bayesiana, é a distribuição a posteriori para esse parâmetro.
- No entanto, a partir da posteriori, podemos extrair estimativas pontuais, intervalares (por região), testar hipóteses, etc.. Do mesmo modo, pré-experimentação, podemos construir estimadores, funções de testes, etc..
- Tais procedimentos são comumente derivados a partir da Teoria da Decisão.
- Relembremos, em linha gerais, o procedimento de obtenção de decisões (regra de decisões) ótimas sob a Teoria da Decisão.

Introdução

- A inferência mais completa sobre θ , sob a abordagem bayesiana, é a distribuição a posteriori para esse parâmetro.
- No entanto, a partir da posteriori, podemos extrair estimativas pontuais, intervalares (por região), testar hipóteses, etc.. Do mesmo modo, pré-experimentação, podemos construir estimadores, funções de testes, etc..
- Tais procedimentos são comumente derivados a partir da Teoria da Decisão.
- Relembremos, em linha gerais, o procedimento de obtenção de decisões (regra de decisões) ótimas sob a Teoria da Decisão.

Introdução

- A inferência mais completa sobre θ , sob a abordagem bayesiana, é a distribuição a posteriori para esse parâmetro.
- No entanto, a partir da posteriori, podemos extrair estimativas pontuais, intervalares (por região), testar hipóteses, etc.. Do mesmo modo, pré-experimentação, podemos construir estimadores, funções de testes, etc..
- Tais procedimentos são comumente derivados a partir da Teoria da Decisão.
- Relembremos, em linha gerais, o procedimento de obtenção de decisões (regra de decisões) ótimas sob a Teoria da Decisão.

Elementos do problema de decisão

- **Problema de decisão:** $(\mathcal{D}, \Theta, L, \mathbb{P})$, onde
- \mathcal{D} : espaço decisões (ações)
- Θ : "estado da natureza" desconhecido
- L : função de perda $L : \mathcal{D} \times \Theta \rightarrow \mathbb{R}$, onde $L(d, \theta)$ que "representa" a penalidade que o agente decisor incorre ao tomar a decisão $d \in \mathcal{D}$ sob o estado da natureza θ .
- \mathbb{P} : medida de probabilidade para o estado da natureza θ .
- Observação: Alternativamente à consideração de uma função de perda, é comum a adoção de uma função Utilidade, que representa "recompensas", ao invés de "penalidades".

Elementos do problema de decisão

- **Problema de decisão:** $(\mathcal{D}, \Theta, L, \mathbb{P})$, onde
- \mathcal{D} : espaço decisões (ações)
- Θ : "estado da natureza" desconhecido
- L : função de perda $L : \mathcal{D} \times \Theta \rightarrow \mathbb{R}$, onde $L(d, \theta)$ que "representa" a penalidade que o agente decisor incorre ao tomar a decisão $d \in \mathcal{D}$ sob o estado da natureza θ .
- \mathbb{P} : medida de probabilidade para o estado da natureza θ .
- Observação: Alternativamente à consideração de uma função de perda, é comum a adoção de uma função Utilidade, que representa "recompensas", ao invés de "penalidades".

Elementos do problema de decisão

- **Problema de decisão:** $(\mathcal{D}, \Theta, L, \mathbb{P})$, onde
- \mathcal{D} : espaço decisões (ações)
- Θ : "estado da natureza" desconhecido
- L : função de perda $L : \mathcal{D} \times \Theta \rightarrow \mathbb{R}$, onde $L(d, \theta)$ que "representa" a penalidade que o agente decisor incorre ao tomar a decisão $d \in \mathcal{D}$ sob o estado da natureza θ .
- \mathbb{P} : medida de probabilidade para o estado da natureza θ .
- Observação: Alternativamente à consideração de uma função de perda, é comum a adoção de uma função Utilidade, que representa "recompensas", ao invés de "penalidades".

Elementos do problema de decisão

- **Problema de decisão:** $(\mathcal{D}, \Theta, L, \mathbb{P})$, onde
- \mathcal{D} : espaço decisões (ações)
- Θ : "estado da natureza" desconhecido
- L : função de perda $L : \mathcal{D} \times \Theta \rightarrow \mathbb{R}$, onde $L(d, \theta)$ que "representa" a penalidade que o agente decisor incorre ao tomar a decisão $d \in \mathcal{D}$ sob o estado da natureza θ .
- \mathbb{P} : medida de probabilidade para o estado da natureza θ .
- Observação: Alternativamente à consideração de uma função de perda, é comum a adoção de uma função Utilidade, que representa "recompensas", ao invés de "penalidades".

Elementos do problema de decisão

- **Problema de decisão:** $(\mathcal{D}, \Theta, L, \mathbb{P})$, onde
- \mathcal{D} : espaço decisões (ações)
- Θ : "estado da natureza" desconhecido
- L : função de perda $L : \mathcal{D} \times \Theta \rightarrow \mathbb{R}$, onde $L(d, \theta)$ que "representa" a penalidade que o agente decisor incorre ao tomar a decisão $d \in \mathcal{D}$ sob o estado da natureza θ .
- \mathbb{P} : medida de probabilidade para o estado da natureza θ .
- Observação: Alternativamente à consideração de uma função de perda, é comum a adoção de uma função Utilidade, que representa "recompensas", ao invés de "penalidades".

Elementos do problema de decisão

- **Problema de decisão:** $(\mathcal{D}, \Theta, L, \mathbb{P})$, onde
- \mathcal{D} : espaço decisões (ações)
- Θ : "estado da natureza" desconhecido
- L : função de perda $L : \mathcal{D} \times \Theta \rightarrow \mathbb{R}$, onde $L(d, \theta)$ que "representa" a penalidade que o agente decisor incorre ao tomar a decisão $d \in \mathcal{D}$ sob o estado da natureza θ .
- \mathbb{P} : medida de probabilidade para o estado da natureza θ .
- Observação: Alternativamente à consideração de uma função de perda, é comum a adoção de uma função Utilidade, que representa "recompensas", ao invés de "penalidades".

Elementos do problema de decisão

- **Problema de decisão:** $(\mathcal{D}, \Theta, L, \mathbb{P})$, onde
- \mathcal{D} : espaço decisões (ações)
- Θ : "estado da natureza" desconhecido
- L : função de perda $L : \mathcal{D} \times \Theta \rightarrow \mathbb{R}$, onde $L(d, \theta)$ que "representa" a penalidade que o agente decisor incorre ao tomar a decisão $d \in \mathcal{D}$ sob o estado da natureza θ .
- \mathbb{P} : medida de probabilidade para o estado da natureza θ .
- Observação: Alternativamente à consideração de uma função de perda, é comum a adoção de uma função Utilidade, que representa "recompensas", ao invés de "penalidades".

Minimização de perda esperada

- Sob certas condições, assegura-se a representação numérica de preferência por funções de perda (utilidade) e o paradigma de minimização (maximização) de perda (utilidade) esperada.

- Definição:** Uma decisão $d^* \in \mathcal{D}$ é uma decisão de Bayes contra \mathbb{P} , com relação à perda L , se, $\forall d \in \mathcal{D}$,

$$\mathbb{E}(L(d^*, \theta)) \leq \mathbb{E}(L(d, \theta))$$

- $\mathbb{E}(L(d, \theta))$ é chamada **risco** da decisão d :
 $\rho(d, \mathbb{P}) = \mathbb{E}(L(d, \theta))$.

- $\mathbb{E}(L(d^*, \theta))$ é chamada **risco de Bayes**:
 $\rho^*(\mathbb{P}) = \rho(d^*, \mathbb{P}) = \mathbb{E}(L(d^*, \theta))$.
 (Em geral, $\rho^*(\mathbb{P}) = \inf \{ \rho(d, \mathbb{P}) : d \in \mathcal{D} \}$)

Minimização de perda esperada

- Sob certas condições, assegura-se a representação numérica de preferência por funções de perda (utilidade) e o paradigma de minimização (maximização) de perda (utilidade) esperada.

- Definição:** Uma decisão $d^* \in \mathcal{D}$ é uma decisão de Bayes contra \mathbb{P} , com relação à perda L , se, $\forall d \in \mathcal{D}$,

$$\mathbb{E}(L(d^*, \theta)) \leq \mathbb{E}(L(d, \theta))$$

- $\mathbb{E}(L(d, \theta))$ é chamada **risco** da decisão d :
 $\rho(d, \mathbb{P}) = \mathbb{E}(L(d, \theta))$.

- $\mathbb{E}(L(d^*, \theta))$ é chamada **risco de Bayes**:
 $\rho^*(\mathbb{P}) = \rho(d^*, \mathbb{P}) = \mathbb{E}(L(d^*, \theta))$.
 (Em geral, $\rho^*(\mathbb{P}) = \inf \{ \rho(d, \mathbb{P}) : d \in \mathcal{D} \}$)

Minimização de perda esperada

- Sob certas condições, assegura-se a representação numérica de preferência por funções de perda (utilidade) e o paradigma de minimização (maximização) de perda (utilidade) esperada.
- Definição:** Uma decisão $d^* \in \mathcal{D}$ é uma decisão de Bayes contra \mathbb{P} , com relação à perda L , se, $\forall d \in \mathcal{D}$,

$$\mathbb{E}(L(d^*, \theta)) \leq \mathbb{E}(L(d, \theta))$$

- $\mathbb{E}(L(d, \theta))$ é chamada **risco** da decisão d :
 $\rho(d, \mathbb{P}) = \mathbb{E}(L(d, \theta))$.
- $\mathbb{E}(L(d^*, \theta))$ é chamada **risco de Bayes**:
 $\rho^*(\mathbb{P}) = \rho(d^*, \mathbb{P}) = \mathbb{E}(L(d^*, \theta))$.
 (Em geral, $\rho^*(\mathbb{P}) = \inf \{ \rho(d, \mathbb{P}) : d \in \mathcal{D} \}$)

Minimização de perda esperada

- Sob certas condições, assegura-se a representação numérica de preferência por funções de perda (utilidade) e o paradigma de minimização (maximização) de perda (utilidade) esperada.

- Definição:** Uma decisão $d^* \in \mathcal{D}$ é uma decisão de Bayes contra \mathbb{P} , com relação à perda L , se, $\forall d \in \mathcal{D}$,

$$\mathbb{E}(L(d^*, \theta)) \leq \mathbb{E}(L(d, \theta))$$

- $\mathbb{E}(L(d, \theta))$ é chamada **risco** da decisão d :
 $\rho(d, \mathbb{P}) = \mathbb{E}(L(d, \theta))$.

- $\mathbb{E}(L(d^*, \theta))$ é chamada **risco de Bayes**:
 $\rho^*(\mathbb{P}) = \rho(d^*, \mathbb{P}) = \mathbb{E}(L(d^*, \theta))$.
 (Em geral, $\rho^*(\mathbb{P}) = \inf \{ \rho(d, \mathbb{P}) : d \in \mathcal{D} \}$)

Minimização de perda esperada

- Sob certas condições, assegura-se a representação numérica de preferência por funções de perda (utilidade) e o paradigma de minimização (maximização) de perda (utilidade) esperada.
- Definição:** Uma decisão $d^* \in \mathcal{D}$ é uma decisão de Bayes contra \mathbb{P} , com relação à perda L , se, $\forall d \in \mathcal{D}$,

$$\mathbb{E}(L(d^*, \theta)) \leq \mathbb{E}(L(d, \theta))$$

- $\mathbb{E}(L(d, \theta))$ é chamada **risco** da decisão d :
 $\rho(d, \mathbb{P}) = \mathbb{E}(L(d, \theta))$.
- $\mathbb{E}(L(d^*, \theta))$ é chamada **risco de Bayes**:
 $\rho^*(\mathbb{P}) = \rho(d^*, \mathbb{P}) = \mathbb{E}(L(d^*, \theta))$.
 (Em geral, $\rho^*(\mathbb{P}) = \inf \{ \rho(d, \mathbb{P}) : d \in \mathcal{D} \}$)

Estimação

- Na sequência, vamos examinar problemas tradicionais em inferência estatística: estimação e testes de hipóteses.
- **Problema de estimação:** $(\Delta, \Theta \times \mathcal{X}, \bar{L}, \bar{\mathbb{P}})$, onde
- $\Delta = \{\delta : \mathcal{X} \rightarrow \Theta\}$: conjunto de estimadores para θ
- $\Theta \times \mathcal{X}$ desconhecido (pré-experimentação)
- $\bar{L} : \Delta \times (\Theta \times \mathcal{X}) \rightarrow \mathbb{R}$ dada por $\bar{L}(\delta, (\theta, x)) = L(\delta(x), \theta)$, onde $L : \Theta \times \Theta \rightarrow \mathbb{R}$ associa a cada par $(d, \theta) \in \Theta^2$ a penalidade $L(d, \theta)$ para a estimativa d quando o estado da natureza assume valor θ .
- $\bar{\mathbb{P}}$ representa incerteza sobre (θ, X) .

Estimação

- Na sequência, vamos examinar problemas tradicionais em inferência estatística: estimação e testes de hipóteses.
- **Problema de estimação:** $(\Delta, \Theta \times \mathcal{X}, \bar{L}, \bar{\mathbb{P}})$, onde
- $\Delta = \{\delta : \mathcal{X} \rightarrow \Theta\}$: conjunto de estimadores para θ
- $\Theta \times \mathcal{X}$ desconhecido (pré-experimentação)
- $\bar{L} : \Delta \times (\Theta \times \mathcal{X}) \rightarrow \mathbb{R}$ dada por $\bar{L}(\delta, (\theta, x)) = L(\delta(x), \theta)$, onde $L : \Theta \times \Theta \rightarrow \mathbb{R}$ associa a cada par $(d, \theta) \in \Theta^2$ a penalidade $L(d, \theta)$ para a estimativa d quando o estado da natureza assume valor θ .
- $\bar{\mathbb{P}}$ representa incerteza sobre (θ, X) .

Estimação

- Na sequência, vamos examinar problemas tradicionais em inferência estatística: estimação e testes de hipóteses.
- **Problema de estimação:** $(\Delta, \Theta \times \mathcal{X}, \bar{L}, \bar{\mathbb{P}})$, onde
 - $\Delta = \{\delta : \mathcal{X} \rightarrow \Theta\}$: conjunto de estimadores para θ
 - $\Theta \times \mathcal{X}$ desconhecido (pré-experimentação)
 - $\bar{L} : \Delta \times (\Theta \times \mathcal{X}) \rightarrow \mathbb{R}$ dada por $\bar{L}(\delta, (\theta, x)) = L(\delta(x), \theta)$, onde $L : \Theta \times \Theta \rightarrow \mathbb{R}$ associa a cada par $(d, \theta) \in \Theta^2$ a penalidade $L(d, \theta)$ para a estimativa d quando o estado da natureza assume valor θ .
 - $\bar{\mathbb{P}}$ representa incerteza sobre (θ, X) .

Estimação

- Na sequência, vamos examinar problemas tradicionais em inferência estatística: estimação e testes de hipóteses.
- **Problema de estimação:** $(\Delta, \Theta \times \mathcal{X}, \bar{L}, \bar{\mathbb{P}})$, onde
- $\Delta = \{\delta : \mathcal{X} \rightarrow \Theta\}$: conjunto de estimadores para θ
- $\Theta \times \mathcal{X}$ desconhecido (pré-experimentação)
- $\bar{L} : \Delta \times (\Theta \times \mathcal{X}) \rightarrow \mathbb{R}$ dada por $\bar{L}(\delta, (\theta, x)) = L(\delta(x), \theta)$, onde $L : \Theta \times \Theta \rightarrow \mathbb{R}$ associa a cada par $(d, \theta) \in \Theta^2$ a penalidade $L(d, \theta)$ para a estimativa d quando o estado da natureza assume valor θ .
- $\bar{\mathbb{P}}$ representa incerteza sobre (θ, X) .

Estimação

- Na sequência, vamos examinar problemas tradicionais em inferência estatística: estimação e testes de hipóteses.
- **Problema de estimação:** $(\Delta, \Theta \times \mathcal{X}, \bar{L}, \bar{\mathbb{P}})$, onde
- $\Delta = \{\delta : \mathcal{X} \rightarrow \Theta\}$: conjunto de estimadores para θ
- $\Theta \times \mathcal{X}$ desconhecido (pré-experimentação)
- $\bar{L} : \Delta \times (\Theta \times \mathcal{X}) \rightarrow \mathbb{R}$ dada por $\bar{L}(\delta, (\theta, x)) = L(\delta(x), \theta)$, onde $L : \Theta \times \Theta \rightarrow \mathbb{R}$ associa a cada par $(d, \theta) \in \Theta^2$ a penalidade $L(d, \theta)$ para a estimativa d quando o estado da natureza assume valor θ .
- $\bar{\mathbb{P}}$ representa incerteza sobre (θ, X) .

Estimação

- Na sequência, vamos examinar problemas tradicionais em inferência estatística: estimação e testes de hipóteses.
- **Problema de estimação:** $(\Delta, \Theta \times \mathcal{X}, \bar{L}, \bar{\mathbb{P}})$, onde
- $\Delta = \{\delta : \mathcal{X} \rightarrow \Theta\}$: conjunto de estimadores para θ
- $\Theta \times \mathcal{X}$ desconhecido (pré-experimentação)
- $\bar{L} : \Delta \times (\Theta \times \mathcal{X}) \rightarrow \mathbb{R}$ dada por $\bar{L}(\delta, (\theta, x)) = L(\delta(x), \theta)$, onde $L : \Theta \times \Theta \rightarrow \mathbb{R}$ associa a cada par $(d, \theta) \in \Theta^2$ a penalidade $L(d, \theta)$ para a estimativa d quando o estado da natureza assume valor θ .
- $\bar{\mathbb{P}}$ representa incerteza sobre (θ, X) .

Estimação

- Na sequência, vamos examinar problemas tradicionais em inferência estatística: estimação e testes de hipóteses.
- **Problema de estimação:** $(\Delta, \Theta \times \mathcal{X}, \bar{L}, \bar{\mathbb{P}})$, onde
- $\Delta = \{\delta : \mathcal{X} \rightarrow \Theta\}$: conjunto de estimadores para θ
- $\Theta \times \mathcal{X}$ desconhecido (pré-experimentação)
- $\bar{L} : \Delta \times (\Theta \times \mathcal{X}) \rightarrow \mathbb{R}$ dada por $\bar{L}(\delta, (\theta, x)) = L(\delta(x), \theta)$, onde $L : \Theta \times \Theta \rightarrow \mathbb{R}$ associa a cada par $(d, \theta) \in \Theta^2$ a penalidade $L(d, \theta)$ para a estimativa d quando o estado da natureza assume valor θ .
- $\bar{\mathbb{P}}$ representa incerteza sobre (θ, X) .

Estimação

- Consideremos $L \geq 0$ e (θ, X) contínuo. Nesse caso, para cada estimador $\delta \in \Delta$, o risco de δ é dado por

- $\rho(\delta, \bar{\mathbb{P}}) = \int_{\Theta \times \mathcal{X}} \bar{L}(\delta, (\theta, x)) f(\theta, x) d\theta dx =$

$$= \int_{\Theta} \underbrace{\left[\int_{\mathcal{X}} L(\delta(x), \theta) f(x|\theta) dx \right]}_{\text{RISCO FREQUENTISTA } R(\delta, \theta)} f(\theta) d\theta =$$

$$= \int_{\mathcal{X}} \underbrace{\left[\int_{\Theta} L(\delta(x), \theta) f(\theta|x) d\theta \right]}_{\rho(\delta(x), \mathbb{P}_x)} f(x) dx =$$

$$= \int_{\mathcal{X}} \rho(\delta(x), \mathbb{P}_x) f(x) dx \geq \int_{\mathcal{X}} \rho(d_x^*, \mathbb{P}_x) f(x) dx, \text{ onde}$$

para cada x , $d_x^* \in \Theta$ é decisão de Bayes de $(\Theta, \Theta, L, \mathbb{P}_x)$.

Estimação

- Consideremos $L \geq 0$ e (θ, X) contínuo. Nesse caso, para cada estimador $\delta \in \Delta$, o risco de δ é dado por

- $$\rho(\delta, \bar{\mathbb{P}}) = \int_{\Theta \times \mathcal{X}} \bar{L}(\delta, (\theta, x)) f(\theta, x) d\theta dx =$$

$$= \int_{\Theta} \underbrace{\left[\int_{\mathcal{X}} L(\delta(x), \theta) f(x|\theta) dx \right]}_{\text{RISCO FREQUENTISTA } R(\delta, \theta)} f(\theta) d\theta =$$

$$= \int_{\mathcal{X}} \underbrace{\left[\int_{\Theta} L(\delta(x), \theta) f(\theta|x) d\theta \right]}_{\rho(\delta(x), \mathbb{P}_x)} f(x) dx =$$

$$= \int_{\mathcal{X}} \rho(\delta(x), \mathbb{P}_x) f(x) dx \geq \int_{\mathcal{X}} \rho(d_x^*, \mathbb{P}_x) f(x) dx, \text{ onde}$$

para cada x , $d_x^* \in \Theta$ é decisão de Bayes de $(\Theta, \Theta, L, \mathbb{P}_x)$.

Estimação

- Desse modo, definindo $\delta^* : \mathcal{X} \rightarrow \Theta$ por $\delta^*(x) = d_x^*$, obtemos que, para todo $\delta \in \Delta$

$$\rho(\delta^*, \bar{\mathbb{P}}) \leq \rho(\delta, \bar{\mathbb{P}})$$

Assim, δ^* é estimador de Bayes considerando \bar{L} contra $\bar{\mathbb{P}}$.

- Note que a obtenção da estimativa para θ considerando perda \bar{L} ao observar $x \in \mathcal{X}$ envolve **APENAS** a distribuição a posteriori de θ dado $X = x$ (minimização da integral "interna" em vermelho). Ou ainda, envolve a distribuição a priori para θ e **APENAS** a função de verossimilhança para θ gerada por x , sem fazer menção (considerar) funções de verossimilhança geradas por outros pontos do espaço amostral (note que não é necessário construir o estimador δ^* para então obter a estimativa $\delta^*(x)$).

Estimação

- Desse modo, definindo $\delta^* : \mathcal{X} \rightarrow \Theta$ por $\delta^*(x) = d_x^*$, obtemos que, para todo $\delta \in \Delta$

$$\rho(\delta^*, \bar{\mathbb{P}}) \leq \rho(\delta, \bar{\mathbb{P}})$$

Assim, δ^* é estimador de Bayes considerando \bar{L} contra $\bar{\mathbb{P}}$.

- Note que a obtenção da estimativa para θ considerando perda \bar{L} ao observar $x \in \mathcal{X}$ envolve **APENAS** a distribuição a posteriori de θ dado $X = x$ (minimização da integral "interna" em vermelho). Ou ainda, envolve a distribuição a priori para θ e **APENAS** a função de verossimilhança para θ gerada por x , sem fazer menção (considerar) funções de verossimilhança geradas por outros pontos do espaço amostral (note que não é necessário construir o estimador δ^* para então obter a estimativa $\delta^*(x)$).

Estimação

- Sob certas condições, decisões ótimas (de Bayes), tais como estimativas pontuais ou intervalares, decisões em testes de hipóteses, são obtidas de modo similar: fixada $L : \mathcal{D} \times \Theta \rightarrow \mathbb{R}$, ao observar $x \in \mathcal{X}$, obtem-se a posteriori de θ dado $X = x$ e então toma-se $d^* \in \mathcal{D}$ solução do problema $(\mathcal{D}, \Theta, L, \mathbb{P}_x)$.
 - Funções de perda comumente adotadas em estimação ($\mathcal{D} = \Theta \subset \mathbb{R}$):
 - 1) $L(d, \theta) = (d - \theta)^2$ (**perda quadrática**): se para todo $x \in \mathcal{X}$, $\mathbb{E}(\theta|X = x) < \infty$ e $\mathbb{E}(\theta|X = x) \in \Theta$, temos
- $\delta^*(x) = \mathbb{E}(\theta|X = x)$ é estimativa de Bayes com relação à perda quadrática. Nesse caso, o estimador é dado por

Estimação

- Sob certas condições, decisões ótimas (de Bayes), tais como estimativas pontuais ou intervalares, decisões em testes de hipóteses, são obtidas de modo similar: fixada $L : \mathcal{D} \times \Theta \rightarrow \mathbb{R}$, ao observar $x \in \mathcal{X}$, obtem-se a posteriori de θ dado $X = x$ e então toma-se $d^* \in \mathcal{D}$ solução do problema $(\mathcal{D}, \Theta, L, \mathbb{P}_x)$.
- Funções de perda comumente adotadas em estimação ($\mathcal{D} = \Theta \subset \mathbb{R}$):
- 1) $L(d, \theta) = (d - \theta)^2$ (**perda quadrática**): se para todo $x \in \mathcal{X}$, $\mathbb{E}(\theta|X = x) < \infty$ e $\mathbb{E}(\theta|X = x) \in \Theta$, temos

$\delta^*(x) = \mathbb{E}(\theta|X = x)$ é estimativa de Bayes com relação à perda quadrática. Nesse caso, o estimador é dado por

Estimação

- Sob certas condições, decisões ótimas (de Bayes), tais como estimativas pontuais ou intervalares, decisões em testes de hipóteses, são obtidas de modo similar: fixada $L : \mathcal{D} \times \Theta \rightarrow \mathbb{R}$, ao observar $x \in \mathcal{X}$, obtem-se a posteriori de θ dado $X = x$ e então toma-se $d^* \in \mathcal{D}$ solução do problema $(\mathcal{D}, \Theta, L, \mathbb{P}_x)$.
- Funções de perda comumente adotadas em estimação ($\mathcal{D} = \Theta \subset \mathbb{R}$):
- 1) $L(d, \theta) = (d - \theta)^2$ (**perda quadrática**): se para todo $x \in \mathcal{X}$, $\mathbb{E}(\theta|X = x) < \infty$ e $\mathbb{E}(\theta|X = x) \in \Theta$, temos

$\delta^*(x) = \mathbb{E}(\theta|X = x)$ é estimativa de Bayes com relação à perda quadrática. Nesse caso, o estimador é dado por

Estimação

- $\delta^*(X) = \mathbb{E}(\theta|X)$, cujo risco é
- $\rho(\delta^*, \bar{\mathbb{P}}) = \int_{\mathcal{X}} \left[\int_{\Theta} L(\delta^*(x), \theta) f(\theta|x) d\theta \right] f(x) dx =$
 $= \int_{\mathcal{X}} \left[\int_{\Theta} (\delta^*(x) - \theta)^2 f(\theta|x) d\theta \right] f(x) dx =$
 $= \int_{\mathcal{X}} \left[\int_{\Theta} (\mathbb{E}(\theta|X = x) - \theta)^2 f(\theta|x) d\theta \right] f(x) dx =$
 $= \int_{\mathcal{X}} \text{VAR}(\theta|X = x) f(x) dx = \mathbb{E}(\text{VAR}(\theta|X)) \Rightarrow$
 $\Rightarrow \rho(\delta^*, \bar{\mathbb{P}}) = \text{VAR}(\theta) - \text{VAR}(\mathbb{E}(\theta|X))$
- Note que $\rho(\delta^*, \bar{\mathbb{P}}) = \mathbb{E}((\delta^*(X) - \theta)^2)$ **NÃO** depende de θ !!!

Estimação

- $\delta^*(X) = \mathbb{E}(\theta|X)$, cujo risco é
- $\rho(\delta^*, \bar{\mathbb{P}}) = \int_{\mathcal{X}} \left[\int_{\Theta} L(\delta^*(x), \theta) f(\theta|x) d\theta \right] f(x) dx =$
 $= \int_{\mathcal{X}} \left[\int_{\Theta} (\delta^*(x) - \theta)^2 f(\theta|x) d\theta \right] f(x) dx =$
 $= \int_{\mathcal{X}} \left[\int_{\Theta} (\mathbb{E}(\theta|X = x) - \theta)^2 f(\theta|x) d\theta \right] f(x) dx =$
 $= \int_{\mathcal{X}} \text{VAR}(\theta|X = x) f(x) dx = \mathbb{E}(\text{VAR}(\theta|X)) \Rightarrow$
 $\Rightarrow \rho(\delta^*, \bar{\mathbb{P}}) = \text{VAR}(\theta) - \text{VAR}(\mathbb{E}(\theta|X))$
- Note que $\rho(\delta^*, \bar{\mathbb{P}}) = \mathbb{E}((\delta^*(X) - \theta)^2)$ **NÃO** depende de θ !!!

Estimação

- $\delta^*(X) = \mathbb{E}(\theta|X)$, cujo risco é
- $\rho(\delta^*, \bar{\mathbb{P}}) = \int_{\mathcal{X}} \left[\int_{\Theta} L(\delta^*(x), \theta) f(\theta|x) d\theta \right] f(x) dx =$
 $= \int_{\mathcal{X}} \left[\int_{\Theta} (\delta^*(x) - \theta)^2 f(\theta|x) d\theta \right] f(x) dx =$
 $= \int_{\mathcal{X}} \left[\int_{\Theta} (\mathbb{E}(\theta|X = x) - \theta)^2 f(\theta|x) d\theta \right] f(x) dx =$
 $= \int_{\mathcal{X}} \text{VAR}(\theta|X = x) f(x) dx = \mathbb{E}(\text{VAR}(\theta|X)) \Rightarrow$
 $\Rightarrow \rho(\delta^*, \bar{\mathbb{P}}) = \text{VAR}(\theta) - \text{VAR}(\mathbb{E}(\theta|X))$
- Note que $\rho(\delta^*, \bar{\mathbb{P}}) = \mathbb{E}((\delta^*(X) - \theta)^2)$ **NÃO** depende de $\theta!!!$

Estimação

- Exemplo: Seja $X = (X_1, \dots, X_n)$ AAS Bernoulli (θ) e $\theta \sim \text{Beta}(a, b)$. Para $x \in \mathcal{X}$, sabemos que

$$\theta|X = x = (x_1, \dots, x_n) \sim \text{Beta}(a + \sum_{i=1}^n x_i, b + n - \sum_{i=1}^n x_i)$$

Logo, $\delta^*(X) = \mathbb{E}(\theta|X) = \frac{a + \sum_{i=1}^n X_i}{a + b + n}$. Assim, temos

$$\begin{aligned} \rho(\delta^*, \bar{\mathbb{P}}) &= \text{VAR}(\theta) - \text{VAR}(\mathbb{E}(\theta|X)) = \\ &= \text{VAR}(\theta) - \text{VAR}\left(\frac{a + \sum_{i=1}^n X_i}{a + b + n}\right) = \text{VAR}(\theta) - \frac{\text{VAR}(\sum_{i=1}^n X_i)}{(a + b + n)^2} = \\ &= \text{VAR}(\theta) - \frac{\mathbb{E}(\text{VAR}(\sum_{i=1}^n X_i|\theta)) + \text{VAR}(\mathbb{E}(\sum_{i=1}^n X_i|\theta))}{(a + b + n)^2} = \end{aligned}$$

Estimação

- Exemplo: Seja $X = (X_1, \dots, X_n)$ AAS Bernoulli (θ) e $\theta \sim \text{Beta}(a, b)$. Para $x \in \mathcal{X}$, sabemos que

$$\theta|X = x = (x_1, \dots, x_n) \sim \text{Beta}(a + \sum_{i=1}^n x_i, b + n - \sum_{i=1}^n x_i)$$

Logo, $\delta^*(X) = \mathbb{E}(\theta|X) = \frac{a + \sum_{i=1}^n X_i}{a + b + n}$. Assim, temos

$$\begin{aligned} \rho(\delta^*, \bar{\mathbb{P}}) &= \text{VAR}(\theta) - \text{VAR}(\mathbb{E}(\theta|X)) = \\ &= \text{VAR}(\theta) - \text{VAR}\left(\frac{a + \sum_{i=1}^n X_i}{a + b + n}\right) = \text{VAR}(\theta) - \frac{\text{VAR}(\sum_{i=1}^n X_i)}{(a + b + n)^2} = \\ &= \text{VAR}(\theta) - \frac{\mathbb{E}(\text{VAR}(\sum_{i=1}^n X_i|\theta)) + \text{VAR}(\mathbb{E}(\sum_{i=1}^n X_i|\theta))}{(a + b + n)^2} = \end{aligned}$$

Estimação

$$\bullet = \text{VAR}(\theta) - \frac{1}{(a+b+n)^2} \{ \mathbb{E}(n\theta(1-\theta)) + \text{VAR}(n\theta) \} \Rightarrow$$

$$\Rightarrow \rho(\delta^*, \bar{\mathbb{P}}) = \{1 - (\frac{n}{a+b+n})^2\} \text{VAR}(\theta) - \frac{n}{(a+b+n)^2} \mathbb{E}(\theta(1-\theta))$$

$$\bullet 2) L(d, \theta) = a_1(d - \theta)\mathbb{I}_{[\theta, \infty)}(d) + a_2(\theta - d)\mathbb{I}_{(-\infty, \theta)}(d),$$

$$a_1, a_2 > 0 :$$

se para todo $x \in \mathcal{X}$, $\mathbb{E}(\theta|X = x) < \infty$, temos

$\delta^*(x) = F_{\theta|X=x}^{-1}(\frac{a_1}{a_1+a_2})$, o percentil de ordem $\frac{a_1}{a_1+a_2}$ da distribuição a posteriori de θ dado $X = x$, isto é, $\delta^*(x)$ satisfaz

$$\mathbb{P}(\theta \leq \delta^*(x)|X = x) \geq \frac{a_1}{a_1+a_2} \text{ e } \mathbb{P}(\theta \geq \delta^*(x)|X = x) \geq \frac{a_2}{a_1+a_2}$$

Estimação

$$\bullet = \text{VAR}(\theta) - \frac{1}{(a+b+n)^2} \{ \mathbb{E}(n\theta(1-\theta)) + \text{VAR}(n\theta) \} \Rightarrow$$

$$\Rightarrow \rho(\delta^*, \bar{\mathbb{P}}) = \{1 - (\frac{n}{a+b+n})^2\} \text{VAR}(\theta) - \frac{n}{(a+b+n)^2} \mathbb{E}(\theta(1-\theta))$$

$$\bullet 2) L(d, \theta) = a_1(d - \theta)\mathbb{I}_{[\theta, \infty)}(d) + a_2(\theta - d)\mathbb{I}_{(-\infty, \theta)}(d),$$

$$a_1, a_2 > 0 :$$

se para todo $x \in \mathcal{X}$, $\mathbb{E}(\theta|X=x) < \infty$, temos

$\delta^*(x) = F_{\theta|X=x}^{-1}(\frac{a_1}{a_1+a_2})$, o percentil de ordem $\frac{a_1}{a_1+a_2}$ da distribuição a posteriori de θ dado $X=x$, isto é, $\delta^*(x)$ satisfaz

$$\mathbb{P}(\theta \leq \delta^*(x)|X=x) \geq \frac{a_1}{a_1+a_2} \text{ e } \mathbb{P}(\theta \geq \delta^*(x)|X=x) \geq \frac{a_2}{a_1+a_2}$$

Estimação

$$\bullet = \text{VAR}(\theta) - \frac{1}{(a+b+n)^2} \{ \mathbb{E}(n\theta(1-\theta)) + \text{VAR}(n\theta) \} \Rightarrow$$

$$\Rightarrow \rho(\delta^*, \bar{\mathbb{P}}) = \{1 - (\frac{n}{a+b+n})^2\} \text{VAR}(\theta) - \frac{n}{(a+b+n)^2} \mathbb{E}(\theta(1-\theta))$$

$$\bullet \text{ 2) } L(d, \theta) = a_1(d - \theta)\mathbb{I}_{[\theta, \infty)}(d) + a_2(\theta - d)\mathbb{I}_{(-\infty, \theta)}(d),$$

$$a_1, a_2 > 0 :$$

se para todo $x \in \mathcal{X}$, $\mathbb{E}(\theta|X=x) < \infty$, temos

$\delta^*(x) = F_{\theta|X=x}^{-1}(\frac{a_1}{a_1+a_2})$, o percentil de ordem $\frac{a_1}{a_1+a_2}$ da distribuição a posteriori de θ dado $X=x$, isto é, $\delta^*(x)$ satisfaz

$$\mathbb{P}(\theta \leq \delta^*(x)|X=x) \geq \frac{a_1}{a_1+a_2} \text{ e } \mathbb{P}(\theta \geq \delta^*(x)|X=x) \geq \frac{a_2}{a_1+a_2}$$

Estimação

- Se $a_1 = a_2$, temos $L(d, \theta) = |d - \theta|$ (**perda absoluta**).

Nesse caso, $\delta^*(x) = F_{\theta|X=x}^{-1}(\frac{1}{2})$: mediana da distribuição a posteriori de θ dado $X = x$.

- 3) $L(d, \theta) = 1 - \mathbb{I}_{(\theta-\epsilon, \theta+\epsilon)}(d)$, $\epsilon > 0$ (θ contínuo)

Nesse caso, $\delta^*(x)$ corresponde ao ponto central do intervalo "modal" de comprimento 2ϵ .

Quando Θ é enumerável, podemos, alternativamente, considerar $L(d, \theta) = \mathbb{I}_{\{\theta\}}(d)$ (**função de perda 0-1**).

Nesse caso, $\delta^*(x)$ é uma moda da distribuição a posteriori de θ dado $X = x$, isto é, $\delta^*(x)$ satisfaz

$$\mathbb{P}(\theta = \delta^*(x) | X = x) \geq \mathbb{P}(\theta = j | X = x), \forall j \in \Theta.$$

Estimação

- Se $a_1 = a_2$, temos $L(d, \theta) = |d - \theta|$ (**perda absoluta**).

Nesse caso, $\delta^*(x) = F_{\theta|X=x}^{-1}(\frac{1}{2})$: mediana da distribuição a posteriori de θ dado $X = x$.

- 3) $L(d, \theta) = 1 - \mathbb{I}_{(\theta-\epsilon, \theta+\epsilon)}(d)$, $\epsilon > 0$ (θ contínuo)

Nesse caso, $\delta^*(x)$ corresponde ao ponto central do intervalo "modal" de comprimento 2ϵ .

Quando Θ é enumerável, podemos, alternativamente, considerar $L(d, \theta) = \mathbb{I}_{\{\theta\}}(d)$ (**função de perda 0-1**).

Nesse caso, $\delta^*(x)$ é uma moda da distribuição a posteriori de θ dado $X = x$, isto é, $\delta^*(x)$ satisfaz

$$\mathbb{P}(\theta = \delta^*(x) | X = x) \geq \mathbb{P}(\theta = j | X = x), \forall j \in \Theta.$$

Estimação

- Se $a_1 = a_2$, temos $L(d, \theta) = |d - \theta|$ (**perda absoluta**).

Nesse caso, $\delta^*(x) = F_{\theta|X=x}^{-1}(\frac{1}{2})$: mediana da distribuição a posteriori de θ dado $X = x$.

- 3) $L(d, \theta) = 1 - \mathbb{I}_{(\theta-\epsilon, \theta+\epsilon)}(d)$, $\epsilon > 0$ (θ contínuo)

Nesse caso, $\delta^*(x)$ corresponde ao ponto central do intervalo "modal" de comprimento 2ϵ .

Quando Θ é enumerável, podemos, alternativamente, considerar $L(d, \theta) = \mathbb{I}_{\{\theta\}}(d)$ (**função de perda 0-1**).

Nesse caso, $\delta^*(x)$ é uma moda da distribuição a posteriori de θ dado $X = x$, isto é, $\delta^*(x)$ satisfaz

$$\mathbb{P}(\theta = \delta^*(x) | X = x) \geq \mathbb{P}(\theta = j | X = x), \forall j \in \Theta.$$

Estimação

- Na sequência, examinamos o problema de estimação por intervalo.
- **Problema de estimação por intervalo:** $(\Delta, \Theta \times \mathcal{X}, \bar{L}, \bar{\mathbb{P}})$
- $\Delta = \{I : \mathcal{X} \rightarrow \mathcal{I}\}$: conjunto de estimadores por intervalo para θ , onde $\mathcal{I} = \{[a, b] : a, b \in \mathbb{R}, a < b\}$.
- $\Theta \times \mathcal{X}$ desconhecido (pré-experimentação)
- $\bar{L} : \Delta \times (\Theta \times \mathcal{X}) \rightarrow \mathbb{R}$ dada por $\bar{L}(I, (\theta, x)) = L(I(x), \theta)$, onde $L : \mathcal{I} \times \Theta \rightarrow \mathbb{R}$ associa ao par $(I, \theta) \in \mathcal{I} \times \Theta$ a penalidade $L(I, \theta)$ para a estimativa por intervalo I quando o estado da natureza assume valor θ .
- $\bar{\mathbb{P}}$ representa incerteza sobre (θ, X) .

Estimação

- Na sequência, examinamos o problema de estimação por intervalo.
- **Problema de estimação por intervalo:** $(\Delta, \Theta \times \mathcal{X}, \bar{L}, \bar{\mathbb{P}})$
- $\Delta = \{I : \mathcal{X} \rightarrow \mathcal{I}\}$: conjunto de estimadores por intervalo para θ , onde $\mathcal{I} = \{[a, b] : a, b \in \mathbb{R}, a < b\}$.
- $\Theta \times \mathcal{X}$ desconhecido (pré-experimentação)
- $\bar{L} : \Delta \times (\Theta \times \mathcal{X}) \rightarrow \mathbb{R}$ dada por $\bar{L}(I, (\theta, x)) = L(I(x), \theta)$, onde $L : \mathcal{I} \times \Theta \rightarrow \mathbb{R}$ associa ao par $(I, \theta) \in \mathcal{I} \times \Theta$ a penalidade $L(I, \theta)$ para a estimativa por intervalo I quando o estado da natureza assume valor θ .
- $\bar{\mathbb{P}}$ representa incerteza sobre (θ, X) .

Estimação

- Na sequência, examinamos o problema de estimação por intervalo.
- **Problema de estimação por intervalo:** $(\Delta, \Theta \times \mathcal{X}, \bar{L}, \bar{\mathbb{P}})$
- $\Delta = \{I : \mathcal{X} \rightarrow \mathcal{I}\}$: conjunto de estimadores por intervalo para θ , onde $\mathcal{I} = \{[a, b] : a, b \in \mathbb{R}, a < b\}$.
- $\Theta \times \mathcal{X}$ desconhecido (pré-experimentação)
- $\bar{L} : \Delta \times (\Theta \times \mathcal{X}) \rightarrow \mathbb{R}$ dada por $\bar{L}(I, (\theta, x)) = L(I(x), \theta)$, onde $L : \mathcal{I} \times \Theta \rightarrow \mathbb{R}$ associa ao par $(I, \theta) \in \mathcal{I} \times \Theta$ a penalidade $L(I, \theta)$ para a estimativa por intervalo I quando o estado da natureza assume valor θ .
- $\bar{\mathbb{P}}$ representa incerteza sobre (θ, X) .

Estimação

- Na sequência, examinamos o problema de estimação por intervalo.
- **Problema de estimação por intervalo:** $(\Delta, \Theta \times \mathcal{X}, \bar{L}, \bar{\mathbb{P}})$
- $\Delta = \{I : \mathcal{X} \rightarrow \mathcal{I}\}$: conjunto de estimadores por intervalo para θ , onde $\mathcal{I} = \{[a, b] : a, b \in \mathbb{R}, a < b\}$.
- $\Theta \times \mathcal{X}$ desconhecido (pré-experimentação)
- $\bar{L} : \Delta \times (\Theta \times \mathcal{X}) \rightarrow \mathbb{R}$ dada por $\bar{L}(I, (\theta, x)) = L(I(x), \theta)$, onde $L : \mathcal{I} \times \Theta \rightarrow \mathbb{R}$ associa ao par $(I, \theta) \in \mathcal{I} \times \Theta$ a penalidade $L(I, \theta)$ para a estimativa por intervalo I quando o estado da natureza assume valor θ .
- $\bar{\mathbb{P}}$ representa incerteza sobre (θ, X) .

Estimação

- Na sequência, examinamos o problema de estimação por intervalo.
- **Problema de estimação por intervalo:** $(\Delta, \Theta \times \mathcal{X}, \bar{L}, \bar{\mathbb{P}})$
- $\Delta = \{I : \mathcal{X} \rightarrow \mathcal{I}\}$: conjunto de estimadores por intervalo para θ , onde $\mathcal{I} = \{[a, b] : a, b \in \mathbb{R}, a < b\}$.
- $\Theta \times \mathcal{X}$ desconhecido (pré-experimentação)
- $\bar{L} : \Delta \times (\Theta \times \mathcal{X}) \rightarrow \mathbb{R}$ dada por $\bar{L}(I, (\theta, x)) = L(I(x), \theta)$, onde $L : \mathcal{I} \times \Theta \rightarrow \mathbb{R}$ associa ao par $(I, \theta) \in \mathcal{I} \times \Theta$ a penalidade $L(I, \theta)$ para a estimativa por intervalo I quando o estado da natureza assume valor θ .
- $\bar{\mathbb{P}}$ representa incerteza sobre (θ, X) .

Estimação

- Na sequência, examinamos o problema de estimação por intervalo.
- **Problema de estimação por intervalo:** $(\Delta, \Theta \times \mathcal{X}, \bar{L}, \bar{\mathbb{P}})$
- $\Delta = \{I : \mathcal{X} \rightarrow \mathcal{I}\}$: conjunto de estimadores por intervalo para θ , onde $\mathcal{I} = \{[a, b] : a, b \in \mathbb{R}, a < b\}$.
- $\Theta \times \mathcal{X}$ desconhecido (pré-experimentação)
- $\bar{L} : \Delta \times (\Theta \times \mathcal{X}) \rightarrow \mathbb{R}$ dada por $\bar{L}(I, (\theta, x)) = L(I(x), \theta)$, onde $L : \mathcal{I} \times \Theta \rightarrow \mathbb{R}$ associa ao par $(I, \theta) \in \mathcal{I} \times \Theta$ a penalidade $L(I, \theta)$ para a estimativa por intervalo I quando o estado da natureza assume valor θ .
- $\bar{\mathbb{P}}$ representa incerteza sobre (θ, X) .

Estimação

- Na sequência, examinamos o problema de estimação por intervalo.
- **Problema de estimação por intervalo:** $(\Delta, \Theta \times \mathcal{X}, \bar{L}, \bar{\mathbb{P}})$
- $\Delta = \{I : \mathcal{X} \rightarrow \mathcal{I}\}$: conjunto de estimadores por intervalo para θ , onde $\mathcal{I} = \{[a, b] : a, b \in \mathbb{R}, a < b\}$.
- $\Theta \times \mathcal{X}$ desconhecido (pré-experimentação)
- $\bar{L} : \Delta \times (\Theta \times \mathcal{X}) \rightarrow \mathbb{R}$ dada por $\bar{L}(I, (\theta, x)) = L(I(x), \theta)$, onde $L : \mathcal{I} \times \Theta \rightarrow \mathbb{R}$ associa ao par $(I, \theta) \in \mathcal{I} \times \Theta$ a penalidade $L(I, \theta)$ para a estimativa por intervalo I quando o estado da natureza assume valor θ .
- $\bar{\mathbb{P}}$ representa incerteza sobre (θ, X) .

Estimação

- Analogamente ao problema de estimação (pontual), sob certas condições, fixada $L : \mathcal{I} \times \Theta \rightarrow \mathbb{R}$, ao observar $x \in \mathcal{X}$, obtém-se a posteriori de θ dado $X = x$ e então toma-se $I^* \in \mathcal{I}$ solução do problema $(\mathcal{I}, \Theta, L, \mathbb{P}_x)$.
- Nesse caso, a função de perda comumente leva em consideração a pertinência de θ a I e o comprimento de I . Por exemplo, para $I = [a, b]$, considere, com $c_1, c_2 > 1$,

$$L([a, b], \theta) = \begin{cases} b - a + c_1(a - \theta), & \text{se } \theta < a \\ b - a, & \text{se } a \leq \theta \leq b \\ b - a + c_2(\theta - b), & \text{se } \theta > b \end{cases}$$

Estimação

- Analogamente ao problema de estimação (pontual), sob certas condições, fixada $L : \mathcal{I} \times \Theta \rightarrow \mathbb{R}$, ao observar $x \in \mathcal{X}$, obtem-se a posteriori de θ dado $X = x$ e então toma-se $I^* \in \mathcal{I}$ solução do problema $(\mathcal{I}, \Theta, L, \mathbb{P}_x)$.
- Nesse caso, a função de perda comumente leva em consideração a pertinência de θ a I e o comprimento de I . Por exemplo, para $I = [a, b]$, considere, com $c_1, c_2 > 1$,

$$L([a, b], \theta) = \begin{cases} b - a + c_1(a - \theta), & \text{se } \theta < a \\ b - a, & \text{se } a \leq \theta \leq b \\ b - a + c_2(\theta - b), & \text{se } \theta > b \end{cases}$$

Estimação

- Analogamente ao problema de estimação (pontual), sob certas condições, fixada $L : \mathcal{I} \times \Theta \rightarrow \mathbb{R}$, ao observar $x \in \mathcal{X}$, obtem-se a posteriori de θ dado $X = x$ e então toma-se $I^* \in \mathcal{I}$ solução do problema $(\mathcal{I}, \Theta, L, \mathbb{P}_x)$.
- Nesse caso, a função de perda comumente leva em consideração a pertinência de θ a I e o comprimento de I . Por exemplo, para $I = [a, b]$, considere, com $c_1, c_2 > 1$,

$$L([a, b], \theta) = \begin{cases} b - a + c_1(a - \theta), & \text{se } \theta < a \\ b - a, & \text{se } a \leq \theta \leq b \\ b - a + c_2(\theta - b), & \text{se } \theta > b \end{cases}$$

Estimação

- Analogamente ao problema de estimação (pontual), sob certas condições, fixada $L : \mathcal{I} \times \Theta \rightarrow \mathbb{R}$, ao observar $x \in \mathcal{X}$, obtem-se a posteriori de θ dado $X = x$ e então toma-se $I^* \in \mathcal{I}$ solução do problema $(\mathcal{I}, \Theta, L, \mathbb{P}_x)$.
- Nesse caso, a função de perda comumente leva em consideração a pertinência de θ a I e o comprimento de I . Por exemplo, para $I = [a, b]$, considere, com $c_1, c_2 > 1$,

$$L([a, b], \theta) = \begin{cases} b - a + c_1(a - \theta), & \text{se } \theta < a \\ b - a, & \text{se } a \leq \theta \leq b \\ b - a + c_2(\theta - b), & \text{se } \theta > b \end{cases}$$

Estimação

- Nesse caso, para cada $x \in \mathcal{X}$, $I^*(x)$ é o intervalo que vai do percentil de ordem $\frac{1}{c_1}$ ao percentil de ordem $1 - \frac{1}{c_2}$ da distribuição a posteriori de θ dado $X = x$. Observe que se $c_1 = c_2 = \frac{2}{\alpha}$, $\alpha \in (0, 1)$, $I^*(x)$ é o intervalo "central" de probabilidade a posteriori $1 - \alpha$. Note que
- $L([a, b], \theta) =$

$$= c_1(a - \theta)\mathbb{I}_{(-\infty, a)}(\theta) + c_2(\theta - b)\mathbb{I}_{(b, \infty)}(\theta) + b - \theta + \theta - a$$

$$= L_1(a, \theta) + L_2(b, \theta), \text{ onde}$$

$$L_1(a, \theta) = (c_1 - 1)(a - \theta)\mathbb{I}_{(-\infty, a)}(\theta) + (\theta - a)\mathbb{I}_{[a, \infty)}(\theta) \text{ e}$$

$$L_2(b, \theta) = (b - \theta)\mathbb{I}_{(-\infty, b)}(\theta) + (c_2 - 1)\mathbb{I}_{[b, \infty)}(\theta).$$

Basta então escolher a e b que minimizam L_1 e L_2 , respectivamente.

Estimação

- Nesse caso, para cada $x \in \mathcal{X}$, $I^*(x)$ é o intervalo que vai do percentil de ordem $\frac{1}{c_1}$ ao percentil de ordem $1 - \frac{1}{c_2}$ da distribuição a posteriori de θ dado $X = x$. Observe que se $c_1 = c_2 = \frac{2}{\alpha}$, $\alpha \in (0, 1)$, $I^*(x)$ é o intervalo "central" de probabilidade a posteriori $1 - \alpha$. Note que

$$\begin{aligned}
 L([a, b], \theta) &= \\
 &= c_1(a - \theta)\mathbb{I}_{(-\infty, a)}(\theta) + c_2(\theta - b)\mathbb{I}_{(b, \infty)}(\theta) + b - \theta + \theta - a \\
 &= L_1(a, \theta) + L_2(b, \theta), \text{ onde} \\
 L_1(a, \theta) &= (c_1 - 1)(a - \theta)\mathbb{I}_{(-\infty, a)}(\theta) + (\theta - a)\mathbb{I}_{[a, \infty)}(\theta) \text{ e} \\
 L_2(b, \theta) &= (b - \theta)\mathbb{I}_{(-\infty, b)}(\theta) + (c_2 - 1)\mathbb{I}_{[b, \infty)}(\theta).
 \end{aligned}$$

Basta então escolher a e b que minimizam L_1 e L_2 , respectivamente.

Estimação

- Nesse caso, para cada $x \in \mathcal{X}$, $I^*(x)$ é o intervalo que vai do percentil de ordem $\frac{1}{c_1}$ ao percentil de ordem $1 - \frac{1}{c_2}$ da distribuição a posteriori de θ dado $X = x$. Observe que se $c_1 = c_2 = \frac{2}{\alpha}$, $\alpha \in (0, 1)$, $I^*(x)$ é o intervalo "central" de probabilidade a posteriori $1 - \alpha$. Note que

$$\begin{aligned}
 L([a, b], \theta) &= \\
 &= c_1(a - \theta)\mathbb{I}_{(-\infty, a)}(\theta) + c_2(\theta - b)\mathbb{I}_{(b, \infty)}(\theta) + b - \theta + \theta - a \\
 &= L_1(a, \theta) + L_2(b, \theta), \text{ onde} \\
 L_1(a, \theta) &= (c_1 - 1)(a - \theta)\mathbb{I}_{(-\infty, a)}(\theta) + (\theta - a)\mathbb{I}_{[a, \infty)}(\theta) \text{ e} \\
 L_2(b, \theta) &= (b - \theta)\mathbb{I}_{(-\infty, b)}(\theta) + (c_2 - 1)\mathbb{I}_{[b, \infty)}(\theta).
 \end{aligned}$$

Basta então escolher a e b que minimizam L_1 e L_2 , respectivamente.

Estimação

- Exemplo 1: $X = (X_1, \dots, X_n)$ AAS do modelo normal de média θ e variância $v^2 > 0$. Suponhamos $\theta \sim N(\mu_0, \sigma_0^2)$, com $\mu_0 \in \mathbb{R}$ e $\sigma_0^2 > 0$. Então,

$\theta | X_1 = x_1, \dots, X_n = x_n \sim N(\mu_x, \sigma_x^2)$, onde

$$\mu_x = \frac{\sigma_0^2 n \bar{x} + v^2 \mu_0}{\sigma_0^2 n + v^2} \quad \text{e} \quad \sigma_x^2 = \frac{\sigma_0^2 v^2}{v^2 + n \sigma_0^2}.$$

O intervalo "central" de probabilidade (a posteriori) $1 - \alpha$ é

$$I^*(x) = [\mu_x - \Phi^{-1}(1 - \frac{\alpha}{2})\sigma_x, \mu_x + \Phi^{-1}(1 - \frac{\alpha}{2})\sigma_x]$$

O estimador por intervalo é então

$$I^*(X) = [A(X) - C(n, v^2, \sigma_0^2), A(X) + C(n, v^2, \sigma_0^2)], \text{ com}$$

$$A(X) = \frac{\sigma_0^2 n \bar{X} + v^2 \mu_0}{\sigma_0^2 n + v^2} \quad \text{e} \quad C(n, v^2, \sigma_0^2) = \Phi^{-1}(1 - \frac{\alpha}{2}) \sqrt{\frac{\sigma_0^2 v^2}{v^2 + n \sigma_0^2}}$$

Estimação

- Exemplo 1: $X = (X_1, \dots, X_n)$ AAS do modelo normal de média θ e variância $v^2 > 0$. Suponhamos $\theta \sim N(\mu_0, \sigma_0^2)$, com $\mu_0 \in \mathbb{R}$ e $\sigma_0^2 > 0$. Então,

$\theta | X_1 = x_1, \dots, X_n = x_n \sim N(\mu_x, \sigma_x^2)$, onde

$$\mu_x = \frac{\sigma_0^2 n \bar{x} + v^2 \mu_0}{\sigma_0^2 n + v^2} \quad \text{e} \quad \sigma_x^2 = \frac{\sigma_0^2 v^2}{v^2 + n \sigma_0^2}.$$

O intervalo "central" de probabilidade (a posteriori) $1 - \alpha$ é

$$I^*(x) = [\mu_x - \Phi^{-1}(1 - \frac{\alpha}{2})\sigma_x, \mu_x + \Phi^{-1}(1 - \frac{\alpha}{2})\sigma_x]$$

O estimador por intervalo é então

$$I^*(X) = [A(X) - C(n, v^2, \sigma_0^2), A(X) + C(n, v^2, \sigma_0^2)], \text{ com}$$

$$A(X) = \frac{\sigma_0^2 n \bar{X} + v^2 \mu_0}{\sigma_0^2 n + v^2} \quad \text{e} \quad C(n, v^2, \sigma_0^2) = \Phi^{-1}(1 - \frac{\alpha}{2}) \sqrt{\frac{\sigma_0^2 v^2}{v^2 + n \sigma_0^2}}$$

Estimação

- Exemplo 2: $X = (X_1, \dots, X_n)$ AAS do modelo Uniforme em $(0, \theta)$, $\theta > 0$. Suponhamos $\theta \sim \text{Pareto}(a, b)$, $a, b > 0$.
Então,

$$\theta | X_1 = x_1, \dots, X_n = x_n \sim \text{Pareto}(a + n, \max\{b, x_{(n)}\}), \text{ com } x_{(n)} = \max\{x_1, \dots, x_n\}.$$

O intervalo "central" de probabilidade (a posteriori) $1 - \alpha$ é

$$I^*(x) = [\max\{b, x_{(n)}\}(1 - \frac{\alpha}{2})^{-\frac{1}{a+n}}, \max\{b, x_{(n)}\}(\frac{\alpha}{2})^{-\frac{1}{a+n}}]$$

O estimador por intervalo é então

$$I^*(X) =$$

$$= [\max\{b, X_{(n)}\}(1 - \frac{\alpha}{2})^{-\frac{1}{a+n}}, \max\{b, X_{(n)}\}(\frac{\alpha}{2})^{-\frac{1}{a+n}}]$$

Estimação

- Exemplo 2: $X = (X_1, \dots, X_n)$ AAS do modelo Uniforme em $(0, \theta)$, $\theta > 0$. Suponhamos $\theta \sim \text{Pareto}(a, b)$, $a, b > 0$.
Então,

$$\theta | X_1 = x_1, \dots, X_n = x_n \sim \text{Pareto}(a + n, \max\{b, x_{(n)}\}), \text{ com } x_{(n)} = \max\{x_1, \dots, x_n\}.$$

O intervalo "central" de probabilidade (a posteriori) $1 - \alpha$ é

$$I^*(x) = [\max\{b, x_{(n)}\}(1 - \frac{\alpha}{2})^{-\frac{1}{a+n}}, \max\{b, x_{(n)}\}(\frac{\alpha}{2})^{-\frac{1}{a+n}}]$$

O estimador por intervalo é então

$$\begin{aligned} I^*(X) &= \\ &= [\max\{b, X_{(n)}\}(1 - \frac{\alpha}{2})^{-\frac{1}{a+n}}, \max\{b, X_{(n)}\}(\frac{\alpha}{2})^{-\frac{1}{a+n}}] \end{aligned}$$

Estimação

- No Exemplo 2, observe que o estimador $I' : \mathcal{X} \rightarrow \mathcal{I}$ que associa a cada $x \in \mathcal{X}$ o intervalo

$$[\max\{b, x_{(n)}\} , \max\{b, x_{(n)}\}(\alpha)^{-\frac{1}{a+n}}]$$

também satisfaz (como I^*) que,

$$\forall x \in \mathcal{X}, \mathbb{P}(\theta \in I'(x) | X = x) = 1 - \alpha.$$

No entanto, para todo $x \in \mathcal{X}$, $\lambda(I'(x)) < \lambda(I^*(x))$.

Em cenários como do Exemplo 2, estimativas diferentes de $I^*(x)$, por exemplo $I'(x)$, podem ser mais "interessantes" como "resumo" da distribuição a posteriori de θ dado $X = x$, $x \in \mathcal{X}$. Examinaremos agora tais estimadores (e otimalidade).

Estimação

- No Exemplo 2, observe que o estimador $I' : \mathcal{X} \rightarrow \mathcal{I}$ que associa a cada $x \in \mathcal{X}$ o intervalo

$$[\max\{b, x_{(n)}\} , \max\{b, x_{(n)}\}(\alpha)^{-\frac{1}{a+n}}]$$

também satisfaz (como I^*) que,

$$\forall x \in \mathcal{X}, \mathbb{P}(\theta \in I'(x) | X = x) = 1 - \alpha.$$

No entanto, para todo $x \in \mathcal{X}$, $\lambda(I'(x)) < \lambda(I^*(x))$.

Em cenários como do Exemplo 2, estimativas diferentes de $I^*(x)$, por exemplo $I'(x)$, podem ser mais "interessantes" como "resumo" da distribuição a posteriori de θ dado $X = x$, $x \in \mathcal{X}$. Examinaremos agora tais estimadores (e otimalidade).