

Inferência Estatística Comparada

AULA 10 - PRINCÍPIOS DE INFERÊNCIA

Resumo

- Até o momento, avaliamos, comparativamente, algumas abordagens à Inferência Estatística (frequentista, bayesiana e um pouco da verossimilhança) com relação aos seguintes aspectos:
- 1) Interpretação de probabilidade (Frequentista x Subjetiva)
- 2) Modelo Estatístico ($(\mathcal{X}, \mathcal{F}, \mathcal{P})$ versus $(\Theta \times \mathcal{X}, \mathcal{A}, \mathbb{P})$)
- 3) Natureza dos elementos básicos em inferência:
 - parâmetro
 - distribuição a priori (marginal) para o parâmetro
 - IID X Permutabilidade

Resumo

- Até o momento, avaliamos, comparativamente, algumas abordagens à Inferência Estatística (frequentista, bayesiana e um pouco da verossimilhança) com relação aos seguintes aspectos:
- 1) Interpretação de probabilidade (Frequentista x Subjetiva)
- 2) Modelo Estatístico ($(\mathcal{X}, \mathcal{F}, \mathcal{P})$ versus $(\Theta \times \mathcal{X}, \mathcal{A}, \mathbb{P})$)
- 3) Natureza dos elementos básicos em inferência:
 - parâmetro
 - distribuição a priori (marginal) para o parâmetro
 - IID X Permutabilidade

Resumo

- Até o momento, avaliamos, comparativamente, algumas abordagens à Inferência Estatística (frequentista, bayesiana e um pouco da verossimilhança) com relação aos seguintes aspectos:
- 1) Interpretação de probabilidade (Frequentista x Subjetiva)
- 2) Modelo Estatístico
($(\mathcal{X}, \mathcal{F}, \mathcal{P})$ versus $(\Theta \times \mathcal{X}, \mathcal{A}, \mathbb{P})$)
- 3) Natureza dos elementos básicos em inferência:
 - parâmetro
 - distribuição a priori (marginal) para o parâmetro
 - IID X Permutabilidade

Resumo

- Até o momento, avaliamos, comparativamente, algumas abordagens à Inferência Estatística (frequentista, bayesiana e um pouco da verossimilhança) com relação aos seguintes aspectos:
- 1) Interpretação de probabilidade (Frequentista x Subjetiva)
- 2) Modelo Estatístico $(\mathcal{X}, \mathcal{F}, \mathcal{P})$ versus $(\Theta \times \mathcal{X}, \mathcal{A}, \mathbb{P})$
- 3) Natureza dos elementos básicos em inferência:
 - parâmetro
 - distribuição a priori (marginal) para o parâmetro
 - IID X Permutabilidade

Resumo

- Até o momento, avaliamos, comparativamente, algumas abordagens à Inferência Estatística (frequentista, bayesiana e um pouco da verossimilhança) com relação aos seguintes aspectos:
- 1) Interpretação de probabilidade (Frequentista x Subjetiva)
- 2) Modelo Estatístico $(\mathcal{X}, \mathcal{F}, \mathcal{P})$ versus $(\Theta \times \mathcal{X}, \mathcal{A}, \mathbb{P})$
- 3) Natureza dos elementos básicos em inferência:
 - parâmetro
 - distribuição a priori (marginal) para o parâmetro
 - IID X Permutabilidade

Resumo

- 4) Construção de procedimentos inferencias ótimos (estimação e testes de hipóteses):

Otimidade pré-experimentação (abordagem frequencista)

X

Otimidade via condicionamento (Teoria da Decisão Bayesiana e abordagem verossimilhancista)

- Em geral, procedimentos frequencistas são baseados em **integração** sobre o espaço amostral; procedimentos bayesianos são determinados via **condicionamento** ao ponto amostral observado.

Resumo

- 4) Construção de procedimentos inferencias ótimos (estimação e testes de hipóteses):

Otimalidade pré-experimentação (abordagem frequencista)

X

Otimalidade via condicionamento (Teoria da Decisão Bayesiana e abordagem verossimilhancista)

- Em geral, procedimentos frequencistas são baseados em **integração** sobre o espaço amostral; procedimentos bayesianos são determinados via **condicionamento** ao ponto amostral observado.

Resumo

- 4) Construção de procedimentos inferencias ótimos (estimação e testes de hipóteses):

Otimalidade pré-experimentação (abordagem frequencista)

X

Otimalidade via condicionamento (Teoria da Decisão Bayesiana e abordagem verossimilhancista)

- Em geral, procedimentos frequencistas são baseados em **integração** sobre o espaço amostral; procedimentos bayesianos são determinados via **condicionamento** ao ponto amostral observado.

Resumo

- i) PROBLEMA DE ESTIMACÃO:

a) Estimador não-viesado para θ :

$$\int_{\mathcal{X}} \delta(x) f(x|\theta) dx = \theta, \forall \theta \in \Theta, \text{ e}$$

$$\int_{\mathcal{X}} (\delta^*(x) - \theta)^2 f(x|\theta) dx \leq \int_{\mathcal{X}} (\delta(x) - \theta)^2 f(x|\theta) dx$$

b) Estimador de Bayes para θ :

$\delta_B^*(x)$ é obtido minimizando (em \mathcal{D}) $\mathbb{E}[L(d, \theta) \mid X = x]$.

Exemplo: $\delta(x) = \mathbb{E}(\theta \mid X = x)$

Resumo

- i) PROBLEMA DE ESTIMACÃO:

a) Estimador não-viesado para θ :

$$\int_{\mathcal{X}} \delta(x) f(x|\theta) dx = \theta, \forall \theta \in \Theta, \text{ e}$$

$$\int_{\mathcal{X}} (\delta^*(x) - \theta)^2 f(x|\theta) dx \leq \int_{\mathcal{X}} (\delta(x) - \theta)^2 f(x|\theta) dx$$

b) Estimador de Bayes para θ :

$\delta_B^*(x)$ é obtido minimizando (em \mathcal{D}) $\mathbb{E}[L(d, \theta) \mid \mathbf{X} = \mathbf{x}]$.

Exemplo: $\delta(x) = \mathbb{E}(\theta \mid \mathbf{X} = \mathbf{x})$

Resumo

- ii) PROBLEMA DE ESTIMAÇÃO POR INTERVALO:

a) Intervalo de confiança para θ :

$$\mathbb{P}(A(X) \leq \theta \leq B(X) \mid \theta) \geq \gamma, \forall \theta \in \Theta, \text{ ou}$$

$$\int_{\mathcal{X}} \mathbb{I}_{[A(x), B(x)]}(\theta) f(x|\theta) dx \geq \gamma, \forall \theta \in \Theta$$

b) Intervalo de probabilidade (credibilidade) para θ :

$$\mathbb{P}(A(x) \leq \theta \leq B(x) \mid X = x) \geq \gamma, \text{ ou}$$

$$\int_{[A(x), B(x)]} f(\theta \mid X = x) d\theta \geq \gamma, [A(x), B(x)] \subset \Theta.$$

Resumo

- ii) PROBLEMA DE ESTIMAÇÃO POR INTERVALO:

a) Intervalo de confiança para θ :

$$\mathbb{P}(A(X) \leq \theta \leq B(X) \mid \theta) \geq \gamma, \forall \theta \in \Theta, \text{ ou}$$

$$\int_{\mathcal{X}} \mathbb{I}_{[A(x), B(x)]}(\theta) f(x|\theta) dx \geq \gamma, \forall \theta \in \Theta$$

b) Intervalo de probabilidade (credibilidade) para θ :

$$\mathbb{P}(A(x) \leq \theta \leq B(x) \mid X = x) \geq \gamma, \text{ ou}$$

$$\int_{[A(x), B(x)]} f(\theta \mid X = x) d\theta \geq \gamma, [A(x), B(x)] \subset \Theta.$$

Resumo

● iii) PROBLEMA DE TESTE DE HIPÓTESES:

a) Teste UMP para as hipóteses $H_0 : \theta \in \Theta_0$ versus $\theta \in \Theta_1$:

$$\int_{\mathcal{X}} \mathbb{I}_{\varphi^{*-1}\{1\}}(x) f(x|\theta) dx \leq \alpha, \quad \forall \theta \in \Theta_0, \text{ e } \int_{\mathcal{X}} \mathbb{I}_{\varphi^{-1}\{1\}}(x) f(x|\theta) dx \geq \alpha, \quad \forall \theta \in \Theta_1,$$

$$\int_{\mathcal{X}} \mathbb{I}_{\varphi^{*-1}\{1\}}(x) f(x|\theta) dx \geq \int_{\mathcal{X}} \mathbb{I}_{\varphi^{-1}\{1\}}(x) f(x|\theta) dx, \quad \forall \theta \in \Theta_0.$$

b) Teste de Bayes com relação à perda $0 - 1 - c$ para H_0 versus H_1 :

$$\varphi_B^*(x) = 1 \Leftrightarrow \mathbb{P}(\theta \in \Theta_0 \mid X = x) < \frac{c}{c+1}, \text{ ou}$$

$$\int_{\Theta_0} f(\theta \mid X = x) d\theta < \frac{c}{c+1}.$$

Resumo

iii) PROBLEMA DE TESTE DE HIPÓTESES:

a) Teste UMP para as hipóteses $H_0 : \theta \in \Theta_0$ versus $\theta \in \Theta_1$:

$$\int_{\mathcal{X}} \mathbb{I}_{\varphi^{*-1}\{1\}}(x) f(x|\theta) dx \leq \alpha, \quad \forall \theta \in \Theta_0, \text{ e } \int_{\mathcal{X}} \mathbb{I}_{\varphi^{-1}\{1\}}(x) f(x|\theta) dx \geq \alpha, \quad \forall \theta \in \Theta_1,$$

$$\int_{\mathcal{X}} \mathbb{I}_{\varphi^{*-1}\{1\}}(x) f(x|\theta) dx \geq \int_{\mathcal{X}} \mathbb{I}_{\varphi^{-1}\{1\}}(x) f(x|\theta) dx, \quad \forall \theta \in \Theta_0.$$

b) Teste de Bayes com relação à perda $0 - 1 - c$ para H_0 versus H_1 :

$$\varphi_B^*(x) = 1 \Leftrightarrow \mathbb{P}(\theta \in \Theta_0 \mid X = x) < \frac{c}{c+1}, \text{ ou}$$

$$\int_{\Theta_0} f(\theta \mid X = x) d\theta < \frac{c}{c+1}.$$

Introdução

- Vamos examinar a partir de agora a concordância dos procedimentos inferenciais estudados com alguns princípios de inferência, princípios de como lidar (tratar) com a informação revelada pelos dados para fins inferenciais.
- Consideremos os seguintes exemplos:

Introdução

- Vamos examinar a partir de agora a concordância dos procedimentos inferenciais estudados com alguns princípios de inferência, princípios de como lidar (tratar) com a informação revelada pelos dados para fins inferenciais.
- Consideremos os seguintes exemplos:

Introdução

- Vamos examinar a partir de agora a concordância dos procedimentos inferenciais estudados com alguns princípios de inferência, princípios de como lidar (tratar) com a informação revelada pelos dados para fins inferenciais.
- Consideremos os seguintes exemplos:

Introdução

- 1) Seja $\Theta = (0, 1)$. Para inferir sobre θ , considere os seguintes experimentos supondo as observações (variáveis), dado θ , condicionalmente IID Bernoulli (θ):

a) Observa-se o número de "sucessos" em 10 observações, X , e

b) Registra-se o número de observações até a ocorrência do segundo "sucesso" (inclusive), Y .

Consideremos a seguinte realização (tanto para experimento a) quanto para experimento b)): o primeiro "sucesso" ocorre ao observarmos a sexta variável de Bernoulli e o segundo "sucesso" ocorre na décima observação. Note que tal realização corresponde a $X = 2$ e $Y = 10$ nos experimentos a) e b), respectivamente.

Introdução

- 1) Seja $\Theta = (0, 1)$. Para inferir sobre θ , considere os seguintes experimentos supondo as observações (variáveis), dado θ , condicionalmente IID Bernoulli (θ):
 - a) Observa-se o número de "sucessos" em 10 observações, X , e
 - b) Registra-se o número de observações até a ocorrência do segundo "sucesso" (inclusive), Y .

Consideremos a seguinte realização (tanto para experimento a) quanto para experimento b)): o primeiro "sucesso" ocorre ao observarmos a sexta variável de Bernoulli e o segundo "sucesso" ocorre na décima observação. Note que tal realização corresponde a $X = 2$ e $Y = 10$ nos experimentos a) e b), respectivamente.

Introdução

- Quais conclusões sobre θ podemos obter a partir dos experimentos a) e b) ? Quais inferenciais podemos fazer sobre θ a partir desses experimentos? Observe que

Experimento **a)**: $X|\theta \sim \text{Binomial}(10, \theta)$ e

Experimento **b)**: $Y|\theta \sim \text{BN}(2, \theta)$. Assim:

$$V_2^a(\theta) = \mathbb{P}(X = 2|\theta) = \binom{10}{2}\theta^2(1-\theta)^8 \text{ e}$$

$$V_{10}^b(\theta) = \mathbb{P}(Y = 10|\theta) = \binom{9}{1}\theta^2(1-\theta)^8$$

Note que, **para todo** $\theta \in [0, 1]$,

$$V_2^a(\theta) = 5 \cdot V_{10}^b(\theta)$$

Introdução

- Quais conclusões sobre θ podemos obter a partir dos experimentos a) e b) ? Quais inferenciais podemos fazer sobre θ a partir desses experimentos? Observe que

Experimento **a)**: $X|\theta \sim \text{Binomial}(10, \theta)$ e

Experimento **b)**: $Y|\theta \sim \text{BN}(2, \theta)$. Assim:

$$V_2^a(\theta) = \mathbb{P}(X = 2|\theta) = \binom{10}{2}\theta^2(1 - \theta)^8 \text{ e}$$

$$V_{10}^b(\theta) = \mathbb{P}(Y = 10|\theta) = \binom{9}{1}\theta^2(1 - \theta)^8$$

Note que, **para todo** $\theta \in [0, 1]$,

$$V_2^a(\theta) = 5 \cdot V_{10}^b(\theta)$$

Introdução

- Inferências:

1) Estimativas de máxima verossimilhança coincidem:

$$\delta_{MV}^a(2) = \delta_{MV}^b(10) = \frac{2}{10} \quad (\delta_{MV}^a(X) = \frac{X}{10} \text{ e } \delta_{MV}^b(Y) = \frac{2}{Y})$$

("likelihood intervals" também coincidem)

2) Operação bayesiana - distribuições a posteriori coincidem:

$$\theta \mid X = 2 \sim \theta \mid Y = 10 ,$$

contra qualquer distribuição a priori (comum sob os dois experimentos) para θ . Procedimentos derivados da posteriori, consequentemente, também coincidem.

Introdução

- Inferências:

1) Estimativas de máxima verossimilhança coincidem:

$$\delta_{MV}^a(2) = \delta_{MV}^b(10) = \frac{2}{10} \quad (\delta_{MV}^a(X) = \frac{X}{10} \text{ e } \delta_{MV}^b(Y) = \frac{2}{Y})$$

("likelihood intervals" também coincidem)

2) Operação bayesiana - distribuições a posteriori coincidem:

$$\theta \mid X = 2 \sim \theta \mid Y = 10 ,$$

contra qualquer distribuição a priori (comum sob os dois experimentos) para θ . Procedimentos derivados da posteriori, consequentemente, também coincidem.

Introdução

- Inferências:

3) Estimativa baseada em estimador não-viesado:

$$\delta_{NV}^a(2) = \frac{2}{10} \quad \text{e} \quad \delta_{NV}^b(10) = \frac{2-1}{10-1} = \frac{1}{9}$$

Lembrete:

$$Y \sim BN(k, \theta), \quad k > 1 \Rightarrow \mathbb{E}\left(\frac{k-1}{Y-1} \mid \theta\right) = \theta, \quad \forall \theta \in (0, 1)$$

Diferentemente do que ocorre com EMV e operação bayesiana, as estimativas baseadas em estimadores não-viesados são diferentes nesse caso (de proporcionalidade entre as funções de verossimilhança geradas por $X = 2$ e $Y = 10$).

Introdução

- Inferências:

3) Estimativa baseada em estimador não-viesado:

$$\delta_{NV}^a(2) = \frac{2}{10} \quad \text{e} \quad \delta_{NV}^b(10) = \frac{2-1}{10-1} = \frac{1}{9}$$

Lembrete:

$$Y \sim BN(k, \theta), \quad k > 1 \quad \Rightarrow \quad \mathbb{E}\left(\frac{k-1}{Y-1} \mid \theta\right) = \theta, \quad \forall \theta \in (0, 1)$$

Diferentemente do que ocorre com EMV e operação bayesiana, as estimativas baseadas em estimadores não-viesados são diferentes nesse caso (de proporcionalidade entre as funções de verossimilhança geradas por $X = 2$ e $Y = 10$).

Introdução

- 2) Seja $\Theta = \{\theta_0, \theta_1\}$.

Experimento **a)** - Observação de X ($\mathcal{X} = \{1, 2, 3, 4, 5\}$):

x	1	2	3	4	5
$P(X = x \mid \theta_0)$	0,05	0,20	0,15	0,40	0,20
$P(X = x \mid \theta_1)$	0,20	0,40	0,15	0,20	0,05

Experimento **b)** - Observação de Y ($\mathcal{Y} = \{1, 2, 3, 4, 5\}$):

y	1	2	3	4	5
$P(Y = y \mid \theta_0)$	0,04	0,01	0,77	0,02	0,16
$P(Y = y \mid \theta_1)$	0,16	0,02	0,77	0,01	0,04

$$V_i^a(\theta) = k(i) \cdot V_i^b(\theta) \text{ , para todo } \theta \in \Theta \text{ , } i \in \mathcal{X}.$$

(por exemplo, $k(1) = 1,25$; $k(2) = 20$, etc.)

Introdução

- 2) Seja $\Theta = \{\theta_0, \theta_1\}$.

Experimento **a)** - Observação de X ($\mathcal{X} = \{1, 2, 3, 4, 5\}$):

x	1	2	3	4	5
$P(X = x \mid \theta_0)$	0,05	0,20	0,15	0,40	0,20
$P(X = x \mid \theta_1)$	0,20	0,40	0,15	0,20	0,05

Experimento **b)** - Observação de Y ($\mathcal{Y} = \{1, 2, 3, 4, 5\}$):

y	1	2	3	4	5
$P(Y = y \mid \theta_0)$	0,04	0,01	0,77	0,02	0,16
$P(Y = y \mid \theta_1)$	0,16	0,02	0,77	0,01	0,04

$$V_i^{a)}(\theta) = k(i) \cdot V_i^{b)}(\theta) \text{ , para todo } \theta \in \Theta \text{ , } i \in \mathcal{X}.$$

(por exemplo, $k(1) = 1,25$; $k(2) = 20$, etc.)

Introdução

- Inferências:

1) Estimadores de máxima verossimilhança: como, para todo $i \in \mathcal{X}$,

$$V_i^a)(\theta) = k(i) \cdot V_i^b)(\theta) \text{ , para todo } \theta \in \{\theta_0, \theta_1\} \text{ ,}$$

EMV (não apenas uma ou outra estimativa) para θ coincidem.

2) Operação bayesiana - (todas) distribuições a posteriori coincidem, isto é

$$\theta \mid X = i \sim \theta \mid Y = i \text{ , para cada } i \in \mathcal{X} \text{ ,}$$

contra qualquer distribuição a priori (comum sob os dois experimentos) para θ .

Introdução

- Inferências:

1) Estimadores de máxima verossimilhança: como, para todo $i \in \mathcal{X}$,

$$V_i^a(\theta) = k(i) \cdot V_i^b(\theta) \text{ , para todo } \theta \in \{\theta_0, \theta_1\} \text{ ,}$$

EMV (não apenas uma ou outra estimativa) para θ coincidem.

2) Operação bayesiana - (todas) distribuições a posteriori coincidem, isto é

$$\theta \mid X = i \sim \theta \mid Y = i \text{ , para cada } i \in \mathcal{X} \text{ ,}$$

contra qualquer distribuição a priori (comum sob os dois experimentos) para θ .

Introdução

- Além disso, quaisquer procedimentos derivados da posteriori (estimativas, decisões em testes de hipóteses, etc.) também coincidem.

3) Testes MP de nível 0,05 para $H_0 : \theta = \theta_0 \times H_1 : \theta = \theta_1$:

No experimento **a)**: $\varphi_{MP}^a(x) = \begin{cases} 1, & \text{se } x = 1 \\ 0, & \text{se } x \neq 1 \end{cases}$

No experimento **b)**: $\varphi_{MP}^b(y) = \begin{cases} 1, & \text{se } y \in \{1, 2\} \\ 0, & \text{se } y \in \{3, 4, 5\} \end{cases}$

Note que $\varphi_{MP}^a(2) \neq \varphi_{MP}^b(2)$, ainda que

$$V_2^a(\theta) = 20 \cdot V_2^b(\theta), \text{ para todo } \theta \in \Theta.$$

Introdução

- Além disso, quaisquer procedimentos derivados da posteriori (estimativas, decisões em testes de hipóteses, etc.) também coincidem.

3) Testes MP de nível 0,05 para $H_0 : \theta = \theta_0 \times H_1 : \theta = \theta_1$:

No experimento **a)**: $\varphi_{MP}^a(x) = \begin{cases} 1, & \text{se } x = 1 \\ 0, & \text{se } x \neq 1 \end{cases}$

No experimento **b)**: $\varphi_{MP}^b(y) = \begin{cases} 1, & \text{se } y \in \{1, 2\} \\ 0, & \text{se } y \in \{3, 4, 5\} \end{cases}$

Note que $\varphi_{MP}^a(2) \neq \varphi_{MP}^b(2)$, ainda que

$$V_2^a(\theta) = 20 \cdot V_2^b(\theta), \text{ para todo } \theta \in \Theta.$$

Introdução

- **Pergunta:** Nesse caso, é razoável esperar que as conclusões sobre H_0 versus H_1 sejam distintas a partir de $X = 2$ e $Y = 2$ se

$$V_2^a)(\theta) = 20 \cdot V_2^b)(\theta) , \text{ para todo } \theta \in \Theta , \text{ isto é,}$$

visto que as funções de verossimilhança geradas por $X = 2$ e $Y = 2$ nos experimentos a) e b), respectivamente, são proporcionais (e, conseqüentemente, encerram essencialmente "a mesma informação" sobre θ) ?

Discutiremos essa questão (e outras de natureza similar - e.g. : Exemplo 1) a partir de alguns princípios de inferência. Tais princípios estabelecem como tratar a informação revelada pelos dados para fins inferenciais sobre o parâmetro de interesse; o que esperar de inferências (conclusões) feitas sobre θ .

Introdução

- **Pergunta:** Nesse caso, é razoável esperar que as conclusões sobre H_0 versus H_1 sejam distintas a partir de $X = 2$ e $Y = 2$ se

$$V_2^a)(\theta) = 20 \cdot V_2^b)(\theta) \text{ , para todo } \theta \in \Theta \text{ , isto é,}$$

visto que as funções de verossimilhança geradas por $X = 2$ e $Y = 2$ nos experimentos a) e b), respectivamente, são proporcionais (e, conseqüentemente, encerram essencialmente "a mesma informação" sobre θ) ?

Discutiremos essa questão (e outras de natureza similar - e.g. : Exemplo 1) a partir de alguns princípios de inferência. Tais princípios estabelecem como tratar a informação revelada pelos dados para fins inferenciais sobre o parâmetro de interesse; o que esperar de inferências (conclusões) feitas sobre θ .

Princípios de Inferência

- Vimos que a função de verossimilhança gerada pelo ponto amostral $x \in \mathcal{X}$, $V_x(\cdot)$, contém toda informação amostral (do ponto amostral x) sobre o parâmetro θ .
- Pré-experimentação: $\mathcal{V} = \{V_x : x \in \mathcal{X}\}$
- Pós-experimentação: após a observação de $x \in \mathcal{X}$, precisamos de (toda) \mathcal{V} para fins inferenciais? Ou basta V_x ? Ou é necessário outro objeto?
- **Princípio da Verossimilhança (PV):** Toda (qualquer) inferência sobre θ (parâmetro de interesse) deve depender de $x \in \mathcal{X}$ (e do experimento que o gerou) apenas através de V_x .
- Vamos examinar esse princípio (e alguns outros) a partir da formulação de A. Birnbaum (1962).

Princípios de Inferência

- Vimos que a função de verossimilhança gerada pelo ponto amostral $x \in \mathcal{X}$, $V_x(\cdot)$, contém toda informação amostral (do ponto amostral x) sobre o parâmetro θ .
- Pré-experimentação: $\mathcal{V} = \{V_x : x \in \mathcal{X}\}$
- Pós-experimentação: após a observação de $x \in \mathcal{X}$, precisamos de (toda) \mathcal{V} para fins inferenciais? Ou basta V_x ? Ou é necessário outro objeto?
- **Princípio da Verossimilhança (PV):** Toda (qualquer) inferência sobre θ (parâmetro de interesse) deve depender de $x \in \mathcal{X}$ (e do experimento que o gerou) apenas através de V_x .
- Vamos examinar esse princípio (e alguns outros) a partir da formulação de A. Birnbaum (1962).

Princípios de Inferência

- Vimos que a função de verossimilhança gerada pelo ponto amostral $x \in \mathcal{X}$, $V_x(\cdot)$, contém toda informação amostral (do ponto amostral x) sobre o parâmetro θ .
- Pré-experimentação: $\mathcal{V} = \{V_x : x \in \mathcal{X}\}$
- Pós-experimentação: após a observação de $x \in \mathcal{X}$, precisamos de (toda) \mathcal{V} para fins inferenciais? Ou basta V_x ? Ou é necessário outro objeto?
- **Princípio da Verossimilhança (PV):** Toda (qualquer) inferência sobre θ (parâmetro de interesse) deve depender de $x \in \mathcal{X}$ (e do experimento que o gerou) apenas através de V_x .
- Vamos examinar esse princípio (e alguns outros) a partir da formulação de A. Birnbaum (1962).

Princípios de Inferência

- Vimos que a função de verossimilhança gerada pelo ponto amostral $x \in \mathcal{X}$, $V_x(\cdot)$, contém toda informação amostral (do ponto amostral x) sobre o parâmetro θ .
- Pré-experimentação: $\mathcal{V} = \{V_x : x \in \mathcal{X}\}$
- Pós-experimentação: após a observação de $x \in \mathcal{X}$, precisamos de (toda) \mathcal{V} para fins inferenciais? Ou basta V_x ? Ou é necessário outro objeto?
- **Princípio da Verossimilhança (PV):** Toda (qualquer) inferência sobre θ (parâmetro de interesse) deve depender de $x \in \mathcal{X}$ (e do experimento que o gerou) apenas através de V_x .
- Vamos examinar esse princípio (e alguns outros) a partir da formulação de A. Birnbaum (1962).

Princípios de Inferência

- Vimos que a função de verossimilhança gerada pelo ponto amostral $x \in \mathcal{X}$, $V_x(\cdot)$, contém toda informação amostral (do ponto amostral x) sobre o parâmetro θ .
- Pré-experimentação: $\mathcal{V} = \{V_x : x \in \mathcal{X}\}$
- Pós-experimentação: após a observação de $x \in \mathcal{X}$, precisamos de (toda) \mathcal{V} para fins inferenciais? Ou basta V_x ? Ou é necessário outro objeto?
- **Princípio da Verossimilhança (PV):** Toda (qualquer) inferência sobre θ (parâmetro de interesse) deve depender de $x \in \mathcal{X}$ (e do experimento que o gerou) apenas através de V_x .
- Vamos examinar esse princípio (e alguns outros) a partir da formulação de A. Birnbaum (1962).

Princípios de Inferência

- Vimos que a função de verossimilhança gerada pelo ponto amostral $x \in \mathcal{X}$, $V_x(\cdot)$, contém toda informação amostral (do ponto amostral x) sobre o parâmetro θ .
- Pré-experimentação: $\mathcal{V} = \{V_x : x \in \mathcal{X}\}$
- Pós-experimentação: após a observação de $x \in \mathcal{X}$, precisamos de (toda) \mathcal{V} para fins inferenciais? Ou basta V_x ? Ou é necessário outro objeto?
- **Princípio da Verossimilhança (PV):** Toda (qualquer) inferência sobre θ (parâmetro de interesse) deve depender de $x \in \mathcal{X}$ (e do experimento que o gerou) apenas através de V_x .
- Vamos examinar esse princípio (e alguns outros) a partir da formulação de A. Birnbaum (1962).

Princípios de Inferência

- "Likelihood" - breve resumo (Edwards (1972,1974)):
- Fisher (1921)
- Bartlett (1936,1952) , Barnard (1947, 1949) , Fisher (1956): primeiras menções ao PV.
- Birnbaum (1962): desenvolvimento formal do PV a partir de conceitos e princípios mais "simples" ("intuitivos") como suficiência e condicionalidade.
- Barnard (1962), Pratt (1965), Birnbaum (1972), Cox e Hinkley (1974), Basu (1975), Dawid (1981), Barnett (1982), Berger e Wolpert (1988) (*); recentemente Wechsler, Pereira e Marques (2008), Mayo (2014), entre outros.
- Teses: Lurdes Y. T. Inoue (1995) ; V. Fossaluza (2008) ; Pedro F. C. Silva (UFMG - 2017); Jaime E. L. Curivil (2019)

Princípios de Inferência

- "Likelihood" - breve resumo (Edwards (1972,1974)):
- Fisher (1921)
- Bartlett (1936,1952) , Barnard (1947, 1949) , Fisher (1956): primeiras menções ao PV.
- Birnbaum (1962): desenvolvimento formal do PV a partir de conceitos e princípios mais "simples" ("intuitivos") como suficiência e condicionalidade.
- Barnard (1962), Pratt (1965), Birnbaum (1972), Cox e Hinkley (1974), Basu (1975), Dawid (1981), Barnett (1982), Berger e Wolpert (1988) (*); recentemente Wechsler, Pereira e Marques (2008), Mayo (2014), entre outros.
- Teses: Lurdes Y. T. Inoue (1995) ; V. Fossaluza (2008) ; Pedro F. C. Silva (UFMG - 2017); Jaime E. L. Curivil (2019)

Princípios de Inferência

- "Likelihood" - breve resumo (Edwards (1972,1974)):
- Fisher (1921)
- Bartlett (1936,1952) , Barnard (1947, 1949) , Fisher (1956): primeiras menções ao PV.
- Birnbaum (1962): desenvolvimento formal do PV a partir de conceitos e princípios mais "simples" ("intuitivos") como suficiência e condicionalidade.
- Barnard (1962), Pratt (1965), Birnbaum (1972), Cox e Hinkley (1974), Basu (1975), Dawid (1981), Barnett (1982), Berger e Wolpert (1988) (*); recentemente Wechsler, Pereira e Marques (2008), Mayo (2014), entre outros.
- Teses: Lurdes Y. T. Inoue (1995) ; V. Fossaluza (2008) ; Pedro F. C. Silva (UFMG - 2017); Jaime E. L. Curivil (2019)

Princípios de Inferência

- "Likelihood" - breve resumo (Edwards (1972,1974)):
- Fisher (1921)
- Bartlett (1936,1952) , Barnard (1947, 1949) , Fisher (1956): primeiras menções ao PV.
- Birnbaum (1962): desenvolvimento formal do PV a partir de conceitos e princípios mais "simples" ("intuitivos") como suficiência e condicionalidade.
- Barnard (1962), Pratt (1965), Birnbaum (1972), Cox e Hinkley (1974), Basu (1975), Dawid (1981), Barnett (1982), Berger e Wolpert (1988) (*); recentemente Wechsler, Pereira e Marques (2008), Mayo (2014), entre outros.
- Teses: Lurdes Y. T. Inoue (1995) ; V. Fossaluza (2008) ; Pedro F. C. Silva (UFMG - 2017); Jaime E. L. Curivil (2019)

Princípios de Inferência

- "Likelihood" - breve resumo (Edwards (1972,1974)):
- Fisher (1921)
- Bartlett (1936,1952) , Barnard (1947, 1949) , Fisher (1956): primeiras menções ao PV.
- Birnbaum (1962): desenvolvimento formal do PV a partir de conceitos e princípios mais "simples" ("intuitivos") como suficiência e condicionalidade.
- Barnard (1962), Pratt (1965), Birnbaum (1972), Cox e Hinkley (1974), Basu (1975), Dawid (1981), Barnett (1982), Berger e Wolpert (1988) (*); recentemente Wechsler, Pereira e Marques (2008), Mayo (2014), entre outros.
- Teses: Lurdes Y. T. Inoue (1995) ; V. Fossaluza (2008) ; Pedro F. C. Silva (UFMG - 2017); Jaime E. L. Curivil (2019)

Princípios de Inferência

- "Likelihood" - breve resumo (Edwards (1972,1974)):
- Fisher (1921)
- Bartlett (1936,1952) , Barnard (1947, 1949) , Fisher (1956): primeiras menções ao PV.
- Birnbaum (1962): desenvolvimento formal do PV a partir de conceitos e princípios mais "simples" ("intuitivos") como suficiência e condicionalidade.
- Barnard (1962), Pratt (1965), Birnbaum (1972), Cox e Hinkley (1974), Basu (1975), Dawid (1981), Barnett (1982), Berger e Wolpert (1988) (*); recentemente Wechsler, Pereira e Marques (2008), Mayo (2014), entre outros.
- Teses: Lurdes Y. T. Inoue (1995) ; V. Fossaluza (2008) ; Pedro F. C. Silva (UFMG - 2017); Jaime E. L. Curivil (2019)

Princípios de Inferência

- "Likelihood" - breve resumo (Edwards (1972,1974)):
- Fisher (1921)
- Bartlett (1936,1952) , Barnard (1947, 1949) , Fisher (1956): primeiras menções ao PV.
- Birnbaum (1962): desenvolvimento formal do PV a partir de conceitos e princípios mais "simples" ("intuitivos") como suficiência e condicionalidade.
- Barnard (1962), Pratt (1965), Birnbaum (1972), Cox e Hinkley (1974), Basu (1975), Dawid (1981), Barnett (1982), Berger e Wolpert (1988) (*); recentemente Wechsler, Pereira e Marques (2008), Mayo (2014), entre outros.
- Teses: Lurdes Y. T. Inoue (1995) ; V. Fossaluza (2008) ; Pedro F. C. Silva (UFMG - 2017); Jaime E. L. Curivil (2019)

Princípios de Inferência

- Sejam θ , X , Θ , \mathcal{X} e $\mathcal{P} = \{\mathbb{P}_\theta : \theta \in \Theta\}$ como definidos anteriormente.
- DEFINIÇÃO:** Um experimento E para θ é um trio (X, θ, \mathcal{P}) , onde X é a quantidade observada segundo \mathbb{P}_θ , $\theta \in \Theta$.

Notação: $E = (X, \theta, \mathcal{P})$ (alternativamente, $(\mathcal{X}, \Theta, \mathcal{P})$).

- Exemplo 1: Seja $n \in \mathbb{N}^*$. Consideremos $\mathcal{X} = \{0, 1, \dots, n\}$, $\Theta = (0, 1)$ e $\mathcal{P} = \{\mathbb{P}_\theta : \theta \in (0, 1)\}$ tal que

$$\mathbb{P}_\theta(\{x\}) = \mathbb{P}(X = x|\theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x} \mathbb{I}_{\{0,1,\dots,n\}}(x)$$

$E = (\mathcal{X}, \Theta, \mathcal{P})$ é um experimento para θ .

Princípios de Inferência

- Sejam θ , X , Θ , \mathcal{X} e $\mathcal{P} = \{\mathbb{P}_\theta : \theta \in \Theta\}$ como definidos anteriormente.
- DEFINIÇÃO:** Um experimento E para θ é um trio (X, θ, \mathcal{P}) , onde X é a quantidade observada segundo \mathbb{P}_θ , $\theta \in \Theta$.

Notação: $E = (X, \theta, \mathcal{P})$ (alternativamente, $(\mathcal{X}, \Theta, \mathcal{P})$).

- Exemplo 1: Seja $n \in \mathbb{N}^*$. Consideremos $\mathcal{X} = \{0, 1, \dots, n\}$, $\Theta = (0, 1)$ e $\mathcal{P} = \{\mathbb{P}_\theta : \theta \in (0, 1)\}$ tal que

$$\mathbb{P}_\theta(\{x\}) = \mathbb{P}(X = x|\theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x} \mathbb{I}_{\{0,1,\dots,n\}}(x)$$

$E = (\mathcal{X}, \Theta, \mathcal{P})$ é um experimento para θ .

Princípios de Inferência

- Sejam θ , X , Θ , \mathcal{X} e $\mathcal{P} = \{\mathbb{P}_\theta : \theta \in \Theta\}$ como definidos anteriormente.
- DEFINIÇÃO:** Um experimento E para θ é um trio (X, θ, \mathcal{P}) , onde X é a quantidade observada segundo \mathbb{P}_θ , $\theta \in \Theta$.

Notação: $E = (X, \theta, \mathcal{P})$ (alternativamente, $(\mathcal{X}, \Theta, \mathcal{P})$).

- Exemplo 1: Seja $n \in \mathbb{N}^*$. Consideremos $\mathcal{X} = \{0, 1, \dots, n\}$, $\Theta = (0, 1)$ e $\mathcal{P} = \{\mathbb{P}_\theta : \theta \in (0, 1)\}$ tal que

$$\mathbb{P}_\theta(\{x\}) = \mathbb{P}(X = x|\theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x} \mathbb{I}_{\{0,1,\dots,n\}}(x)$$

$E = (\mathcal{X}, \Theta, \mathcal{P})$ é um experimento para θ .

Princípios de Inferência

- Sejam θ , X , Θ , \mathcal{X} e $\mathcal{P} = \{\mathbb{P}_\theta : \theta \in \Theta\}$ como definidos anteriormente.
- DEFINIÇÃO:** Um experimento E para θ é um trio (X, θ, \mathcal{P}) , onde X é a quantidade observada segundo \mathbb{P}_θ , $\theta \in \Theta$.

Notação: $E = (X, \theta, \mathcal{P})$ (alternativamente, $(\mathcal{X}, \Theta, \mathcal{P})$).

- Exemplo 1:** Seja $n \in \mathbb{N}^*$. Consideremos $\mathcal{X} = \{0, 1, \dots, n\}$, $\Theta = (0, 1)$ e $\mathcal{P} = \{\mathbb{P}_\theta : \theta \in (0, 1)\}$ tal que

$$\mathbb{P}_\theta(\{x\}) = \mathbb{P}(X = x|\theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x} \mathbb{I}_{\{0,1,\dots,n\}}(x)$$

$E = (\mathcal{X}, \Theta, \mathcal{P})$ é um experimento para θ .

Princípios de Inferência

- Exemplo 2: Seja $k \in \mathbb{N}^*$. Consideremos os conjuntos $\mathcal{Y} = \{k, k+1, k+2, \dots\}$, $\Theta = (0, 1)$ e $\mathcal{P}' = \{\mathbb{P}'_\theta : \theta \in (0, 1)\}$ tal que

$$\mathbb{P}'_\theta(\{y\}) = \mathbb{P}'(Y = y|\theta) = \binom{y-1}{k-1} \theta^k (1-\theta)^{y-k} \mathbb{I}_{\{k, k+1, \dots\}}(y)$$

$E' = (\mathcal{Y}, \Theta, \mathcal{P}')$ é um experimento para θ .

- O conjunto de experimentos para (o mesmo) θ é denotado por \mathcal{E}_θ (ou \mathcal{E}_Θ).
- Dos exemplos 1 e 2, temos que $E, E' \in \mathcal{E}_\theta$ (admitindo que tais experimentos dizem respeito a mesma quantidade de interesse θ).

Princípios de Inferência

- Exemplo 2: Seja $k \in \mathbb{N}^*$. Consideremos os conjuntos $\mathcal{Y} = \{k, k+1, k+2, \dots\}$, $\Theta = (0, 1)$ e $\mathcal{P}' = \{\mathbb{P}'_\theta : \theta \in (0, 1)\}$ tal que

$$\mathbb{P}'_\theta(\{y\}) = \mathbb{P}'(Y = y|\theta) = \binom{y-1}{k-1} \theta^k (1-\theta)^{y-k} \mathbb{I}_{\{k, k+1, \dots\}}(y)$$

$E' = (\mathcal{Y}, \Theta, \mathcal{P}')$ é um experimento para θ .

- O conjunto de experimentos para (o mesmo) θ é denotado por \mathcal{E}_θ (ou \mathcal{E}_Θ).
- Dos exemplos 1 e 2, temos que $E, E' \in \mathcal{E}_\theta$ (admitindo que tais experimentos dizem respeito a mesma quantidade de interesse θ).

Princípios de Inferência

- Exemplo 2: Seja $k \in \mathbb{N}^*$. Consideremos os conjuntos $\mathcal{Y} = \{k, k+1, k+2, \dots\}$, $\Theta = (0, 1)$ e $\mathcal{P}' = \{\mathbb{P}'_\theta : \theta \in (0, 1)\}$ tal que

$$\mathbb{P}'_\theta(\{y\}) = \mathbb{P}'(Y = y|\theta) = \binom{y-1}{k-1} \theta^k (1-\theta)^{y-k} \mathbb{I}_{\{k, k+1, \dots\}}(y)$$

$E' = (\mathcal{Y}, \Theta, \mathcal{P}')$ é um experimento para θ .

- O conjunto de experimentos para (o mesmo) θ é denotado por \mathcal{E}_θ (ou \mathcal{E}_Θ).
- Dos exemplos 1 e 2, temos que $E, E' \in \mathcal{E}_\theta$ (admitindo que tais experimentos dizem respeito a mesma quantidade de interesse θ).

Princípios de Inferência

- Exemplo 2: Seja $k \in \mathbb{N}^*$. Consideremos os conjuntos $\mathcal{Y} = \{k, k+1, k+2, \dots\}$, $\Theta = (0, 1)$ e $\mathcal{P}' = \{\mathbb{P}'_\theta : \theta \in (0, 1)\}$ tal que

$$\mathbb{P}'_\theta(\{y\}) = \mathbb{P}'(Y = y|\theta) = \binom{y-1}{k-1} \theta^k (1-\theta)^{y-k} \mathbb{I}_{\{k, k+1, \dots\}}(y)$$

$E' = (\mathcal{Y}, \Theta, \mathcal{P}')$ é um experimento para θ .

- O conjunto de experimentos para (o mesmo) θ é denotado por \mathcal{E}_θ (ou \mathcal{E}_Θ).
- Dos exemplos 1 e 2, temos que $E, E' \in \mathcal{E}_\theta$ (admitindo que tais experimentos dizem respeito a mesma quantidade de interesse θ).

Princípios de Inferência

- Exemplo 3: Consideremos os conjuntos $\mathcal{X} = \mathbb{N}^n$, $\Theta = \mathbb{R}_+$ e $\mathcal{P} = \{\mathbb{P}_\theta : \theta > 0\}$ tal que

$$\begin{aligned} \mathbb{P}_\theta(\{(x_1, \dots, x_n)\}) &= \mathbb{P}(X = (x_1, \dots, x_n) | \theta) = \\ &= \mathbb{P}(X_1 = x_1, \dots, X_n = x_n | \theta) = \\ &= \frac{e^{-n\theta} \theta^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n x_i!} \prod_{i=1}^n \mathbb{I}_{\mathbb{N}}(x_i) \end{aligned}$$

$E = (\mathcal{X}, \Theta, \mathcal{P})$ é um experimento para θ .

- Finalmente, apresentamos a seguir o conceito de experimento misto (aleatorizado).

Princípios de Inferência

- Exemplo 3: Consideremos os conjuntos $\mathcal{X} = \mathbb{N}^n$, $\Theta = \mathbb{R}_+$ e $\mathcal{P} = \{\mathbb{P}_\theta : \theta > 0\}$ tal que

$$\begin{aligned}\mathbb{P}_\theta(\{(x_1, \dots, x_n)\}) &= \mathbb{P}(X = (x_1, \dots, x_n) | \theta) = \\ &= \mathbb{P}(X_1 = x_1, \dots, X_n = x_n | \theta) = \\ &= \frac{e^{-n\theta} \theta^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n x_i!} \prod_{i=1}^n \mathbb{I}_{\mathbb{N}}(x_i)\end{aligned}$$

$E = (\mathcal{X}, \Theta, \mathcal{P})$ é um experimento para θ .

- Finalmente, apresentamos a seguir o conceito de experimento misto (aleatorizado).

Princípios de Inferência

- Exemplo 3: Consideremos os conjuntos $\mathcal{X} = \mathbb{N}^n$, $\Theta = \mathbb{R}_+$ e $\mathcal{P} = \{\mathbb{P}_\theta : \theta > 0\}$ tal que

$$\begin{aligned}\mathbb{P}_\theta(\{(x_1, \dots, x_n)\}) &= \mathbb{P}(X = (x_1, \dots, x_n) | \theta) = \\ &= \mathbb{P}(X_1 = x_1, \dots, X_n = x_n | \theta) = \\ &= \frac{e^{-n\theta} \theta^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n x_i!} \prod_{i=1}^n \mathbb{I}_{\mathbb{N}}(x_i)\end{aligned}$$

$E = (\mathcal{X}, \Theta, \mathcal{P})$ é um experimento para θ .

- Finalmente, apresentamos a seguir o conceito de experimento misto (aleatorizado).

Princípios de Inferência

- **DEFINIÇÃO :** Sejam $E_1 = (X_1, \theta, \mathcal{P}_1)$ e $E_2 = (X_2, \theta, \mathcal{P}_2)$ dois experimentos para θ , com $X_j \in \mathcal{X}_j$ e $\mathcal{P}_j = \{\mathbb{P}_\theta^{(j)} : \theta \in \Theta\}$, $j = 1, 2$. Seja J uma variável aleatória Uniforme em $\{1, 2\}$ (independente de X_1 e X_2 e θ).

O experimento $E^* = (X^*, \theta, \mathcal{P}^*)$, com

$$X^* = \{1\} \times \mathcal{X}_1 \cup \{2\} \times \mathcal{X}_2 \text{ e}$$

\mathcal{P}^* satisfazendo

$$\mathbb{P}_\theta^*(\{(j, x_j)\}) = \mathbb{P}^*(X^* = (j, x_j) | \theta) = \frac{1}{2} \mathbb{P}_j(X_j = x_j | \theta)$$

é chamado experimento misto de E_1 e E_2 .

- O experimento E^* consiste na escolha, segundo a variável J , do experimento (E_1 ou E_2) a ser conduzido e, então, registrar uma observação do experimento escolhido.

Princípios de Inferência

- **DEFINIÇÃO :** Sejam $E_1 = (X_1, \theta, \mathcal{P}_1)$ e $E_2 = (X_2, \theta, \mathcal{P}_2)$ dois experimentos para θ , com $X_j \in \mathcal{X}_j$ e $\mathcal{P}_j = \{\mathbb{P}_\theta^{(j)} : \theta \in \Theta\}$, $j = 1, 2$. Seja J uma variável aleatória Uniforme em $\{1, 2\}$ (independente de X_1 e X_2 e θ).

O experimento $E^* = (X^*, \theta, \mathcal{P}^*)$, com

$$X^* = \{1\} \times \mathcal{X}_1 \cup \{2\} \times \mathcal{X}_2 \text{ e}$$

\mathcal{P}^* satisfazendo

$$\mathbb{P}_\theta^*(\{(j, x_j)\}) = \mathbb{P}^*(X^* = (j, x_j) | \theta) = \frac{1}{2} \mathbb{P}_j(X_j = x_j | \theta)$$

é chamado experimento misto de E_1 e E_2 .

- O experimento E^* consiste na escolha, segundo a variável J , do experimento (E_1 ou E_2) a ser conduzido e, então, registrar uma observação do experimento escolhido.

Princípios de Inferência

- **DEFINIÇÃO :** Sejam $E_1 = (X_1, \theta, \mathcal{P}_1)$ e $E_2 = (X_2, \theta, \mathcal{P}_2)$ dois experimentos para θ , com $X_j \in \mathcal{X}_j$ e $\mathcal{P}_j = \{\mathbb{P}_\theta^{(j)} : \theta \in \Theta\}$, $j = 1, 2$. Seja J uma variável aleatória Uniforme em $\{1, 2\}$ (independente de X_1 e X_2 e θ).

O experimento $E^* = (X^*, \theta, \mathcal{P}^*)$, com

$$X^* = \{1\} \times \mathcal{X}_1 \cup \{2\} \times \mathcal{X}_2 \text{ e}$$

\mathcal{P}^* satisfazendo

$$\mathbb{P}_\theta^*(\{(j, x_j)\}) = \mathbb{P}^*(X^* = (j, x_j) | \theta) = \frac{1}{2} \mathbb{P}_j(X_j = x_j | \theta)$$

é chamado experimento misto de E_1 e E_2 .

- O experimento E^* consiste na escolha, segundo a variável J , do experimento (E_1 ou E_2) a ser conduzido e, então, registrar uma observação do experimento escolhido.

Princípios de Inferência

- Exemplo 4: Retomando os exemplos 1) e 2), onde $\Theta = (0, 1)$, consideremos o experimento misto $E^* = (X^*, \theta, \mathcal{P}^*)$, com

$$X^* = \{1\} \times \{0, 1, \dots, n\} \cup \{2\} \times \{k, k+1, k+2, \dots\} \text{ e}$$

\mathcal{P}^* satisfazendo

$$\mathbb{P}_\theta^*(\{(1, x)\}) = \mathbb{P}^*(X^* = (1, x)|\theta) = \frac{1}{2} \mathbb{P}(X = x|\theta) \text{ e}$$

$$\mathbb{P}_\theta^*(\{(2, y)\}) = \mathbb{P}^*(X^* = (2, y)|\theta) = \frac{1}{2} \mathbb{P}'(Y = y|\theta)$$

O experimento E^* consiste em escolher qual dos experimentos deve ser conduzido, E (observação de $X|\theta \sim \text{Bin}(n, \theta)$) ou E' (observação de $Y|\theta \sim \text{BN}(k, \theta)$), e então registrar o valor da variável a ser observada segundo o experimento escolhido (X ou Y).

Princípios de Inferência

- Exemplo 4: Retomando os exemplos 1) e 2), onde $\Theta = (0, 1)$, consideremos o experimento misto $E^* = (X^*, \theta, \mathcal{P}^*)$, com

$$X^* = \{1\} \times \{0, 1, \dots, n\} \cup \{2\} \times \{k, k+1, k+2, \dots\} \quad \text{e}$$

\mathcal{P}^* satisfazendo

$$\mathbb{P}_\theta^*(\{(1, x)\}) = \mathbb{P}^*(X^* = (1, x)|\theta) = \frac{1}{2} \mathbb{P}(X = x|\theta) \quad \text{e}$$

$$\mathbb{P}_\theta^*(\{(2, y)\}) = \mathbb{P}^*(X^* = (2, y)|\theta) = \frac{1}{2} \mathbb{P}'(Y = y|\theta)$$

O experimento E^* consiste em escolher qual dos experimentos deve ser conduzido, E (observação de $X|\theta \sim \text{Bin}(n, \theta)$) ou E' (observação de $Y|\theta \sim \text{BN}(k, \theta)$), e então registrar o valor da variável a ser observada segundo o experimento escolhido (X ou Y).

Princípios de Inferência

- A partir da condução do experimento E e da observação de x , podemos inferir, tirar conclusões sobre θ . Tal inferência, conclusão sobre θ é denominada (Birnbaum (1962)) **Evidência sobre θ a partir de E e x , $Ev(e, x)$** .
- Afinal, qual é o significado de $Ev(E, x)$?
- Em princípio, não há restrição sobre $Ev(E, x)$: estimativa, decisão sobre hipóteses, etc.. (não precisa ser restrita aos problemas tradicionais de inferência estatística). Ênfase da abordagem é sobre **como $Ev(E, x)$ deve depender de E e x** .
- Críticas sobre a formulação original; revisão da formulação (Birnbaum (1972), dentre outros); introdução de relações de equivalência em $\mathcal{R}_\theta = \cup_{E \in \mathcal{E}_\theta} \{E\} \times \mathcal{X}_E$ (conjunto de todas as realizações de experimentos da forma (E, x));

Princípios de Inferência

- A partir da condução do experimento E e da observação de x , podemos inferir, tirar conclusões sobre θ . Tal inferência, conclusão sobre θ é denominada (Birnbbaum (1962)) **Evidência sobre θ a partir de E e x , $Ev(e, x)$** .
- Afinal, qual é o significado de $Ev(E, x)$?
- Em princípio, não há restrição sobre $Ev(E, x)$: estimativa, decisão sobre hipóteses, etc.. (não precisa ser restrita aos problemas tradicionais de inferência estatística). Ênfase da abordagem é sobre **como $Ev(E, x)$ deve depender de E e x** .
- Críticas sobre a formulação original; revisão da formulação (Birnbbaum (1972), dentre outros); introdução de relações de equivalência em $\mathcal{R}_\theta = \cup_{E \in \mathcal{E}_\theta} \{E\} \times \mathcal{X}_E$ (conjunto de todas as realizações de experimentos da forma (E, x));

Princípios de Inferência

- A partir da condução do experimento E e da observação de x , podemos inferir, tirar conclusões sobre θ . Tal inferência, conclusão sobre θ é denominada (Birnbaum (1962)) **Evidência sobre θ a partir de E e x , $Ev(e, x)$** .
- Afinal, qual é o significado de $Ev(E, x)$?
- Em princípio, não há restrição sobre $Ev(E, x)$: estimativa, decisão sobre hipóteses, etc.. (não precisa ser restrita aos problemas tradicionais de inferência estatística). Ênfase da abordagem é sobre **como $Ev(E, x)$ deve depender de E e x** .
- Críticas sobre a formulação original; revisão da formulação (Birnbaum (1972), dentre outros); introdução de relações de equivalência em $\mathcal{R}_\theta = \cup_{E \in \mathcal{E}_\theta} \{E\} \times \mathcal{X}_E$ (conjunto de todas as realizações de experimentos da forma (E, x));

Princípios de Inferência

- A partir da condução do experimento E e da observação de x , podemos inferir, tirar conclusões sobre θ . Tal inferência, conclusão sobre θ é denominada (Birnbbaum (1962)) **Evidência sobre θ a partir de E e x , $Ev(e, x)$** .
- Afinal, qual é o significado de $Ev(E, x)$?
- Em princípio, não há restrição sobre $Ev(E, x)$: estimativa, decisão sobre hipóteses, etc.. (não precisa ser restrita aos problemas tradicionais de inferência estatística). Ênfase da abordagem é sobre **como $Ev(E, x)$ deve depender de E e x** .
- Críticas sobre a formulação original; revisão da formulação (Birnbbaum (1972), dentre outros); introdução de relações de equivalência em $\mathcal{R}_\theta = \cup_{E \in \mathcal{E}_\theta} \{E\} \times \mathcal{X}_E$ (conjunto de todas as realizações de experimentos da forma (E, x));

Princípios de Inferência

- A partir da condução do experimento E e da observação de x , podemos inferir, tirar conclusões sobre θ . Tal inferência, conclusão sobre θ é denominada (Birnbaum (1962)) **Evidência sobre θ a partir de E e x** , $Ev(e, x)$.
- Afinal, qual é o significado de $Ev(E, x)$?
- Em princípio, não há restrição sobre $Ev(E, x)$: estimativa, decisão sobre hipóteses, etc.. (não precisa ser restrita aos problemas tradicionais de inferência estatística). Ênfase da abordagem é sobre **como $Ev(E, x)$ deve depender de E e x** .
- Críticas sobre a formulação original; revisão da formulação (Birnbaum (1972), dentre outros); introdução de relações de equivalência em $\mathcal{R}_\theta = \cup_{E \in \mathcal{E}_\theta} \{E\} \times \mathcal{X}_E$ (conjunto de todas as realizações de experimentos da forma (E, x)).

Princípios de Inferência

- Exemplo 1: Consideremos o exemplo da aula passada em que $\Theta = (0, 1)$ e os experimentos $E_1 = (X, \theta, \mathcal{P}_1)$ e $E_2 = (Y, \theta, \mathcal{P}_2)$, com $X|\theta \sim \text{Bin}(10, \theta)$ e $Y|\theta \sim \text{BN}(2, \theta)$. Consideremos as seguintes evidências sobre θ : para $R = (E, x) \in \mathcal{R}_\theta$.

$$(i) \text{Ev}_1(E, x) = \operatorname{argmax} V_x^{(E)}(\cdot)$$

$$\text{Assim, } \text{Ev}_1(E_1, 4) = \frac{4}{10} \text{ e } \text{Ev}_1(E_2, 9) = \frac{2}{9}$$

- (ii) Suponha que exista uma distribuição (a priori) contínua para θ (com densidade f). Definimos

$$\text{Ev}_2(E, x) = f_E(\cdot|x), \text{ com } f_E(\theta|x) = \frac{V_x^{(E)}(\theta) f(\theta)}{\int_{\Theta} V_x^{(E)}(\theta') f(\theta') d\theta'}$$

$$\text{Assim, se } f(\theta) = \mathbb{I}_{(0,1)}(\theta), \text{Ev}_2(E_1, 10) = 11 \theta^{10} \mathbb{I}_{(0,1)}(\theta) \text{ e}$$

$$\text{Ev}_2(E_2, 6) = 105 \theta^2 (1 - \theta)^4 \mathbb{I}_{(0,1)}(\theta).$$

Princípios de Inferência

- Exemplo 1: Consideremos o exemplo da aula passada em que $\Theta = (0, 1)$ e os experimentos $E_1 = (X, \theta, \mathcal{P}_1)$ e $E_2 = (Y, \theta, \mathcal{P}_2)$, com $X|\theta \sim \text{Bin}(10, \theta)$ e $Y|\theta \sim \text{BN}(2, \theta)$. Consideremos as seguintes evidências sobre θ : para $R = (E, x) \in \mathcal{R}_\theta$.

$$(i) \text{Ev}_1(E, x) = \operatorname{argmax} V_x^{(E)}(\cdot)$$

$$\text{Assim, } \text{Ev}_1(E_1, 4) = \frac{4}{10} \text{ e } \text{Ev}_1(E_2, 9) = \frac{2}{9}$$

- (ii) Suponha que exista uma distribuição (a priori) contínua para θ (com densidade f). Definimos

$$\text{Ev}_2(E, x) = f_E(\cdot|x), \text{ com } f_E(\theta|x) = \frac{V_x^{(E)}(\theta) f(\theta)}{\int_{\Theta} V_x^{(E)}(\theta') f(\theta') d\theta'}$$

$$\text{Assim, se } f(\theta) = \mathbb{I}_{(0,1)}(\theta), \text{Ev}_2(E_1, 10) = 11 \theta^{10} \mathbb{I}_{(0,1)}(\theta) \text{ e}$$

$$\text{Ev}_2(E_2, 6) = 105 \theta^2 (1 - \theta)^4 \mathbb{I}_{(0,1)}(\theta).$$

Princípios de Inferência

- (iii) $Ev_3(E, x) = \delta_{NV}^{(E)}(x)$, onde $\delta_{NV}^{(E)} : \mathcal{X}_E \rightarrow \Theta$ é estimador não-viesado ótimo sob E .

$$\text{Assim, } Ev_3(E_1, 6) = \frac{6}{10} \text{ e } Ev_1(E_2, 21) = \frac{1}{20}$$

Nesse exemplo, podemos definir as relações de equivalência $\cong_i \subset \mathcal{R}_\theta \times \mathcal{R}_\theta$, $i = 1, 2, 3$, por

$$(E, x) \cong_i (E', x') \Leftrightarrow Ev_i(E, x) = Ev_i(E', x')$$

Assim,

$$(E_1, 2) \cong_1 (E_2, 10) \text{ , } (E_1, 5) \cong_1 (E_2, 4) \text{ , mas}$$

$$(E_1, 2) \not\cong_1 (E_1, 7) \text{ . Além disso,}$$

$$(E_1, 2) \cong_2 (E_2, 10) \text{ , mas } (E_1, 5) \not\cong_2 (E_2, 4) \text{ . Por fim,}$$

$$(E_1, 2) \not\cong_3 (E_2, 10) \text{ e mas } (E_1, 1) \cong_3 (E_2, 11)$$

Princípios de Inferência

- (iii) $Ev_3(E, x) = \delta_{NV}^{(E)}(x)$, onde $\delta_{NV}^{(E)} : \mathcal{X}_E \rightarrow \Theta$ é estimador não-viesado ótimo sob E .

Assim, $Ev_3(E_1, 6) = \frac{6}{10}$ e $Ev_1(E_2, 21) = \frac{1}{20}$

Nesse exemplo, podemos definir as relações de equivalência $\cong_i \subset \mathcal{R}_\theta \times \mathcal{R}_\theta$, $i = 1, 2, 3$, por

$$(E, x) \cong_i (E', x') \Leftrightarrow Ev_i(E, x) = Ev_i(E', x')$$

Assim,

$$(E_1, 2) \cong_1 (E_2, 10) , (E_1, 5) \cong_1 (E_2, 4) , \text{ mas}$$

$$(E_1, 2) \not\cong_1 (E_1, 7) . \text{ Além disso,}$$

$$(E_1, 2) \cong_2 (E_2, 10) , \text{ mas } (E_1, 5) \not\cong_2 (E_2, 4) . \text{ Por fim,}$$

$$(E_1, 2) \not\cong_3 (E_2, 10) \text{ e mas } (E_1, 1) \cong_3 (E_2, 11)$$

Princípios de Inferência

- **PRINCÍPIO DA SUFICIÊNCIA (WSP)**

Considere o experimento $E = (X, \theta, \mathcal{P}) = (\mathcal{X}, \Theta, \mathcal{P})$ para θ .
Seja $T : \mathcal{X} \rightarrow \mathcal{T}$ uma estatística suficiente para θ . Então,
para $x_1, x_2 \in \mathcal{X}$,

$$T(x_1) = T(x_2) \Rightarrow Ev(E, x_1) = Ev(E, x_2)$$

- Dois pontos amostrais que levam a um mesmo valor de uma estatística suficiente T para θ devem produzir inferências idênticas (coincidentes) sobre θ .
- "... the Weak Sufficiency Principle is, itself, a cornerstone of classical statistics" (Berger and Wolpert (1988)).

Princípios de Inferência

● PRINCÍPIO DA SUFICIÊNCIA (WSP)

Considere o experimento $E = (X, \theta, \mathcal{P}) = (\mathcal{X}, \Theta, \mathcal{P})$ para θ .
Seja $T : \mathcal{X} \rightarrow \mathcal{T}$ uma estatística suficiente para θ . Então,
para $x_1, x_2 \in \mathcal{X}$,

$$T(x_1) = T(x_2) \Rightarrow Ev(E, x_1) = Ev(E, x_2)$$

- Dois pontos amostrais que levam a um mesmo valor de uma estatística suficiente T para θ devem produzir inferências idênticas (coincidentes) sobre θ .
- "... the Weak Sufficiency Principle is, itself, a cornerstone of classical statistics" (Berger and Wolpert (1988)).

Princípios de Inferência

- **PRINCÍPIO DA SUFICIÊNCIA (WSP)**

Considere o experimento $E = (X, \theta, \mathcal{P}) = (\mathcal{X}, \Theta, \mathcal{P})$ para θ .
Seja $T : \mathcal{X} \rightarrow \mathcal{T}$ uma estatística suficiente para θ . Então,
para $x_1, x_2 \in \mathcal{X}$,

$$T(x_1) = T(x_2) \Rightarrow Ev(E, x_1) = Ev(E, x_2)$$

- Dois pontos amostrais que levam a um mesmo valor de uma estatística suficiente T para θ devem produzir inferências idênticas (coincidentes) sobre θ .
- "... the Weak Sufficiency Principle is, itself, a cornerstone of classical statistics" (Berger and Wolpert (1988)).

Princípios de Inferência

- **PRINCÍPIO DA SUFICIÊNCIA (WSP)**

Considere o experimento $E = (X, \theta, \mathcal{P}) = (\mathcal{X}, \Theta, \mathcal{P})$ para θ .
Seja $T : \mathcal{X} \rightarrow \mathcal{T}$ uma estatística suficiente para θ . Então,
para $x_1, x_2 \in \mathcal{X}$,

$$T(x_1) = T(x_2) \Rightarrow Ev(E, x_1) = Ev(E, x_2)$$

- Dois pontos amostrais que levam a um mesmo valor de uma estatística suficiente T para θ devem produzir inferências idênticas (coincidentes) sobre θ .
- "... the Weak Sufficiency Principle is, itself, a cornerstone of classical statistics" (Berger and Wolpert (1988)).

Princípios de Inferência

- Exemplo: Consideremos o experimento $E = (\mathcal{X}, \Theta, \mathcal{P})$, \mathcal{X} enumerável, tal que, para todo $x \in \mathcal{X}$, $V_x : \Theta \rightarrow \mathbb{R}_+$ é limitada. Seja T uma estatística suficiente para θ . Consideremos a evidência sobre θ dada por

$$Ev(E, x) = \operatorname{argmax} V_x(\cdot).$$

Sejam $x_1, x_2 \in \mathcal{X}$ tais que $T(x_1) = T(x_2)$. Assim,

$$\begin{aligned} Ev(E, x_1) &= \operatorname{argmax} V_{x_1}(\cdot) = \operatorname{argmax} a(x_1) b(T(x_1), \cdot) = \\ &= \operatorname{argmax} b(T(x_1), \cdot) = \operatorname{argmax} b(T(x_2), \cdot) = \\ &= \operatorname{argmax} a(x_2) b(T(x_2), \cdot) = \operatorname{argmax} V_{x_2}(\cdot) = Ev(E, x_2) \end{aligned}$$

Logo, $T(x_1) = T(x_2) \Rightarrow Ev(E, x_1) = Ev(E, x_2)$.

Princípios de Inferência

- Exemplo: Consideremos o experimento $E = (\mathcal{X}, \Theta, \mathcal{P})$, \mathcal{X} enumerável, tal que, para todo $x \in \mathcal{X}$, $V_x : \Theta \rightarrow \mathbb{R}_+$ é limitada. Seja T uma estatística suficiente para θ . Consideremos a evidência sobre θ dada por

$$Ev(E, x) = \operatorname{argmax} V_x(\cdot).$$

Sejam $x_1, x_2 \in \mathcal{X}$ tais que $T(x_1) = T(x_2)$. Assim,

$$\begin{aligned} Ev(E, x_1) &= \operatorname{argmax} V_{x_1}(\cdot) = \operatorname{argmax} a(x_1) b(T(x_1), \cdot) = \\ &= \operatorname{argmax} b(T(x_1), \cdot) = \operatorname{argmax} b(T(x_2), \cdot) = \\ &= \operatorname{argmax} a(x_2) b(T(x_2), \cdot) = \operatorname{argmax} V_{x_2}(\cdot) = Ev(E, x_2) \end{aligned}$$

Logo, $T(x_1) = T(x_2) \Rightarrow Ev(E, x_1) = Ev(E, x_2)$.

Princípios de Inferência

- Exemplo: Consideremos o experimento $E = (\mathcal{X}, \Theta, \mathcal{P})$, \mathcal{X} enumerável. Suponhamos que exista uma distribuição de probabilidade (a priori) contínua para θ com densidade f . Seja T uma estatística suficiente para θ . Consideremos a seguinte evidência sobre θ : $Ev(E, x) = f_E(\cdot|x)$, onde

$$f_E(\theta|x) = f_E(\theta|X = x) = \frac{V_x^{(E)}(\theta) f(\theta)}{\int_{\Theta} V_x^{(E)}(\theta') f(\theta') d\theta'} \propto V_x^{(E)}(\theta) f(\theta)$$

Sejam $x_1, x_2 \in \mathcal{X}$ tais que $T(x_1) = T(x_2)$. Da definição de Ev e de suficiência (bayesiana), temos que

$$\begin{aligned} Ev(E, x_1) &= f_E(\cdot|X = x_1) = f_E(\cdot|T(X) = T(x_1)) = \\ &= f_E(\cdot|T(X) = T(x_2)) = f_E(\cdot|X = x_2) = Ev(E, x_2) \end{aligned}$$

Logo, $T(x_1) = T(x_2) \Rightarrow Ev(E, x_1) = Ev(E, x_2)$.

Princípios de Inferência

- Exemplo: Consideremos o experimento $E = (\mathcal{X}, \Theta, \mathcal{P})$, \mathcal{X} enumerável. Suponhamos que exista uma distribuição de probabilidade (a priori) contínua para θ com densidade f . Seja T uma estatística suficiente para θ . Consideremos a seguinte evidência sobre θ : $Ev(E, x) = f_E(\cdot|x)$, onde

$$f_E(\theta|x) = f_E(\theta|X = x) = \frac{V_x^{(E)}(\theta) f(\theta)}{\int_{\Theta} V_x^{(E)}(\theta') f(\theta') d\theta'} \propto V_x^{(E)}(\theta) f(\theta)$$

Sejam $x_1, x_2 \in \mathcal{X}$ tais que $T(x_1) = T(x_2)$. Da definição de Ev e de suficiência (bayesiana), temos que

$$\begin{aligned} Ev(E, x_1) &= f_E(\cdot|X = x_1) = f_E(\cdot|T(X) = T(x_1)) = \\ &= f_E(\cdot|T(X) = T(x_2)) = f_E(\cdot|X = x_2) = Ev(E, x_2) \end{aligned}$$

Logo, $T(x_1) = T(x_2) \Rightarrow Ev(E, x_1) = Ev(E, x_2)$.

Princípios de Inferência

- Exemplo: Consideremos o experimento $E = (\mathcal{X}, \Theta, \mathcal{P})$, \mathcal{X} enumerável. Seja T uma estatística suficiente e completa. Suponhamos que exista estimador não-viesado para θ , $\delta_0 : \mathcal{X} \rightarrow \Theta$. Seja $\delta_E^*(X) = \mathbb{E}_E(\delta_0(X)|T(X)) = g_E(T(X))$ o ENVVUM para θ . Consideremos a seguinte evidência sobre θ a partir de E e x :

$$Ev(E, x) = \delta_E^*(x) = g_E(T(x))$$

Sejam $x_1, x_2 \in \mathcal{X}$ tais que $T(x_1) = T(x_2)$. Então,

$$\begin{aligned} Ev(E, x_1) &= \delta_E^*(x_1) = g_E(T(x_1)) = g_E(T(x_2)) = \\ &= \delta_E^*(x_2) = Ev(E, x_2) \end{aligned}$$

Logo, $T(x_1) = T(x_2) \Rightarrow Ev(E, x_1) = Ev(E, x_2)$.

Princípios de Inferência

- Exemplo: Consideremos o experimento $E = (\mathcal{X}, \Theta, \mathcal{P})$, \mathcal{X} enumerável. Seja T uma estatística suficiente e completa. Suponhamos que exista estimador não-viesado para θ , $\delta_0 : \mathcal{X} \rightarrow \Theta$. Seja $\delta_E^*(X) = \mathbb{E}_E(\delta_0(X)|T(X)) = g_E(T(X))$ o ENVVUM para θ . Consideremos a seguinte evidência sobre θ a partir de E e x :

$$Ev(E, x) = \delta_E^*(x) = g_E(T(x))$$

Sejam $x_1, x_2 \in \mathcal{X}$ tais que $T(x_1) = T(x_2)$. Então,

$$\begin{aligned} Ev(E, x_1) &= \delta_E^*(x_1) = g_E(T(x_1)) = g_E(T(x_2)) = \\ &= \delta_E^*(x_2) = Ev(E, x_2) \end{aligned}$$

Logo, $T(x_1) = T(x_2) \Rightarrow Ev(E, x_1) = Ev(E, x_2)$.